# ANALISIS DETERMINAN PENYEBAB *STUNTING* PROVINSI DI INDONESIA: APLIKASI MODEL *RANDOM FOREST* DAN INTERPRETASI SHAP PADA DATA SSGI TAHUN 2024

**TUGAS AKHIR**

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut Teknologi Sumatera


**Oleh:**

**Cindy Nadila Putri**

**122140002**



**PROGRAM STUDI TEKNIK INFORMATIKA**

**FAKULTAS TEKNOLOGI INDUSTRI**

**INSTITUT TEKNOLOGI SUMATERA**

**LAMPUNG SELATAN**


**2026**

# KATA PENGANTAR

Puji syukur kehadirat Allah SWT, yang atas rahmat dan karunia-Nya, penulis dapat menyelesaikan Tugas Akhir berjudul ”Analisis Determinan Penyebab Stunting Provinsi di Indonesia: Aplikasi Model Random Forest dan Interpretasi SHAP pada Data SSGI Tahun 2024”. Tugas Akhir ini disusun guna memenuhi salah satu syarat kelulusan Program Studi Teknik Informatika, Institut Teknologi Sumatera.

Penulis menyampaikan ucapan terima kasih kepada Bapak Martin Clinton Tosima Manullang, Ph.D., selaku dosen pembimbing atas bimbingan, arahan, masukan, dan motivasi yang diberikan selama proses penyusunan Tugas Akhir ini.

Rasa terima kasih yang tak terhingga penulis sampaikan kepada orang tua dan keluarga penulis atas doa dan dukungannya. Penulis juga berterima kasih kepada seluruh sahabat dan rekan seperjuangan atas kerja sama dan semangat selama masa perkuliahan.

Penulis menyadari Tugas Akhir ini masih jauh dari sempurna, oleh karena itu kritik dan saran yang membangun sangat diharapkan demi perbaikan. Semoga Tugas Akhir ini dapat memberikan manfaat bagi para pembaca.

# DAFTAR ISI

**KATA PENGANTAR** . . . . . **ii**

**DAFTAR ISI** . . . . . **iii**

**DAFTAR TABEL** . . . . . **vi**

**DAFTAR GAMBAR** . . . . . **vii**

**DAFTAR RUMUS** . . . . . **viii**

**DAFTAR KODE** . . . . . **x**

**BAB I PENDAHULUAN** . . . . . **1**

1.1 Latar Belakang . . . . . 1

1.2 Rumusan Masalah . . . . . 5

1.3 Tujuan Penelitian . . . . . 5

1.4 Batasan Masalah . . . . . 5

1.5 Manfaat Penelitian . . . . . 6

1.6 Sistematika Penulisan . . . . . 7

**BAB II TINJAUAN PUSTAKA** . . . . . **9**

2.1 Tinjauan Pustaka . . . . . 9

2.2 Dasar Teori . . . . . 14

2.2.1 *Stunting* . . . . . 14

2.2.2 Determinan *Stunting* . . . . . 15

2.2.3 Survei Status Gizi Indonesia (SSGI) . . . . . 17

2.2.4 *Machine Learning* . . . . . 18

2.2.5 *Supervised Learning* . . . . . 19

2.2.5.1 Regresi . . . . . 19

2.2.6 *Random Forest Regression* . . . . . 20

2.2.7 *Feature Selection* . . . . . 21
2.2.8 Transformasi Data . . . . . 22
2.2.9 Agregasi Data . . . . . 22
2.2.10 Metrik Evaluasi Regresi . . . . . 23
2.2.11 *Cross Validation* . . . . . 24
2.2.12 *Leave-One-Out Cross Validation* (LOOCV) . . . . . 25
2.2.13 Interpretabilitas Model . . . . . 26
2.2.14 SHAP *(SHapley Additive exPlanations)* . . . . . 27

**BAB III METODE PENELITIAN . . . . . 28**
3.1 Alur Penelitian . . . . . 28
3.2 Langkah Penelitian . . . . . 29
3.2.1 Persiapan Data . . . . . 30
3.2.1.1 Ekstraksi Data . . . . . 31
3.2.1.2 Seleksi Fitur Determinan . . . . . 32
3.2.1.3 Transformasi dan Agregasi Data . . . . . 32
3.2.2 Pra-pemrosesan Data . . . . . 34
3.2.2.1 Representasi Dataset Penelitian . . . . . 34
3.2.3 Pemodelan *Random Forest* . . . . . 35
3.2.3.1 *Hyperparameter Tuning* Berbasis *Cross Validation* . . 36
3.2.3.2 Pelatihan Model Final . . . . . 37
3.2.4 Evaluasi Performa Model . . . . . 38
3.3 Interpretasi Hasil dengan SHAP . . . . . 39
3.3.1 Interpretasi Global . . . . . 40
3.3.2 Interpretasi Lokal . . . . . 41
3.3.2.1 Pemilihan Sampel Provinsi . . . . . 41
3.3.2.2 Visualisasi dan Analisis *Waterfall Plot* . . . . . 42
3.4 Lingkungan Pengembangan Model . . . . . 42
3.5 Ilustrasi Perhitungan Metode . . . . . 43

3.5.1 Prediksi *Random Forest Regression* . . . . . 43
3.5.2 Perhitungan *Error* Prediksi . . . . . 44
3.5.3 Perhitungan Metrik Evaluasi . . . . . 45
3.6 Ilustrasi Rancangan Pengujian . . . . . 46
3.6.1 Skema *Leave-One-Out Cross Validation* (LOOCV) . . . . . 47
3.6.2 *Hyperparameter Tuning* . . . . . 47
3.6.3 Pemilihan Model Final . . . . . 48

**BAB IV HASIL DAN PEMBAHASAN . . . . . 49**
4.1 Hasil Penelitian . . . . . 49
4.2 Hasil Pengujian . . . . . 49
4.3 Analisis Hasil Penelitian . . . . . 50

**BAB V HASIL DAN PEMBAHASAN . . . . . 52**
5.1 Hasil Penelitian . . . . . 52
5.1.1 Analisis Deskriptif . . . . . 52
5.1.2 Persiapan Data . . . . . 53
5.1.2.1 Ekstraksi Data . . . . . 54
5.1.2.2 Seleksi Fitur Determinan . . . . . 55
5.1.2.3 Transformasi dan Agregasi Data . . . . . 56
5.1.3 Pra-pemrosesan dan Eksplorasi Data . . . . . 57
5.1.3.1 Eksplorasi Data (EDA) . . . . . 58
5.1.3.2 Penanganan *Missing Value* . . . . . 62
5.1.3.3 Eliminasi Variabel Non-Determinan . . . . . 62
5.1.3.4 Penetapan Variabel Penelitian . . . . . 63
5.1.4 Pemodelan *Random Forest* . . . . . 64
5.1.4.1 *Hyperparameter Tuning* Berbasis *Cross Validation* . . 64
5.1.4.2 Pelatihan Model Final . . . . . 65
5.2 Evaluasi Performa Model . . . . . 67
5.3 Analisis Hasil Pemodelan *Random Forest* . . . . . 68

5.3.1 Analisis Konfigurasi Parameter . . . . . 69
5.3.2 Analisis Pola Prediksi *Stunting* per Provinsi . . . . . 69
5.3.3 Analisis Metrik Evaluasi . . . . . 69
5.4 Interpretasi Model Menggunakan SHAP . . . . . 70
5.4.1 Interpretasi Global (*Global Explanation*) . . . . . 71
5.4.1.1 Tingkat Kepentingan Fitur (*Feature Importance Plot*) 71
5.4.1.2 Arah dan Distribusi Dampak Fitur (*Summary Plot*) . . 74
5.4.1.3 Analisis Ketergantungan Fitur (*Dependence Plot*) . . . 76
5.5 Analisis Hasil Penelitian . . . . . 81
5.5.1 Interpretasi Global (*Global Explanation*) . . . . . 81
5.5.2 Interpretasi Lokal (*Local Explanation*) . . . . . 82
5.5.3 Pembahasan dan Rekomendasi Kebijakan . . . . . 82

**DAFTAR PUSTAKA** . . . . . **83**

**LAMPIRAN** . . . . . **87**
A Dataset . . . . . 87

# DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu . . . . . 12
Tabel 3.1 Distribusi Variabel Determinan Stunting berdasarkan Kategori . . . . . 35
Tabel 3.2 Data Hipotetis Output Pohon Keputusan . . . . . 44
Tabel 3.3 Data Hipotetis Aktual vs Prediksi . . . . . 44
Tabel 3.4 Data Hipotetis untuk Evaluasi Agregat . . . . . 45
Tabel 3.5 Ilustrasi Skema Pembagian Data LOOCV . . . . . 47
Tabel 3.6 Data Hipotetis Hasil Tuning Parameter . . . . . 48
Tabel 4.1 Data *dummy* Pengujian . . . . . 50
Tabel 5.1 Kondisi Awal Dataset SSGI 2024 . . . . . 54
Tabel 5.2 Potongan Daftar Hasil Ekstraksi Tabel dari Laporan SSGI 2024 . . . . . 55
Tabel 5.3 Potongan Daftar Hasil Seleksi Fitur Determinan *Stunting* . . 55
Tabel 5.4 Skenario Transformasi dan Agregasi Fitur Determinan *Stunting* . . . . . 57
Tabel 5.5 Cuplikan *Dataset* Mentah SSGI 2024 Sebelum Pra-pemrosesan . . . . . 58
Tabel 5.6 Perbandingan Jumlah Observasi Sebelum dan Sesudah Pembersihan . . . . . 62
Tabel 5.7 Perbandingan Jumlah Atribut Sebelum dan Sesudah Eliminasi 63
Tabel 5.8 Ilustrasi *Dataset* Final Pemodelan *Stunting* . . . . . 64
Tabel 5.9 Hasil *Hyperparameter Tuning* Model *Random Forest* . . . . . 65
Tabel 5.10 Cuplikan Perbandingan Nilai Aktual dan Prediksi . . . . . 66
Tabel 5.11 Hasil Pengujian Performa Model Regresi Final . . . . . 68
Tabel 5.12 Keterangan Istilah Variabel pada *SHAP Bar Plot* . . . . . 73

# DAFTAR GAMBAR

Gambar 2.1 Kerangka Konseptual Faktor Penyebab *Stunting* [17] . . . . 16
Gambar 2.2 Struktur Umum *Random Forest Regression* [22] . . . . . 20
Gambar 2.3 Skema Partisi Data pada LOOCV [25] . . . . . 25
Gambar 3.1 Diagram Alir Penelitian . . . . . 28
Gambar 3.2 Alur Penyiapan Data . . . . . 31
Gambar 3.3 Alur Pra-pemrosesan Data . . . . . 34
Gambar 3.4 Alur Pembangunan Model *Random Forest Regression* . . . 36
Gambar 3.5 Alur Interpretasi Model dengan SHAP . . . . . 39
Gambar 4.1 Contoh Graf Pengujian . . . . . 50
Gambar 5.1 Distribusi Prevalensi *Stunting* per Provinsi . . . . . 60
Gambar 5.2 Histogram Distribusi Data Target . . . . . 61
Gambar 5.3 *Heatmap* Korelasi 15 Variabel Teratas . . . . . 61
Gambar 5.4 Sebaran Nilai Aktual dan Prediksi *Stunting* per Provinsi . 67
Gambar 5.5 Rata-Rata Dampak Absolut Fitur terhadap *Stunting* (*SHAP Bar Plot*) . . . . . 72
Gambar 5.6 Arah dan Distribusi Dampak Fitur terhadap *Stunting* (*SHAP Summary Plot*) . . . . . 75
Gambar 5.7 *Dependence Plot* Variabel Persen Tidak Memenuhi MMFF 77
Gambar 5.8 *Dependence Plot* Variabel Persen Usia Ibu Berisiko . . . . . 78
Gambar 5.9 *Dependence Plot* Variabel Persen Tidak Memenuhi MDD 79
Gambar 5.10 *Dependence Plot* Variabel Persen Tidak Dapat PMT . . . . 80
Gambar 5.11 *Dependence Plot* Variabel Persen Akses Sanitasi Berisiko 81

# DAFTAR RUMUS

Rumus 2.1 Rumus perhitungan Z-score antropometri . . . . . 15
Rumus 2.2 Persamaan dasar regresi linear . . . . . 19
Rumus 2.3 Rata-rata prediksi pada Random Forest Regression . . . . . 20
Rumus 2.4 Rumus Mean Absolute Error (MAE) . . . . . 23
Rumus 2.5 Rumus Root Mean Square Error (RMSE) . . . . . 23
Rumus 2.6 Rumus Mean Absolute Percentage Error (MAPE) . . . . . 24
Rumus 2.7 Rumus Koefisien Determinasi ($R^2$) . . . . . 24

# DAFTAR KODE

Kode 4.1 Akuisisi Gambar . . . . . 49

# BAB I
# PENDAHULUAN

## 1.1 Latar Belakang

Kualitas sumber daya manusia yang unggul sangat ditentukan oleh status gizi dan kesehatan yang optimal pada masa pertumbuhan. Di Indonesia, pencapaian kualitas tersebut masih terhambat oleh tingginya prevalensi masalah gizi kronis atau yang dikenal sebagai *stunting*. Istilah *stunting* pertama kali diperkenalkan dalam literatur medis pada tahun 1972 untuk mengklasifikasikan kondisi perlambatan pertumbuhan linear akibat malnutrisi kronis [1] Masalah ini telah menjadi perhatian serius karena dampaknya yang meluas, terutama pada anak-anak sebagai generasi penerus bangsa. Berbagai faktor, seperti pola hidup, akses terhadap makanan bergizi, serta kualitas pelayanan kesehatan, turut berkontribusi terhadap tingginya prevalensi masalah ini.

Penyakit *stunting* merupakan kondisi di mana tubuh mengalami kekurangan gizi secara berlebihan dan terjadi pada rentang waktu yang cukup lama [2]. Dampak dari masalah ini akan mengakibatkan kendala pertumbuhan pada anak sehingga tinggi badan anak cenderung menjadi lebih pendek. Tak hanya memengaruhi pertumbuhan fisik, kondisi *stunting* juga akan berpengaruh ke dalam aspek pertumbuhan lainnya seperti mental, intelektual, dan kognitif anak [3]. Oleh karena itu, penting untuk memahami faktor-faktor yang menyebabkan terjadinya *stunting* agar dapat mengambil langkah-langkah pencegahan yang efektif.

Di Indonesia, kasus *stunting* terjadi pada balita usia 0-5 tahun berada pada persentase sebesar 19,8% menurut Survei Status Gizi Indonesia (SSGI) [4]. Meskipun telah mengalami penurunan dari tahun sebelumnya yaitu angka 21,5%, hasil ini menunjukan bahwa target pemerintah Indonesia yaitu menurunkan prevalensi *stunting* sampai 14,4% di tahun 2029 masih belum tercapai [5],

[6]. Kondisi ini menegaskan bahwa stunting masih menjadi permasalahan kesehatan masyarakat yang memerlukan perhatian serius dan pendekatan yang komprehensif. Selain itu, upaya penanganan stunting tidak hanya berfokus pada penurunan angka prevalensi, tetapi juga pada pemahaman faktor-faktor yang memengaruhi terjadinya kondisi tersebut secara lebih mendalam.

*Stunting* dapat berasal dari faktor-faktor yang sangat kompleks dilihat dari aspek sosial, biologis, maupun lingkungan. Faktor-faktor seperti kurangnya asupan gizi, buruknya sanitasi, serta keterbatasan akses terhadap layanan kesehatan sering kali tidak berdiri sendiri, melainkan memiliki hubungan yang saling memengaruhi satu sama lain [7], [8]. Dalam konteks analisis data, keterkaitan antarvariabel ini berpotensi menimbulkan hubungan yang kuat atau tumpang tindih, sehingga penting untuk dipertimbangkan dalam proses pemodelan. Selain itu, faktor lain seperti tingkat edukasi ibu dan kondisi kehamilan, termasuk kejadian berat badan lahir rendah (BBLR), juga berkontribusi terhadap risiko stunting di kemudian hari [8]. Hal ini dapat mengakibatkan terjadinya *stunting* di kemudian hari. Meskipun berbagai faktor risiko tersebut bersifat umum, intensitas dan dampaknya ternyata sangat bervariasi bergantung pada kondisi geografis dan sosiodemografi masing-masing daerah.

Tingkat *stunting* di Indonesia sendiri dinilai tidak merata di seluruh wilayah. Beberapa provinsi seperti Bali dan DI Yogyakarta menunjukkan angka prevalensi yang relatif rendah, berbanding terbalik dengan provinsi Nusa Tenggara Timur dan Sulawesi Barat yang mencatat angka jauh lebih tinggi [4]. Situasi yang timpang ini menunjukkan adanya variasi faktor determinan yang memengaruhi kejadian *stunting* di tiap daerah, baik dari segi sosial, ekonomi, pendidikan, maupun kondisi lingkungan [9]. Faktor lainnya seperti status gizi ibu, akses terhadap layanan kesehatan, dan sanitasi dasar memiliki kontribusi yang berbeda-beda pada setiap wilayah. Adanya variasi faktor risiko ini mengindikasikan bahwa pendekatan penanganan yang bersifat generalis memiliki keterbatasan

dalam menjangkau akar masalah di tiap daerah, sehingga dibutuhkan landasan data yang spesifik per wilayah untuk mendukung perumusan strategi intervensi yang lebih presisi dan tepat sasaran. Maka dari itu, diperlukan analisis yang lebih mendalam untuk memahami faktor-faktor yang paling berpengaruh untuk situasi *stunting* tiap provinsi.

Mengingat kompleksitas faktor determinan yang memengaruhi kejadian *stunting*, metode analisis statistik konvensional sering kali memiliki keterbatasan dalam menangkap pola hubungan antarvariabel yang rumit. Oleh karena itu, pendekatan komputasi modern berbasis *Machine Learning* kini menjadi alternatif solusi yang krusial untuk memetakan faktor risiko dengan akurasi yang lebih tinggi. Pemanfaatan algoritma cerdas ini memungkinkan pengolahan data dalam skala besar sekaligus mengungkap interaksi non-linear yang sulit dideteksi oleh metode tradisional. Efektivitas pendekatan tersebut telah terbukti secara empiris dalam studi yang berhasil mengidentifikasi determinan utama malnutrisi di negara berkembang dengan performa prediksi yang sangat kompetitif [10].

Penelitian sebelumnya menerapkan algoritma *machine learning* untuk memprediksi *stunting* pada kalangan remaja di Ethiopia dan menunjukkan bahwa pendekatan tersebut mampu menangkap hubungan kompleks antarvariabel [9]. Namun, penelitian ini dilakukan pada kelompok usia dan wilayah tertentu, sehingga konteks penerapannya masih terbatas. Di Indonesia, pendekatan serupa telah mulai dikembangkan, salah satunya oleh Pratama *et al.* (2024) yang membandingkan beberapa algoritma dalam memprediksi prevalensi *stunting* tingkat provinsi dan menemukan bahwa *Random Forest* memberikan performa terbaik [11]. Studi tersebut memberikan gambaran awal mengenai potensi model prediktif dalam analisis *stunting* di Indonesia.

Meskipun studi di Indonesia tersebut telah berhasil membangun model prediksi *stunting*, fokus utamanya masih terbatas pada pencapaian metrik akurasi dan belum mengurai interaksi antarvariabel secara mendalam. Di sisi lain, pemanfaatan algoritma interpretabilitas seperti *SHAP* umumnya masih

berpusat pada studi kasus di luar negeri yang memiliki karakteristik demografi jauh berbeda dari kondisi lokal. Oleh karena itu, riset yang memanfaatkan data nasional terbaru untuk memadukan performa prediksi dengan penjelasan kontribusi fitur (*feature contribution*) secara transparan masih sangat minim. Menjawab *research gap* tersebut, penelitian ini mengusulkan pendekatan yang tidak sekadar berfokus pada hasil akhir dari model *black-box*, tetapi juga mampu membedah arah dan besaran pengaruh setiap variabel determinan secara logis.

Untuk mengatasi keterbatasan tersebut, penelitian ini menggunakan algoritma *Random Forest* yang dikombinasikan dengan metode interpretabilitas SHAP (*SHapley Additive exPlanations*). Pemilihan *Random Forest* tidak hanya didasarkan pada performa prediksi yang telah ditunjukkan pada penelitian sebelumnya, tetapi juga pada kemampuannya dalam menangani hubungan non-linear serta interaksi kompleks antarvariabel yang umum ditemukan pada data kesehatan populasi. Selain itu, model ini relatif stabil terhadap variabel yang saling berkorelasi dan tidak bergantung pada asumsi distribusi tertentu, sehingga sesuai untuk karakteristik data agregat SSGI. Sementara itu, SHAP digunakan untuk menjelaskan kontribusi masing-masing fitur terhadap hasil prediksi model [10]. Melalui pendekatan ini, setiap faktor dapat dinilai apakah ia meningkatkan atau menurunkan kemungkinan terjadinya stunting pada suatu wilayah. Dengan demikian, kombinasi antara *Random Forest* dan SHAP tidak hanya memberikan hasil prediksi yang akurat, tetapi juga penjelasan yang dapat dipahami secara intuitif oleh pengambil keputusan. Pendekatan ini memberikan nilai tambah dalam analisis kebijakan berbasis data, terutama untuk menentukan prioritas intervensi di daerah dengan tingkat *stunting* tinggi.

Menjawab permasalahan tersebut, penelitian ini diarahkan untuk mengidentifikasi faktor-faktor determinan utama yang memengaruhi prevalensi *stunting* antar provinsi di Indonesia menggunakan data SSGI tahun 2024 melalui pendekatan *Random Forest* yang diinterpretasikan dengan SHAP. Penelitian ini berfokus pada dua aspek utama, yaitu menilai performa model dalam

memprediksi tingkat *stunting* serta memahami peran masing-masing variabel terhadap hasil prediksi. Hasil penelitian diharapkan dapat memberikan dasar empiris bagi pemerintah dan pemangku kebijakan dalam merancang strategi intervensi gizi yang lebih efektif dan berbasis bukti ilmiah.

## 1.2 Rumusan Masalah

Berdasarkan pemaparan latar belakang, dihasilkan rumusan masalah pada penelitian yang akan dijabarkan pada poin berikut:

1. Faktor apa saja yang menjadi determinan utama penyebab *stunting* antar provinsi di Indonesia berdasarkan data SSGI tahun 2024?
2. Bagaimana performa model *Random Forest* dalam memprediksi prevalensi *stunting* antar provinsi di Indonesia?
3. Bagaimana interpretasi SHAP digunakan untuk menjelaskan kontribusi masing-masing faktor terhadap hasil prediksi model *Random Forest*?

## 1.3 Tujuan Penelitian

Setelah penjabaran rumusan masalah, pada penelitian ini dibuat tujuan penelitian yaitu sebagai berikut:

1. Mengidentifikasi faktor-faktor determinan utama penyebab *stunting* antar provinsi di Indonesia berdasarkan data SSGI tahun 2024.
2. Menganalisis performa model *Random Forest* dalam memprediksi prevalensi *stunting* antar provinsi di Indonesia.
3. Menerapkan interpretasi SHAP untuk menjelaskan kontribusi masing-masing faktor terhadap hasil prediksi model *Random Forest*.

## 1.4 Batasan Masalah

Agar penelitian tidak terlalu luas dan tidak keluar dari pokok permasalahan, maka ditentukan batasan oleh beberapa poin berikut:

1. Data yang digunakan untuk penelitian ini terbatas pada Survei Status Gizi Indonesia (SSGI) tahun 2024 yang telah dipublikasikan oleh Kementerian

Kesehatan RI. Perlu diketahui bahwa penelitian ini tidak menggunakan data tambahan dari sumber lain. Sehingga penelitian yang dilakukan bukan analisis *time-series* antartahun dan memiliki ruang lingkup spasial terbatas pada 38 provinsi di Indonesia sesuai ketersediaan data.

2. Populasi yang diambil untuk menjadi fokus penelitian ini adalah anak balita usia 0-59 bulan (5 tahun), sesuai dengan sasaran pengukuran prevalensi *stunting* pada SSGI.
3. Variabel yang digunakan untuk penelitian ini mencakup berbagai faktor yang memiliki potensi untuk memengaruhi prevalensi penyebab stunting, seperti karakteristik balita, karakteristik ibu, serta kondisi rumah tangga yang meliputi status gizi, pendidikan, ekonomi, dan akses terhadap fasilitas kesehatan, air bersih, serta sanitasi. variabel-variabel ini merupakan sebagian dari indikator yang tersedia dalam dataset SSGI tahun 2024 dan dipilih berdasarkan relevansi terhadap topik penelitian.
4. Analisis yang dilakukan pada penelitian ini difokuskan pada tingkat provinsi di Indonesia, sehingga hasilnya mencerminkan kondisi agregat dan tidak mempertimbangkan variasi di tingkat kabupaten/kota atau individu.
5. Model yang digunakan untuk penelitian ini adalah algoritma *Random Forest* untuk memprediksi prevalensi *stunting*, dengan interpretasi hasil menggunakan metode SHAP (*SHapley Additive exPlanations*) untuk memahami kontribusi setiap variabel terhadap prediksi prevalensi *stunting*.
6. Penelitian ini berfokus pada analisis faktor determinan penyebab *stunting*, bukan pada pengembangan sistem prediksi *stunting* secara *real-time* atau aplikasi praktis lainnya.

## 1.5 Manfaat Penelitian

Penelitian ini dilaksanakan dengan harapan dapat memberikan manfaat sebagai berikut:

1. Bagi masyarakat, penelitian ini memberikan informasi empiris mengenai faktor determinan utama yang memengaruhi prevalensi *stunting* antarprovinsi di Indonesia. Selain itu, hasil interpretasi model menggunakan SHAP dapat membantu menjelaskan kontribusi masing-masing faktor secara lebih jelas, sehingga dapat digunakan sebagai dasar dalam penyusunan strategi intervensi gizi yang lebih tepat sasaran sesuai karakteristik wilayah.
2. Bagi peneliti, penelitian ini memberikan pemahaman mengenai penerapan model *Random Forest* dalam memprediksi prevalensi *stunting* serta pemanfaatan metode interpretabilitas SHAP untuk menjelaskan hasil prediksi model pada data kesehatan masyarakat.
3. Bagi akademisi, penelitian ini dapat menjadi referensi dalam pengembangan analisis data kesehatan menggunakan pendekatan *machine learning*, khususnya dalam mengintegrasikan model prediktif dengan metode interpretasi untuk menghasilkan analisis yang lebih komprehensif.

## 1.6 Sistematika Penulisan

Secara keseluruhan, struktur penulisan laporan ini disusun untuk memberikan gambaran umum setiap tahapan penelitian mengenai analisis determinan penyebab *stunting* di provinsi-provinsi di Indonesia. Setiap bab disusun secara sistematis agar pembahasan mengenai penerapan model *Random Forest* dan interpretasi SHAP pada data SSGI tahun 2024 dapat diikuti dengan runtut dan mudah dipahami.

**Bab I**

Bab I berisi pendahuluan. Pendahuluan menguraikan latar belakang, rumusan masalah, tujuan, manfaat, batasan masalah dan sistematika penulisan dari penelitian.

**Bab II**

Bab II berisi tinjauan pustaka. Pada bab ini akan dibahas teori-teori mengenai *stunting*, faktor-faktor determinan penyebab *stunting*, Survei Status Gizi Indonesia (SSGI), serta penerapan algoritma *machine learning* khususnya *Random Forest* pada model prediksi risiko *stunting*. Selain itu, bab ini juga membahas hasil penelitian terdahulu yang relevan sebagai landasan konseptual dan pembeda penelitian ini dari studi yang telah dilakukan sebelumnya.

**Bab III**

Bab ini menjelaskan metode yang akan digunakan dalam penelitian, termask sumber dan jenis data, variabel penelitian, tahapan pengolahan data, serta rancangan model analisis menggunakan *Random Forest* dan SHAP. Selain itu, bab ini juga menjelaskan mengenai teknik evaluasi model serta prosedur interpretasi hasil untuk mengidentifikasi faktor determinan utama penyebab *stunting*.

**Bab IV**

Bab ini menguraikan hasil analisis data, performa model *Random Forest*, hasil interpretasi SHAP, serta pembahasan mengenai faktor-faktor determinan yang memiliki pengaruh prevalensi *stunting* antar provinsi di Indonesia.

**Bab V**

Bab V berisi Kesimpulan dan saran. Pada bab ini akan diberikan kesimpulan dari hasil penelitian yang menjawab rumusan masalah berdasarkan hasil analisis yang telah dilakukan sebelumnya. Saran-saran juga diberikan sebagai masukan bagi pihak terkait dan peneliti selanjutnya untuk pengembangan kebijakan dan penelitian lanjutan di bidang *stunting*.

# BAB II
# TINJAUAN PUSTAKA

## 2.1 Tinjauan Pustaka

Bagian ini memaparkan tinjauan terhadap delapan jurnal utama yang menjadi acuan dan rujukan dalam pelaksanaan penelitian ini. Jurnal-jurnal tersebut memberikan landasan mengenai pemilihan algoritma, penggunaan variabel determinan, serta metode evaluasi model yang diterapkan dalam tugas akhir ini.

1. Pande *et al.* [12] pada tahun 2023 meneliti faktor-faktor penentu pertumbuhan linear anak di India guna memahami penyebab masalah gizi kronis. Studi ini menggunakan pendekatan *multilevel mixed-effect logistic regression* untuk menguji pengaruh variabel dari tingkat individu hingga lingkungan komunitas dengan memanfaatkan data NFHS-5 yang mencakup lebih dari 146 ribu balita. Hasil analisis menunjukkan bahwa prevalensi *stunting* mencapai angka 36%, di mana faktor individu seperti jenis kelamin laki-laki dan berat lahir rendah terbukti meningkatkan risiko secara signifikan. Lingkungan dengan tingkat kemiskinan tinggi meningkatkan kemungkinan *stunting* hingga 68% pada tingkat komunitas, sedangkan komunitas dengan literasi tinggi justru mampu menurunkan risiko tersebut secara efektif. Penelitian ini menjadi referensi yang relevan karena memberikan landasan empiris bahwa variabel sosial-ekonomi dan lingkungan memiliki kontribusi besar terhadap kejadian *stunting*, selaras dengan variabel yang akan dianalisis dalam penelitian ini.
2. Zemariam *et al.* [9] pada tahun 2025 mengkaji kemampuan berbagai algoritma *machine learning* untuk memprediksi status *stunting* serta determinan sosial-ekonominya pada remaja perempuan di Ethiopia. Penelitian ini membandingkan kinerja delapan algoritma berbeda,

termasuk *Random Forest*, dengan menerapkan teknik penyeimbangan data (*SMOTE*) serta seleksi fitur algoritma Boruta untuk menyaring variabel yang paling informatif. Hasil evaluasi menunjukkan bahwa *Random Forest* menjadi model dengan performa terbaik dibandingkan algoritma lainnya, mencatatkan akurasi sebesar 77% dan nilai AUC mencapai 85%. Model ini juga berhasil mengidentifikasi bahwa faktor wilayah, indeks kekayaan rendah, serta minimnya pendidikan formal merupakan prediktor utama kejadian *stunting*. Temuan ini mendukung penelitian ini karena membuktikan efektivitas *Random Forest* dalam menangani data survei kesehatan yang kompleks, serta kemampuannya dalam menyoroti kontribusi variabel sosial-ekonomi terhadap isu gizi secara akurat.

3. Jemil *et al.* [13] pada tahun 2026 bertujuan memprediksi kejadian *severe stunting* serta determinan utamanya pada balita di 12 negara Afrika Timur. Studi ini membandingkan kinerja delapan algoritma klasifikasi dengan menerapkan teknik *SMOTE* untuk penyeimbangan data serta *Stratified 10-Fold Cross-Validation* sebagai metode evaluasi menggunakan data DHS dengan sampel lebih dari 76 ribu anak. Hasil eksperimen menempatkan *Random Forest* sebagai model terbaik dengan akurasi mencapai 87% dan nilai AUC sebesar 0,83. Studi ini berhasil mengungkap bahwa faktor seperti kurangnya ASI eksklusif, status ekonomi rendah, serta sanitasi buruk merupakan pemicu utama risiko *stunting* parah melalui analisis interpretabilitas (SHAP). Referensi ini krusial bagi penelitian ini karena memberikan validasi empiris mengenai keandalan kombinasi *Random Forest* dan metode SHAP dalam membedah faktor risiko malnutrisi secara mendetail.
4. Tamanna *et al.* [10] pada tahun 2025 memanfaatkan data *Bangladesh Demographic and Health Survey* (BDHS) untuk mengevaluasi determinan berbagai bentuk malnutrisi, termasuk *stunting*, *wasting*, dan *underweight*. Studi ini menerapkan algoritma Boruta untuk seleksi fitur sebelum

menguji performa berbagai model *machine learning*, seperti *Random Forest*, XGBoost, dan SVM, dalam memprediksi status gizi balita. Hasil evaluasi menunjukkan bahwa *Random Forest* mampu memodelkan kondisi malnutrisi secara kompetitif, dengan akurasi prediksi *stunting* mencapai 64,19% dan *wasting* sebesar 76,68%. Penelitian ini juga mengidentifikasi bahwa pendidikan ibu, indeks kekayaan, serta fasilitas sanitasi merupakan prediktor utama status gizi anak melalui analisis nilai SHAP. Temuan ini memperkuat landasan penelitian ini karena membuktikan bahwa *Random Forest* efektif digunakan untuk memodelkan masalah gizi yang kompleks, sekaligus menegaskan peran krusial variabel sosial-ekonomi yang akan menjadi fokus analisis pada tingkat provinsi di Indonesia.

5. Pratama *et al.* [11] pada tahun 2024 membandingkan efektivitas berbagai algoritma *machine learning* untuk memprediksi prevalensi *stunting* tingkat provinsi di Indonesia dalam konteks nasional. Studi ini menguji performa model seperti SVR, GAM, dan *Random Forest* menggunakan metrik evaluasi regresi dengan memanfaatkan dataset gabungan dari Survei Status Gizi Indonesia (SSGI) tahun 2021–2022 dan data publikasi resmi lainnya. Hasilnya menunjukkan bahwa *Random Forest Regression* memberikan kinerja paling unggul dengan nilai $R^2$ sebesar 0,703 dan tingkat kesalahan (MAPE) di bawah 10%. Korelasi kuat antara akses sanitasi layak dan kemiskinan terhadap angka prevalensi juga terkonfirmasi dalam penelitian tersebut. Temuan ini menjadi landasan empiris yang krusial bagi penelitian ini, karena membuktikan bahwa *Random Forest* merupakan metode yang tangguh untuk menangani karakteristik data agregat SSGI, sehingga relevan untuk diterapkan kembali pada data terbaru tahun 2024.

Ringkasan sistematis dari seluruh jurnal rujukan ditampilkan pada Tabel 2.1 untuk mempermudah pemetaan posisi penelitian terhadap studi-studi terdahulu. Tabel ini merangkum aspek-aspek kunci yang meliputi judul, metode, serta temuan utama guna memperjelas perbedaan pendekatan dan kontribusi kebaruan

dalam penelitian ini.

Tabel 2.1 Ringkasan Penelitian Terdahulu

| **No.** | **Judul & Penulis** | **Masalah** | **Metode** | **Hasil Utama** |
|---|---|---|---|---|
| 1. | Pande *et al.* [12] (2023): *Analyzing determinants from both compositional and contextual level impeding desired linear growth of children in Indian context* | Identifikasi determinan *stunting* anak (individu & kontekstual) di India. | *Multilevel Mixed-Effect Logistic Regression*. | Prevalensi *stunting* 36%; faktor risiko utama meliputi jenis kelamin laki-laki, BBLR, dan kemiskinan komunitas; literasi tinggi menjadi faktor protektif. |
| 2 | Zemariam *et al.* [9] (2025): *Prediction of stunting and its socioeconomic determinants among* | Prediksi *stunting* pada remaja | *Random Forest* (RF), | RF menjadi model terbaik (Akurasi 77%, AUC 85%). |

| No. | Judul & Penulis | Masalah | Metode | Hasil Utama |
|---|---|---|---|---|
| | *adolescent girls in Ethiopia using machine learning algorithms* | perempuan di Ethiopia beserta faktor sosial-ekonominya. | SMOTE, Boruta. | Faktor dominan: wilayah, indeks kekayaan rendah, dan kurangnya pendidikan. |
| 3. | Jemil *et al.* [13] (2026): *Predicting severe stunting and its determinants among under-five in Eastern African Countries: A machine learning algorithms* | Prediksi kejadian *severe stunting* balita di 12 negara Afrika Timur. | RF, SMOTE, *Stratified 10-Fold CV*, SHAP. | RF unggul dengan Akurasi 87% dan AUC 0.83. SHAP mengungkap determinan kunci: kurang ASI eksklusif, ekonomi lemah, dan sanitasi buruk. |
| 4 | Tamanna *et al.* [10] (2025): *Identifying determinants of malnutrition in under-five children in* | Evaluasi determinan malnutrisi | Boruta *Feature Selection*, | RF kompetitif dengan akurasi *stunting* 64,19% |

| No. | Judul & Penulis | Masalah | Metode | Hasil Utama |
|---|---|---|---|---|
| | *Bangladesh: insights from the BDHS-2022 cross-sectional study* | (*stunting, wasting*) pada balita di Bangladesh. | RF, XGBoost. | dan *wasting* 76,68%. Determinan utama: pendidikan ibu, kekayaan, dan sanitasi. |
| 5. | Pratama *et al.* [11] (2024): *Comparison of Machine Learning Algorithms for Predicting Stunting Prevalence in Indonesia* | Prediksi prevalensi *stunting* tingkat provinsi di Indonesia (Data SSGI). | *Random Forest Regression*, SVR, GAM. | *RF Regression* terbaik ($R^2 = 0,703$, MAPE ¡ 10%). Menunjukkan korelasi kuat antara sanitasi layak dan kemiskinan terhadap prevalensi. |

## 2.2 Dasar Teori

Sebelum dilakukannya sebuah penelitian, diperlukan adanya dasar teori yang memiliki kaitan erat dengan topik penelitian. Teori yang diterapkan untuk penelitian harus berupa data atau informasi yang bersifat fakta disertai dengan referensi informasi dari media seperti jurnal, buku, penelitian, dan informasi dari sumber yang dapat dipertanggungjawabkan.

### 2.2.1 *Stunting*

*Stunting* merupakan kondisi kegagalan pertumbuhan pada anak akibat kekurangan gizi kronis serta infeksi berulang dalam jangka waktu lama [14]. Secara teknis, kondisi ini diukur menggunakan indeks Tinggi Badan menurut

Umur (TB/U) dengan ambang batas nilai *Z-score* $< -2\sigma$ (Standar Deviasi) yang dihitung dari perkalian rata-rata populasi dan koefisien variasi [15], [16]. Penentuan status *stunting* melalui perhitungan *Z-score* secara matematis dinyatakan sebagai berikut:

$$Z = \frac{y - M}{M \times S} \tag{Rumus 2.1}$$

Keterangan:

- $Z$ : Nilai *z-score* yang dihasilkan untuk menentukan status gizi.
- $y$ : Nilai hasil pengukuran riil (panjang badan atau tinggi badan anak).
- $M$ : Nilai *Median* referensi populasi untuk umur dan jenis kelamin tertentu.
- $S$ : Nilai *Coefficient of Variation* (koefisien variasi) populasi untuk umur & jenis kelamin tertentu.

Kondisi ini memiliki dampak jangka pendek berupa penurunan daya tahan tubuh, serta dampak jangka panjang yang menghambat perkembangan kognitif anak [14]. Hal tersebut menjadikannya sebagai masalah multidimensi yang dipengaruhi oleh interaksi kompleks antara pola asuh, nutrisi, hingga faktor lingkungan. Karakteristik data yang dipengaruhi oleh variabel lintas sektor ini memerlukan pendekatan komputasi untuk mengidentifikasi pola determinan secara lebih akurat. Melalui pemodelan yang tepat, hubungan antar-variabel ini dapat diinterpretasikan untuk mendukung strategi intervensi yang lebih efektif di tingkat wilayah.

### 2.2.2 Determinan *Stunting*

Determinan *stunting* merupakan sekumpulan faktor risiko yang secara langsung maupun tidak langsung memengaruhi kegagalan pertumbuhan pada anak [17]. Faktor-faktor ini saling berinteraksi mulai dari tingkat asupan nutrisi individu hingga kondisi lingkungan tempat tinggal. Penentuan variabel determinan dalam penelitian ini merujuk pada kerangka konseptual yang

ditetapkan oleh *World Health Organization* (WHO), yang membagi faktor risiko menjadi tingkat konteks sosial, politik, serta faktor rumah tangga dan lingkungan [17]. Visualisasi kerangka faktor risiko tersebut disajikan pada Gambar 2.1 untuk memberikan gambaran menyeluruh mengenai hierarki penyebabnya.

Gambar 2.1 Kerangka Konseptual Faktor Penyebab *Stunting* [17]

Indikator kesehatan ibu dan anak menjadi variabel utama yang diukur melalui cakupan layanan kesehatan di suatu provinsi. Hal ini mencakup variabel seperti prevalensi ibu hamil risiko tinggi, cakupan pemberian ASI eksklusif, hingga pemenuhan imunisasi dasar lengkap [4]. Merujuk pada Gambar 2.1, variabel-variabel tersebut merepresentasikan kualitas pengasuhan dan asupan

yang merupakan faktor penyebab langsung di tingkat populasi. Tinggi rendahnya capaian indikator ini mencerminkan sejauh mana perlindungan kesehatan dasar telah terimplementasi secara merata di suatu wilayah.

Variabel sosial ekonomi dan lingkungan yang direpresentasikan melalui indikator makro juga memberikan kontribusi besar terhadap fluktuasi angka *stunting*. Akses terhadap infrastruktur dasar, seperti air minum aman dan sanitasi layak, serta tingkat kemiskinan wilayah menjadi variabel kunci dalam dimensi ini [11], [14]. Faktor-faktor tersebut bertindak sebagai determinan dasar yang memengaruhi kemampuan masyarakat dalam mengelola sumber daya kesehatan secara kolektif. Identifikasi terhadap seluruh variabel risiko ini diperlukan sebagai landasan dalam tahap pemilihan fitur (*feature selection*) pada pemodelan regresi.

### 2.2.3 Survei Status Gizi Indonesia (SSGI)

Survei Status Gizi Indonesia (SSGI) merupakan instrumen nasional utama yang digunakan oleh pemerintah untuk memantau status gizi balita secara berkala [4]. Survei ini bertujuan untuk menyediakan data prevalensi *stunting* yang akurat dan representatif dari tingkat nasional hingga kabupaten/kota [4]. Dalam penelitian ini, laporan resmi SSGI digunakan sebagai sumber primer untuk mengekstraksi variabel target dan prediktor pada skala provinsi. Penggunaan publikasi resmi ini menjamin bahwa basis analisis yang digunakan telah melalui proses validasi teknis oleh lembaga berwenang sebelum digunakan sebagai masukan model.

Indikator yang dikumpulkan dalam SSGI mencakup intervensi gizi spesifik dan intervensi gizi sensitif yang disajikan dalam bentuk proporsi populasi [4]. Indikator spesifik meliputi layanan kesehatan langsung, sedangkan indikator sensitif mencakup faktor pendukung seperti kualitas lingkungan dan sanitasi [4]. Metodologi perolehan datanya dilakukan melalui pengukuran antropometri yang terstandarisasi guna menghasilkan estimasi angka yang konsisten antarwilayah.

Proses standardisasi ini penting untuk meminimalisir bias pengukuran yang mungkin terjadi saat pengambilan sampel di lapangan secara masif.

Data hasil SSGI memiliki karakteristik nilai kontinu dalam rentang 0–100 persen yang merepresentasikan capaian makro di 38 provinsi di Indonesia [4]. Struktur data berbasis persentase ini memastikan konsistensi satuan pengukuran di seluruh variabel, sehingga mempermudah proses komputasi tanpa terkendala perbedaan skala. Karakteristik data agregat ini memberikan perspektif populasi yang luas untuk mendukung analisis kebijakan di tingkat daerah. Format data numerik yang seragam tersebut selanjutnya akan diproses menggunakan algoritma pembelajaran mesin untuk melakukan estimasi prevalensi.

### 2.2.4 *Machine Learning*

*Machine Learning* merupakan cabang dari kecerdasan buatan yang memungkinkan sistem untuk mempelajari pola secara mandiri dari kumpulan data tanpa melalui pemrograman instruksi secara eksplisit [18]. Teknologi ini bekerja dengan membangun model statistik yang mampu mengenali tren tersembunyi guna melakukan generalisasi pada data baru. Di bidang kesehatan, pendekatan ini sangat berguna untuk menganalisis hubungan antar variabel yang kompleks dan sering kali bersifat non-linear. Penggunaan algoritma ini berpotensi menghasilkan estimasi yang lebih adaptif terhadap kompleksitas data dibandingkan dengan pendekatan statistik tradisional [18].

Prinsip kerja yang paling relevan dalam pemetaan faktor kesehatan adalah *supervised learning*, di mana model dilatih menggunakan pasangan data masukan dan target yang sudah diketahui nilainya [18]. Melalui proses pelatihan ini, algoritma akan mencoba menemukan fungsi pemetaan paling optimal untuk meminimalkan kesalahan prediksi. Pendekatan ini secara khusus dapat diterapkan dalam bentuk regresi jika variabel yang diprediksi berupa nilai kontinu, seperti angka prevalensi *stunting* di tingkat provinsi. Pemodelan ini menjadi dasar teknis sebelum melakukan implementasi algoritma yang lebih

spesifik guna mendapatkan performa prediksi yang stabil dan akurat.

### 2.2.5 *Supervised Learning*

*Supervised learning* adalah kategori dalam pembelajaran mesin yang beroperasi menggunakan pasangan data masukan dan target yang telah memiliki label atau nilai kebenaran sebelumnya [18]. Dalam mekanismenya, algoritma akan mempelajari fungsi pemetaan antara fitur masukan (*input*) dan variabel target (*output*) untuk meminimalkan selisih kesalahan prediksi. Peran fitur dalam proses ini sangat krusial, karena kualitas informasi yang dikandung oleh fitur akan menentukan kemampuan model dalam mengenali karakteristik unik dari data [18]. Tujuan akhir dari model ini adalah untuk memprediksi label atau nilai pada data baru dengan tingkat akurasi yang optimal berdasarkan pengalaman pelatihan. Berdasarkan tipe variabel targetnya, *supervised learning* dapat diklasifikasikan lebih spesifik menjadi tugas klasifikasi atau tugas regresi.

#### 2.2.5.1 Regresi

Pendekatan regresi dalam *machine learning* digunakan secara khusus untuk menangani permasalahan di mana variabel target yang diprediksi merupakan nilai kontinu atau numerik [18]. Berbeda dengan klasifikasi yang mengelompokkan data ke dalam kategori diskrit, regresi berfokus pada estimasi hubungan kuantitatif antar variabel untuk menghasilkan keluaran dalam rentang angka tertentu. Ilustrasi dasar dari hubungan ini dapat digambarkan melalui persamaan regresi linear sederhana sebagai berikut:

$$y = \beta_0 + \beta_1 x + \epsilon$$

(Rumus 2.2)

Di mana $y$ adalah variabel target, $x$ adalah fitur masukan, $\beta$ adalah koefisien model, dan $\epsilon$ merupakan *error* [19]. Penggunaan metode regresi ini memungkinkan peneliti untuk memodelkan fenomena numerik seperti angka prevalensi dengan tingkat presisi yang terukur.

### 2.2.6 *Random Forest Regression*

*Random Forest Regression* merupakan algoritma *ensemble learning* yang bekerja dengan membangun sekumpulan pohon keputusan (*decision trees*) secara independen selama tahap pelatihan [20]. Algoritma ini menerapkan mekanisme *bootstrap aggregating* (*bagging*) dan seleksi fitur acak untuk menciptakan variasi antar pohon guna meningkatkan stabilitas model. Perbedaan utama *Random Forest* untuk regresi dibandingkan klasifikasi terletak pada *output* akhirnya yang merupakan nilai rata-rata dari seluruh prediksi pohon [21]. Struktur model ini dapat diilustrasikan sebagai berikut:

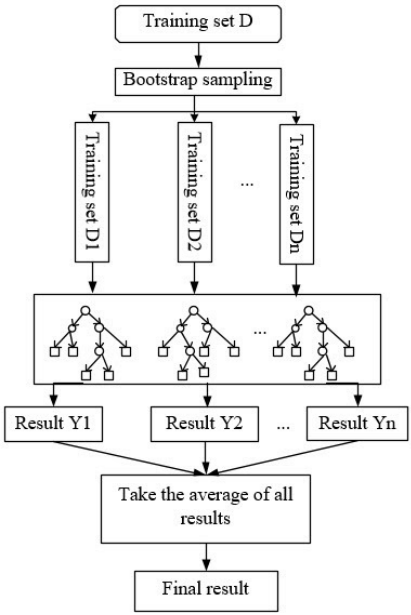


Gambar 2.2 Struktur Umum *Random Forest Regression* [22]

Secara matematis, hasil prediksi akhir ($\hat{y}$) dari total $K$ pohon keputusan dapat dirumuskan sebagai:

$$\hat{y} = \frac{1}{K} \sum_{k=1}^{K} f_k(x)$$

(Rumus 2.3)

Nilai prediksi akhir $\hat{y}$ diperoleh dengan menghitung rata-rata aritmatika dari luaran fungsi $f_k(x)$ yang dihasilkan oleh $K$ buah pohon keputusan yang dibangun secara independen dalam *ensemble* [20], [21]. Model ini dikenal tangguh dalam menangani data non-linear dan memiliki ketahanan terhadap *outlier* di dalam dataset [20]. Setelah model berhasil dibangun dan melakukan prediksi, kinerjanya harus diukur secara objektif melalui evaluasi model regresi.

### 2.2.7 *Feature Selection*

*Feature selection* merupakan proses pemilihan variabel yang paling relevan untuk digunakan dalam pembangunan model prediktif guna mengurangi kompleksitas data, meningkatkan efisiensi komputasi, serta membantu model mempelajari pola yang lebih representatif tanpa terganggu oleh variabel yang redundan [19]. Secara umum, proses seleksi fitur dimulai dari identifikasi seluruh kandidat variabel, dilanjutkan dengan peninjauan relevansi berdasarkan hubungan teoritis maupun keterkaitan statistik terhadap variabel target, serta penyederhanaan variabel yang memiliki informasi tumpang tindih agar tidak menimbulkan bias dalam pembelajaran model [18], [21]. Tahapan ini bertujuan untuk memastikan bahwa setiap variabel yang digunakan memiliki keterkaitan yang logis dengan kondisi kesehatan masyarakat, sehingga model yang dibangun mampu memberikan gambaran yang sesuai dengan realitas di lapangan. Selain itu, kualitas data seperti konsistensi satuan, kelengkapan nilai, dan potensi korelasi tinggi antar fitur juga diperiksa untuk menghindari redundansi informasi. Himpunan variabel terpilih yang telah dinyatakan relevan selanjutnya perlu disesuaikan bentuk dan skalanya melalui tahap transformasi data agar siap digunakan dalam proses pemodelan.

### 2.2.8 Transformasi Data

Transformasi data merupakan prosedur modifikasi nilai data asli ke dalam format tertentu guna meningkatkan performa algoritma pembelajaran mesin [21]. Proses ini mencakup pembersihan data dari nilai pencilan (*outliers*) guna menjamin distribusi data yang lebih stabil hingga rekayasa fitur melalui pembentukan variabel baru agar lebih representatif. Dalam analisis data kesehatan, transformasi sering kali diperlukan untuk memastikan bahwa variabel yang digunakan memiliki keterkaitan konseptual yang kuat terhadap fenomena yang diteliti [21], [23]. Keberhasilan transformasi akan menentukan kualitas representasi informasi yang kemudian dapat diproses lebih lanjut untuk menghasilkan model yang akurat. Setelah data ditransformasi, informasi tersebut dapat digunakan sebagai dasar dalam melakukan interpretasi hasil pada tahap analisis selanjutnya.

### 2.2.9 Agregasi Data

Agregasi data adalah proses pengumpulan dan perangkuman data dari tingkat individu menjadi format kelompok atau unit yang lebih besar, seperti wilayah administratif [19]. Dalam konteks spasial, agregasi memungkinkan peneliti untuk melihat representasi makro dari suatu populasi yang sering kali lebih stabil dan bermakna untuk kebijakan publik dibandingkan data individu yang fluktuatif. Meskipun memberikan keunggulan dalam penyederhanaan informasi, agregasi memiliki keterbatasan berupa hilangnya variasi detail di tingkat mikro [18]. Namun, penggunaan data agregat efektif untuk memetakan determinan kesehatan masyarakat pada lingkup wilayah seperti provinsi. Data agregat yang telah tersusun rapi ini kemudian siap digunakan sebagai masukan bagi algoritma *Random Forest Regression*.

### 2.2.10 Metrik Evaluasi Regresi

Evaluasi model regresi bertujuan untuk mengukur sejauh mana prediksi yang dihasilkan oleh model mendekati nilai aktual dari data observasi [18]. Proses ini dilakukan untuk mengetahui tingkat presisi model dalam memberikan estimasi angka prevalensi berdasarkan variabel-variabel indikator yang digunakan. Terdapat beberapa metrik statistik utama yang umum digunakan dalam mengevaluasi performa tersebut, antara lain *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), *Mean Absolute Percentage Error* (MAPE), serta Koefisien Determinasi ($R^2$). Masing-masing metrik memberikan perspektif berbeda mengenai besaran kesalahan dan kualitas kecocokan model terhadap variasi data yang tersedia [19]. Berikut adalah penjabaran dari metrik-metrik statistik yang digunakan:

1. *Mean Absolute Error* (MAE) MAE mengukur rata-rata selisih absolut antara nilai aktual dengan nilai prediksi tanpa memperhatikan arah kesalahannya [21].

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

(Rumus 2.4)

   Pada rumus tersebut, $n$ adalah jumlah data, $y_i$ merupakan nilai aktual, dan $\hat{y}_i$ adalah nilai hasil prediksi model.

2. *Root Mean Square Error* (RMSE) RMSE memberikan bobot lebih besar pada kesalahan yang besar dengan cara menguadratkan selisih sebelum dirata-ratakan dan diakarkan [11].

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

(Rumus 2.5)

   Keterangan simbol pada rumus ini adalah $n$ sebagai jumlah sampel, $y_i$ sebagai nilai observasi asli, dan $\hat{y}_i$ sebagai estimasi nilai dari model.

3. *Mean Absolute Percentage Error* (MAPE) MAPE menunjukkan besarnya kesalahan prediksi dalam bentuk persentase relatif terhadap nilai aktualnya

[24].

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

(Rumus 2.6)

Variabel $y_i$ melambangkan data aktual, $\hat{y}_i$ adalah data prediksi, dan $n$ menunjukkan total observasi yang dihitung.

4. Koefisien Determinasi ($R^2$) $R^2$ mengukur seberapa besar proporsi varians pada variabel dependen yang dapat dijelaskan oleh variabel independen dalam model [25].

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

(Rumus 2.7)

Simbol $y_i$ adalah nilai aktual, $\hat{y}_i$ adalah nilai prediksi, dan $\bar{y}$ merupakan nilai rata-rata dari seluruh data aktual.

Pemilihan metrik yang tepat sangat menentukan interpretasi peneliti terhadap akurasi model yang dikembangkan. Untuk menjamin bahwa nilai evaluasi tersebut tidak bersifat bias, diperlukan prosedur validasi yang ketat melalui *cross validation*.

### 2.2.11 *Cross Validation*

*Cross validation* merupakan teknik validasi model yang bertujuan untuk menilai kemampuan generalisasi model pada dataset yang independen [21]. Prosedur ini dilakukan dengan membagi data menjadi bagian latih (*training set*) dan bagian uji (*testing set*) secara berulang dengan skema tertentu. Tujuan utamanya adalah untuk mengurangi bias evaluasi yang mungkin muncul jika model hanya diuji pada satu bagian data acak saja [19]. Melalui proses ini, peneliti dapat memperoleh estimasi performa model yang lebih stabil dan objektif. Salah satu varian dari teknik ini yang intensif dan sistematis adalah *Leave-One-Out Cross Validation* (LOOCV).

### 2.2.12 *Leave-One-Out Cross Validation* (LOOCV)

*Leave-One-Out Cross Validation* (LOOCV) merupakan bentuk ekstrem dari *K-Fold Cross Validation* di mana jumlah lipatan (*fold*) sama dengan jumlah total sampel data ($N$) [19]. Dalam setiap iterasinya, satu sampel digunakan sebagai data uji sementara $N-1$ sampel lainnya digunakan sebagai data latih, dan proses ini diulang sebanyak $N$ kali. Skema ini cocok digunakan untuk dataset dengan jumlah sampel yang kecil karena mampu memaksimalkan penggunaan data untuk pelatihan model [19]. Kelebihan utamanya adalah menghasilkan estimasi yang hampir tidak bias, meskipun membutuhkan biaya komputasi yang lebih tinggi jika jumlah data meningkat. Mekanisme perulangan pada skema evaluasi ini dapat dilihat secara visual pada Gambar 2.3.

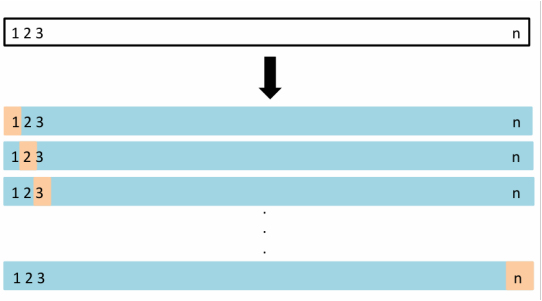


Gambar 2.3 Skema Partisi Data pada LOOCV [25]

Berdasarkan Gambar 2.3, pada setiap baris iterasi, blok berwarna biru merepresentasikan himpunan data latih (*training set*) yang berjumlah $N-1$ sampel. Sementara itu, satu blok kecil berwarna jingga menunjukkan sampel tunggal yang dialokasikan sebagai data uji (*testing set*). Posisi blok jingga ini akan terus bergeser secara berurutan pada setiap iterasi ke bawah, sehingga menjamin bahwa seluruh $N$ sampel tepat satu kali mendapat giliran untuk dievaluasi.

Ketangguhan skema evaluasi LOOCV ini tidak hanya berlaku pada data tabular standar, tetapi juga telah diakui keandalannya dalam studi pemodelan

observasi yang memuat unsur kewilayahan atau spasial, sebagaimana dibuktikan oleh Irisson *et al.* (2022) [26]. Dalam studinya, mereka mengimplementasikan skema *leave-one-out* untuk mengevaluasi model prediktif pada dataset observasi kelautan yang tersebar di berbagai lokasi geografis dengan jumlah sampel yang sangat terbatas. Pendekatan tersebut terbukti secara efektif mampu mencegah *overfitting* dan meminimalkan bias estimasi pada data berskala regional. Karakteristik tantangan spasial tersebut relevan dengan pemodelan pada penelitian ini. Oleh karena itu, penerapan LOOCV pada agregasi data 38 provinsi di Indonesia dinilai sebagai pendekatan yang paling optimal untuk memastikan bahwa setiap unit wilayah mendapatkan kesempatan yang sama untuk diuji secara adil, tanpa khawatir model akan kekurangan proporsi data latih.

Meskipun model telah tervalidasi dengan baik, kompleksitas algoritma *ensemble* sering kali menciptakan hambatan dalam memahami alasan di balik sebuah prediksi, yang dikenal sebagai masalah *black-box*.

### 2.2.13 Interpretabilitas Model

Interpretabilitas model merujuk pada sejauh mana manusia dapat memahami alasan dan proses pengambilan keputusan di balik keluaran sebuah algoritma [27]. Masalah *black-box* sering kali ditemukan pada algoritma kompleks seperti *Random Forest*, di mana hubungan antar variabel sulit dijelaskan secara intuitif. Di bidang kesehatan, interpretasi menjadi aspek yang sangat krusial karena pembuat kebijakan perlu mengetahui variabel apa yang paling memengaruhi suatu kondisi [28]. Penjelasan model dapat dibagi menjadi *global explanation* untuk tren populasi secara menyeluruh dan *local explanation* untuk kasus spesifik. Untuk menjembatani kebutuhan interpretasi pada model kompleks tersebut, metode SHAP menjadi salah satu solusi yang paling banyak digunakan.

### 2.2.14 SHAP *(SHapley Additive exPlanations)*

SHAP (*SHapley Additive exPlanations*) merupakan metode interpretasi model yang didasarkan pada teori permainan kooperatif (*cooperative game theory*) untuk menjelaskan kontribusi setiap fitur terhadap prediksi tertentu [29]. Secara konseptual, metode ini mengibaratkan model prediksi sebagai sebuah ”permainan”, dan variabel-variabel determinan yang digunakan adalah ”pemain” yang bekerja sama. Nilai Shapley kemudian menghitung seberapa besar kontribusi rata-rata atau ”andil” masing-masing variabel terhadap hasil akhir prediksi, dengan mempertimbangkan semua kemungkinan kombinasi fitur yang ada. Pendekatan ini memastikan distribusi atribusi yang adil, sehingga peneliti dapat memahami arah dan kekuatan pengaruh setiap variabel secara intuitif [29].

Keunggulan utama SHAP terletak pada konsistensi teoritisnya serta kemampuannya untuk memberikan visualisasi yang jelas, baik untuk menjelaskan pola secara keseluruhan (global) maupun kasus spesifik per wilayah (lokal). Keandalan SHAP dalam membuka ”kotak hitam” (*black box*) model *machine learning* telah divalidasi secara luas lintas disiplin ilmu. Selain di sektor kesehatan, fleksibilitas metode ini juga telah terbukti tangguh dalam membedah data berdimensi tinggi di bidang lain, seperti analisis risiko pada asuransi medis [30]. Keberhasilan implementasi di berbagai domain kompleks tersebut menegaskan bahwa nilai Shapley merupakan standar yang andal untuk mengukur kontribusi variabel. Melalui penerapan metode ini, hasil prediksi prevalensi *stunting* tidak hanya menjadi sekadar angka, tetapi juga memberikan wawasan presisi mengenai faktor determinan utama di tiap wilayah.

# BAB III
# METODE PENELITIAN

## 3.1 Alur Penelitian

Penelitian ini dirancang untuk menganalisis faktor-faktor determinan penyebab *stunting* pada tingkat provinsi di Indonesia dengan memanfaatkan data sekunder *Annual Report* SSGI tahun 2024. Pendekatan yang digunakan mengombinasikan pemodelan *machine Learning* regresi menggunakan *Random Forest* dan metode interpretasi model SHAP. Model ini dibangun menggunakan dataset agregat tingkat provinsi yang memuat berbagai indikator status gizi balita serta faktor determinan yang mencakup aspek kesehatan ibu dan anak, pola asuh, layanan kesehatan, penyakit, perlindungan sosial, dan kondisi sanitasi. Penelitian ini bertujuan untuk mengidentifikasi faktor determinan utama yang berkontribusi terhadap tingginya prevalensi *stunting* antar provinsi, serta memberikan pemahaman yang bersifat interpretatif sebagai dasar perumusan kebijakan dan intervensi gizi yang lebih tepat sasaran. Secara garis besar, tahapan penelitian digambarkan dalam diagram alir (*flowchart*) pada Gambar 3.1.

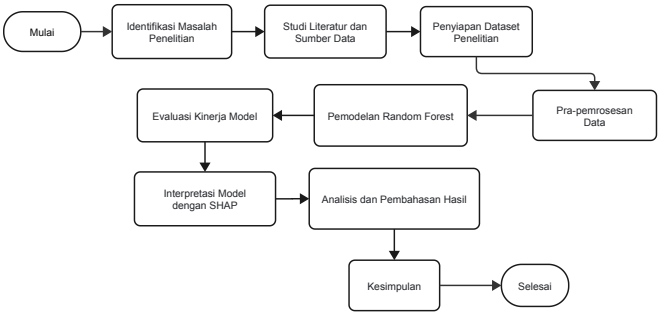


Gambar 3.1 Diagram Alir Penelitian

Berdasarkan Gambar 3.1, alur penelitian disusun secara sistematis yang diawali dengan tahap identifikasi masalah mengenai urgensi penanganan *stunting* di Indonesia dan kompleksitas faktor determinan yang mempengaruhinya di tingkat provinsi. Tahap ini didukung oleh studi literatur mendalam untuk memahami variabel-variabel determinan multidimensi yang mencakup berbagai aspek, serta metode pengolahan data dan pemodelan *machine learning* yang relevan. Berlandaskan pemahaman tersebut, selanjutnya dilakukan pengumpulan dataset yang bersumber dari Laporan Tahunan SSGI tahun 2024. Laporan Tahunan SSGI 2024 kemudian digunakan untuk menyiapkan dataset agregat tingkat provinsi yang memuat variabel target (prevalensi *stunting*) dan variabel fitur (faktor determinan). Data mentah yang diperoleh selanjutnya diproses melalui tahapan pra-pemrosesan data yang meliputi pembersihan data, penyaringan data, dan pemisahan variabel target dan fitur.

Setelah data siap, tahap berikutnya adalah pembangunan model regresi menggunakan algoritma *Random Forest*. Proses ini mencakup penentuan parameter terbaik melalui *Grid Search* dan validasi silang (*Cross Validation*) untuk memastikan performa model yang optimal. Model yang telah dilatih kemudian dievaluasi kinerjanya menggunakan metrik statistik seperti MAE, RMSE, MAPE, serta koefisien determinasi ($R^2$ Score). Langkah terakhir adalah menginterpretasikan hasil prediksi model *Random Forest* menggunakan SHAP untuk mengetahui kontribusi setiap fitur determinan terhadap angka *stunting*, baik secara global skala nasional maupun lokal per provinsi.

## 3.2 Langkah Penelitian

Tahapan penelitian disusun secara sistematis untuk menjawab rumusan masalah yang telah ditetapkan. Secara garis besar, alur penelitian terdiri dari identifikasi masalah, studi literatur, penyiapan data, pra-pemrosesan, pembangunan model, hingga evaluasi dan interpretasi hasil. Penjelasan rinci mengenai masing-masing tahapan diuraikan sebagai berikut.

### 3.2.1 Persiapan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang bersumber dari Laporan Publikasi SSGI tahun 2024 yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia [4]. Laporan ini disajikan dalam bentuk dokumen PDF dan memuat informasi statistik yang komprehensif, mencakup ±5.189 tabel statistik yang menggambarkan indikator kesehatan ibu dan anak, pola asuh, akses pelayanan kesehatan, kondisi sanitasi dan lingkungan, serta karakteristik demografi rumah tangga. Secara spesifik, populasi target dalam survei ini difokuskan pada rumah tangga kelompok balita usia 0-59 bulan, dengan data yang disajikan menggunakan pendekatan *cross-sectional* untuk menggambarkan kondisi kesehatan pada satu titik waktu tertentu. Seluruh informasi statistik tersebut disajikan dalam bentuk numerik atau persentase yang merepresentasikan prevalensi kejadian di wilayah terkait.

Informasi dalam laporan SSGI 2024 disajikan dalam berbagai tingkat agregasi wilayah, mulai dari data nasional, provinsi, hingga rincian kabupaten/kota. Dari berbagai tingkatan tersebut, penelitian ini membatasi unit analisis pada skala provinsi guna menganalisis variabilitas determinan *stunting* antarwilayah secara makro. Namun, kompleksitas struktur data ini menyebabkan data tidak dapat langsung digunakan sebagai *dataset* penelitian kuantitatif tanpa melalui proses penyiapan data terlebih dahulu. Oleh karena itu, diperlukan suatu tahapan penyiapan data untuk mengekstraksi, menyeleksi, dan menyusun kembali informasi yang relevan agar diperoleh *dataset* terstruktur yang sesuai dengan tujuan penelitian. Alur penyiapan data yang dilakukan dalam penelitian ini ditunjukkan pada Gambar 3.2.

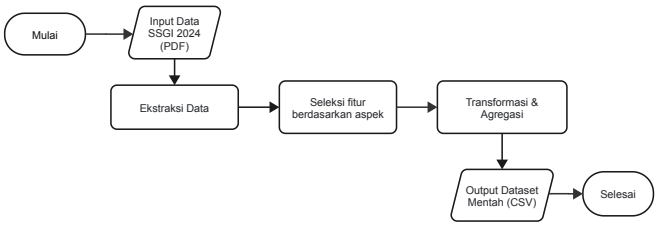


Gambar 3.2 Alur Penyiapan Data

Alur penyiapan data pada Gambar 3.2 menggambarkan tahapan yang dilakukan untuk mengonversi data mentah SSGI 2024 dalam bentuk PDF menjadi *dataset* terstruktur yang siap digunakan pada tahap pra-pemrosesan dan pemodelan. Penjelasan lebih lanjut mengenai masing-masing tahapan penyiapan data diuraikan sebagai berikut:

#### 3.2.1.1 Ekstraksi Data

Tahap pertama difokuskan pada pengumpulan data mentah dari laporan SSGI 2024 yang tersedia dalam bentuk dokumen PDF dengan ribuan tabel statistik yang kompleks. Mengingat data tersebar dalam berbagai sub-bab laporan, dilakukan identifikasi manual terlebih dahulu untuk memetakan nomor halaman tabel yang memuat indikator determinan *stunting* dan prevalensi gizi balita. Informasi dari tabel-tabel tersebut kemudian diekstraksi dan dikonversi dari bentuk dokumen statis menjadi lembar kerja digital (*spreadsheet*) yang lebih fleksibel. Proses ekstraksi data ini tidak dilakukan secara otomatisasi penuh melainkan melalui pendekatan ekstraksi selektif. Tabel-tabel yang memuat variabel determinan *stunting* untuk skala provinsi dipilah secara terpisah dan dikonversi ke dalam format *spreadsheet* menggunakan fitur Power Query pada Microsoft Excel yang memungkinkan penyeleksian dan transformasi tabel dari dokumen statis secara presisi. Karena data asli menggunakan pendekatan *cross-sectional* dengan banyak kategori, proses ekstraksi dilakukan dengan memastikan angka persentase yang diambil sesuai dengan label baris dan kolom

yang benar.

Pada tahap ini juga ditetapkan skala analisis yang digunakan dalam penelitian, yaitu skala provinsi sebagai representasi kondisi nasional. Pemilihan skala provinsi dilakukan dengan mempertimbangkan tujuan penelitian yang berfokus pada pemetaan faktor determinan *stunting* secara makro. Berdasarkan keputusan tersebut, seluruh tabel yang dianalisis dibatasi pada tabel tingkat provinsi yang tersedia dalam laporan SSGI 2024.

#### 3.2.1.2 Seleksi Fitur Determinan

Tahap seleksi fitur dilakukan untuk menentukan variabel determinan *stunting* yang relevan dari 100 tabel tingkat provinsi hasil ekstraksi data SSGI 2024. Proses seleksi ini mempertimbangkan kesesuaian variabel dengan tujuan penelitian, keterwakilan indikator determinan, serta potensi redundansi informasi antar tabel. Variabel yang bersifat terlalu rinci, deskriptif kategori, atau tidak lagi informatif pada tingkat agregasi provinsi dieliminasi dan, apabila memungkinkan, direpresentasikan melalui variabel status atau skor risiko komposit.

Pendekatan seleksi ini diterapkan untuk menyesuaikan karakteristik data dengan tingkat analisis penelitian, yaitu pada level provinsi, sehingga kompleksitas yang tidak diperlukan dapat dikurangi tanpa menghilangkan makna substantif indikator. Berdasarkan proses tersebut, sebanyak 71 tabel dipertahankan dan digunakan sebagai dasar pembentukan fitur penelitian. Hasil seleksi ini menghasilkan *dataset* yang lebih ringkas, informatif, dan relevan dalam mengidentifikasi faktor-faktor determinan *stunting* antarprovinsi.

#### 3.2.1.3 Transformasi dan Agregasi Data

Setelah melalui proses seleksi tabel, langkah selanjutnya adalah transformasi data untuk memastikan setiap variabel yang terbentuk memiliki representasi informasi yang kuat terhadap risiko *stunting*. Pada tahap ini, tidak semua informasi dari tabel mentah digunakan secara langsung; sebaliknya,

dilakukan peninjauan ulang untuk menetapkan satu indikator yang paling representatif dari setiap tabel. Untuk tabel yang hanya memuat indikator tunggal, nilai persentase diadopsi langsung sebagai fitur numerik. Namun, pada tabel yang memiliki kategori majemuk, dilakukan strategi transformasi khusus dengan memilih indikator yang mencerminkan risiko tertinggi atau melakukan penggabungan kategori agar menghasilkan variabel baru yang lebih ringkas dan substantif.

Selanjutnya, proses agregasi dilakukan untuk menyederhanakan struktur data sehingga seluruh variabel memiliki skala yang seragam dan mudah dibandingkan antar provinsi. Pada tabel yang memiliki lebih dari satu kategori indikator, proses agregasi dilakukan melalui pendekatan penggabungan indikator berbasis risiko. Sebagai contoh, pada tabel usia kehamilan ibu yang terdiri dari kategori usia <21 tahun, 21–39 tahun, dan >40 tahun, hanya kategori yang merepresentasikan kondisi berisiko yang dipertahankan. Nilai persentase ibu dengan usia kehamilan <20 tahun dan >35 tahun dijumlahkan untuk membentuk satu variabel baru yang merepresentasikan proporsi kehamilan berisiko pada usia ekstrem. Secara matematis, proses ini dapat dinyatakan sebagai berikut:

$$X_{\text{risiko usia kehamilan}} = X_{<20} + X_{>35}$$

Di mana $X_{<20}$ adalah persentase kehamilan usia di bawah 20 tahun dan $X_{>35}$ adalah persentase kehamilan usia di atas 35 tahun. Pendekatan serupa diterapkan pada tabel lain yang memiliki kategori majemuk, dengan prinsip utama mempertahankan indikator yang memiliki relevansi risiko terhadap kejadian *stunting* serta menghindari redundansi informasi antarvariabel. Seluruh variabel direpresentasikan dalam bentuk persentase guna menjaga konsistensi satuan data dan memudahkan proses pemodelan. Hasil dari tahap ini adalah *dataset* terstruktur berbasis provinsi yang siap digunakan sebagai input pada tahapan analisis selanjutnya.

### 3.2.2 Pra-pemrosesan Data

Setelah proses penyiapan dan pembentukan *dataset* terstruktur selesai dilakukan, tahap selanjutnya adalah pra-pemrosesan data. Tahapan ini bertujuan untuk memastikan bahwa data yang digunakan sebagai input model memiliki kualitas yang baik, konsisten, dan layak secara statistik sebelum masuk ke proses pemodelan *machine learning*. Mengingat *dataset* disusun dari hasil ekstraksi dan transformasi data sekunder, terdapat potensi munculnya permasalahan seperti nilai kosong atau ketidakkonsistenan format.

Alur pra-pemrosesan data ditunjukkan pada Gambar 3.3. Proses ini diawali dengan pemuatan *dataset* ke dalam lingkungan komputasi serta pemeriksaan struktur dan konsistensi data. Selanjutnya dilakukan *Exploratory Data Analysis* (EDA) untuk memperoleh gambaran umum karakteristik data. Tahap akhir pra-pemrosesan mencakup eliminasi variabel non-determinan serta penetapan prevalensi *stunting* sebagai variabel target ($y$) dan indikator determinan sebagai variabel prediktor ($X$).

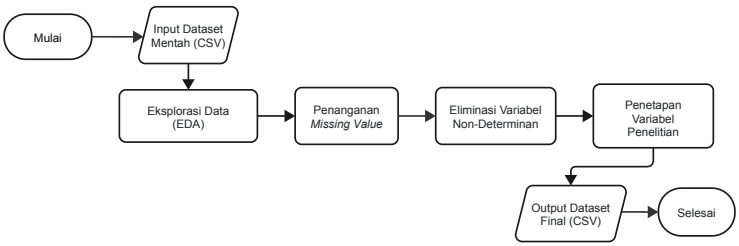


Gambar 3.3 Alur Pra-pemrosesan Data

#### 3.2.2.1 Representasi Dataset Penelitian

Dataset yang digunakan dalam penelitian ini bersumber dari Laporan Publikasi SSGI tahun 2024 yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia [4]. Data tersebut merupakan data sekunder berskala nasional yang menyajikan berbagai indikator status gizi, kesehatan ibu dan anak,

serta kondisi lingkungan dan sosial ekonomi pada tingkat provinsi. Setelah melalui tahap penyiapan dan seleksi data, diperoleh satu dataset terstruktur yang terdiri dari 56 variabel independen dan satu variabel dependen berupa prevalensi *stunting*. Untuk memudahkan pemahaman struktur data dan menjaga konsistensi analisis determinan, seluruh variabel independen kemudian dikelompokkan ke dalam beberapa kategori tematik berdasarkan karakteristik indikator yang diwakilinya.

Tabel 3.1 Distribusi Variabel Determinan Stunting berdasarkan Kategori

| No | Kategori Variabel | Jumlah Fitur |
|---|---|---|
| 1 | Riwayat Kehamilan dan Kelahiran | 15 |
| 2 | Riwayat Pemberian ASI dan MP-ASI | 17 |
| 3 | Akses dan Pemanfaatan Pelayanan Kesehatan | 9 |
| 4 | Imunisasi dan Morbiditas Balita | 8 |
| 5 | Kepemilikan dan Pemanfaatan Jaminan Kesehatan | 2 |
| 6 | Pendampingan Keluarga dan Pengetahuan Stunting | 4 |
| 7 | Kontrasepsi Pasca Bersalin | 1 |
| 8 | Bantuan Sosial | 1 |
| 9 | Akses Air Minum dan Sanitasi | 4 |
| **Total** | | **56** |

Tabel 3.1 menunjukkan bahwa variabel determinan yang digunakan dalam penelitian ini didominasi oleh indikator terkait riwayat kehamilan, pola pemberian makan bayi dan anak, serta akses pelayanan kesehatan. Komposisi ini mencerminkan pendekatan multidimensi dalam menganalisis *stunting*, di mana faktor biologis, perilaku, layanan kesehatan, serta kondisi lingkungan dianalisis secara simultan. Pengelompokan ini juga menjadi dasar dalam interpretasi model, khususnya pada tahap analisis kontribusi fitur menggunakan SHAP.

### 3.2.3 Pemodelan *Random Forest*

Setelah melalui tahapan penyiapan dan pra-pemrosesan data, *dataset* yang telah bersih dan terstruktur selanjutnya digunakan pada tahap pemodelan. Pada penelitian ini, pendekatan yang digunakan adalah *Random Forest Regression* untuk memodelkan hubungan antara variabel determinan *stunting* dan nilai

prevalensi *stunting* pada tingkat provinsi yang memiliki nilai numerik kontinu. Pemilihan metode ini didasarkan pada kemampuannya dalam menangani data dengan jumlah fitur yang relatif banyak serta hubungan non-linier antarvariabel tanpa asumsi distribusi data yang ketat [23]. Alur proses pemodelan disajikan secara ringkas pada Gambar 3.4.

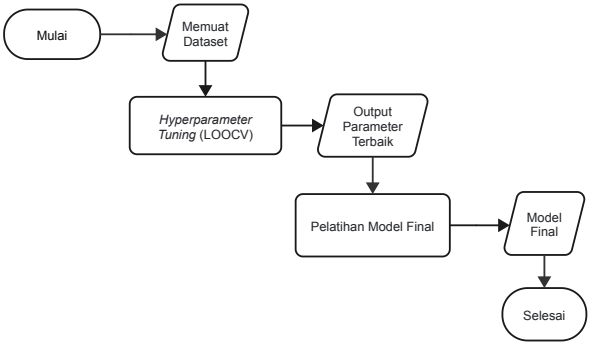


Gambar 3.4 Alur Pembangunan Model *Random Forest Regression*

#### 3.2.3.1 *Hyperparameter Tuning* Berbasis *Cross Validation*

Tahap awal pembangunan model difokuskan pada pencarian konfigurasi model yang paling optimal melalui strategi validasi yang ketat. Mengingat keterbatasan jumlah sampel data yang hanya tersedia pada tingkat provinsi, penelitian ini menerapkan metode *Leave-One-Out Cross Validation* (LOOCV) sebagai pengganti pembagian data latih-uji konvensional [31]. Dalam skema ini, proses pelatihan dilakukan secara iteratif sebanyak jumlah sampel, di mana pada setiap iterasi, satu provinsi digunakan sebagai data uji sementara provinsi sisanya menjadi data latih. Pendekatan ini dipilih untuk memaksimalkan pemanfaatan informasi dari data yang terbatas serta menghasilkan estimasi performa model yang tidak bias terhadap pemilihan acak data uji tertentu.

Bersamaan dengan proses validasi LOOCV, dilakukan optimasi kinerja model melalui mekanisme *Hyperparameter Tuning* menggunakan metode *Grid*

*SearchCV*. Tahap ini bertujuan untuk mencari kombinasi parameter terbaik dari algoritma Random Forest, meliputi jumlah pohon keputusan (`n_estimators`), batas kedalaman maksimal pohon (`max_depth`), jumlah sampel minimum pada simpul daun (`min_samples_leaf`), serta jumlah fitur maksimal yang dipertimbangkan pada setiap pemecahan simpul (`max_features`), guna menghasilkan model dengan tingkat kesalahan prediksi terendah. Eksplorasi ruang parameter ini dinilai krusial untuk mencegah terjadinya *overfitting*[1] yang sering menjadi kendala pada dataset berskala kecil [32]. Kombinasi parameter yang menghasilkan nilai rata-rata *Root Mean Squared Error* (RMSE) terendah selama proses validasi silang kemudian ditetapkan sebagai konfigurasi model optimal.

#### 3.2.3.2 Pelatihan Model Final

Setelah parameter optimal diperoleh dari tahap validasi, langkah selanjutnya adalah pembangunan model final (*final model fitting*). Pada tahap ini, model *Random Forest* dilatih ulang menggunakan keseluruhan *dataset* provinsi yang tersedia dengan menerapkan parameter terbaik hasil optimasi sebelumnya. Tujuannya adalah untuk menangkap pola data secara utuh tanpa menyisakan data untuk pengujian, karena evaluasi performa telah diselesaikan pada tahap validasi silang. Model terbaik ini kemudian digunakan untuk memetakan hubungan non-linier yang kompleks antara seluruh variabel determinan dengan prevalensi *stunting*.

Selain menghasilkan prediksi angka prevalensi, model final ini memiliki fungsi krusial untuk mengekstraksi nilai kepentingan fitur (*feature importance*). Nilai ini mengkuantifikasi kontribusi relatif setiap indikator determinan terhadap hasil prediksi model secara global. Informasi mengenai bobot kontribusi fitur inilah yang nantinya menjadi landasan utama dalam analisis prioritas intervensi

[1] *Overfitting* merupakan kondisi saat model terlalu mempelajari *noise* data latih sehingga kehilangan kemampuan generalisasi pada data baru.

penanganan *stunting* pada tahap interpretasi hasil menggunakan metode SHAP.

### 3.2.4 Evaluasi Performa Model

Evaluasi performa model dilakukan untuk mengukur sejauh mana model *Random Forest Regression* mampu memprediksi prevalensi *stunting* secara akurat pada tingkat provinsi. Mengingat penelitian ini bersifat regresi, digunakan beberapa metrik evaluasi berbasis kesalahan prediksi dan kekuatan penjelasan model. Penggunaan lebih dari satu metrik bertujuan untuk memberikan gambaran performa model secara komprehensif, baik dari sisi rata-rata kesalahan absolut, sensitivitas terhadap kesalahan besar, maupun kemampuan model dalam menjelaskan variasi data target. Seluruh metrik dievaluasi pada skema validasi silang yang telah ditetapkan pada tahap pemodelan.

1. ***Mean Absolute Error* (MAE)**

   MAE digunakan untuk mengukur rata-rata selisih absolut antara nilai prevalensi *stunting* hasil prediksi model dengan nilai aktual pada masing-masing provinsi. Metrik ini memberikan gambaran kesalahan prediksi secara langsung dalam satuan persentase, sehingga memudahkan interpretasi seberapa jauh hasil prediksi model menyimpang dari data SSGI 2024 yang sebenarnya.

2. ***Root Mean Squared Error* (RMSE)**

   RMSE digunakan sebagai indikator utama akurasi model karena mengembalikan nilai kesalahan ke dalam skala yang sama dengan prevalensi *stunting*. Dalam konteks penelitian ini, RMSE membantu menilai seberapa besar deviasi prediksi model terhadap nilai aktual *stunting* antarprovinsi secara keseluruhan.

3. ***R-squared* ($R^2$)**

   Koefisien determinasi $R^2$ digunakan untuk mengukur sejauh mana variasi prevalensi *stunting* antarprovinsi dapat dijelaskan oleh variabel determinan yang dimasukkan ke dalam model. Metrik ini memberikan gambaran

kemampuan model dalam menangkap hubungan kompleks antara faktor kesehatan ibu, balita, dan lingkungan dengan tingkat *stunting*.

4. ***Mean Absolute Percentage Error* (MAPE)**

   MAPE digunakan untuk mengukur kesalahan prediksi dalam bentuk persentase relatif terhadap nilai aktual prevalensi *stunting*. Metrik ini membantu melihat konsistensi performa model antarprovinsi, terutama ketika terdapat perbedaan tingkat *stunting* yang cukup besar antara satu wilayah dan wilayah lainnya.

## 3.3 Interpretasi Hasil dengan SHAP

Interpretasi keputusan model *Random Forest* yang bersifat *black-box* dilakukan menggunakan metode SHAP guna mengidentifikasi besaran pengaruh faktor determinan secara transparan. Analisis mencakup tinjauan global skala nasional dan tinjauan lokal spesifik per provinsi. Alur kerja analisis interpretabilitas model ini diilustrasikan pada Gambar 3.5.

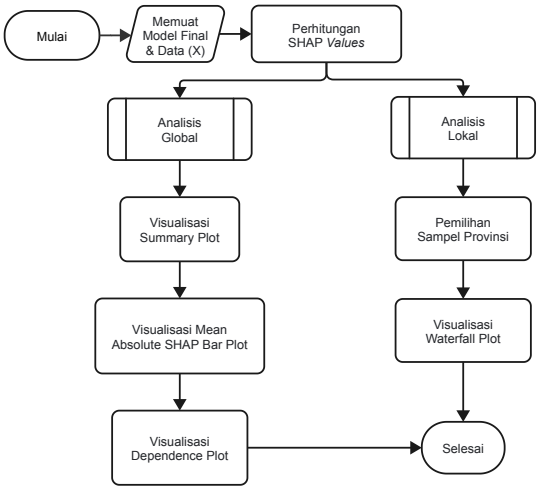


Gambar 3.5 Alur Interpretasi Model dengan SHAP

### 3.3.1 Interpretasi Global

Interpretasi global bertujuan untuk memberikan gambaran menyeluruh mengenai faktor-faktor yang paling dominan mempengaruhi prevalensi *stunting* di tingkat nasional. Analisis ini menggabungkan nilai SHAP mutlak dari seluruh sampel data untuk mengidentifikasi hirarki kepentingan fitur serta pola hubungan umum antara determinan dan kejadian *stunting*. Dalam penelitian ini, interpretasi global diuraikan melalui dua komponen visualisasi utama:

1. ***Feature Importance Plot***

   Visualisasi berbentuk diagram batang ini mengurutkan variabel determinan berdasarkan rata-rata nilai absolut SHAP. Perhitungan tersebut dinyatakan secara matematis melalui rumus $\frac{1}{n}\sum_{i=1}^{n}|\phi_i^{(j)}|$. Grafik ini berfungsi untuk melihat tingkat kepentingan setiap fitur terhadap keluaran model secara keseluruhan. Pengurutan posisi fitur dilakukan tanpa memandang arah pengaruh variabel tersebut, baik yang bernilai positif maupun negatif. Variabel yang berada di posisi paling atas merupakan indikator dengan dampak paling besar terhadap hasil tebakan algoritma.

2. ***Summary Plot (Beeswarm)***

   Visualisasi ini merupakan bentuk distribusi nilai SHAP yang menyajikan arah pengaruh setiap variabel terhadap hasil prediksi. Grafik beeswarm menggunakan gradasi warna untuk membedakan besaran nilai asli dari sebuah observasi. Titik berwarna merah merepresentasikan nilai fitur yang tinggi, sedangkan titik biru merepresentasikan nilai fitur yang rendah. Posisi titik di sebelah kanan sumbu nol menandakan adanya dorongan peningkatan pada prediksi prevalensi *stunting*. Sebaliknya, sebaran titik di sebelah kiri sumbu nol menunjukkan bahwa variabel tersebut membantu menurunkan angka tebakan *stunting*.

3. ***Dependence Plot***

   Visualisasi ini berbentuk grafik pencar (*scatter plot*) yang bertugas

membedah pola pengaruh dari satu variabel spesifik secara lebih rinci. Sumbu mendatar pada grafik ini menampilkan angka asli dari fitur yang sedang dianalisis. Sementara itu, sumbu vertikal menunjukkan besaran nilai SHAP yang dihasilkan oleh perubahan angka pada fitur tersebut. Visualisasi ini berguna untuk melihat ambang batas (*threshold*) di mana sebuah indikator mulai merubah keputusan model secara drastis. Melalui grafik ini, peneliti dapat mengamati bentuk hubungan sebab-akibat secara langsung antara variabel masukan dan target keluaran.

### 3.3.2 Interpretasi Lokal

Interpretasi lokal dilakukan untuk memahami mekanisme prediksi model *Random Forest* pada tingkat wilayah spesifik, yaitu provinsi. Berbeda dengan interpretasi global yang menyoroti pola umum secara nasional, pendekatan ini berfokus pada kontribusi variabel determinan terhadap prediksi prevalensi *stunting* pada masing-masing provinsi. Analisis ini penting karena faktor dominan penyebab *stunting* dapat bervariasi antarwilayah meskipun memiliki tingkat prevalensi yang relatif serupa. Alur interpretasi lokal menggunakan metode SHAP dalam penelitian ini ditunjukkan pada Gambar 3.5.

#### 3.3.2.1 Pemilihan Sampel Provinsi

Mengingat interpretasi lokal bersifat mendalam dan kontekstual, tidak seluruh provinsi dianalisis secara individual. Oleh karena itu, dilakukan pemilihan sampel provinsi yang bertujuan untuk merepresentasikan variasi kondisi *stunting* di Indonesia. Pemilihan sampel didasarkan pada distribusi nilai prevalensi *stunting* hasil prediksi model, sehingga mencakup provinsi dengan tingkat prevalensi relatif tinggi, rendah, serta kondisi menengah. Hal ini didasarkan pada distribusi nilai prevalensi *stunting* hasil prediksi model, yakni dengan memilih secara spesifik provinsi yang memiliki tingkat prevalensi tertinggi (mewakili nilai maksimum), tingkat prevalensi terendah (mewakili

nilai minimum), serta tingkat prevalensi menengah (mewakili nilai median). Pendekatan ini memungkinkan analisis yang lebih terfokus tanpa mengurangi representativitas karakteristik wilayah secara nasional.

#### 3.3.2.2 Visualisasi dan Analisis *Waterfall Plot*

Setelah sampel provinsi ditetapkan, interpretasi lokal dilakukan menggunakan visualisasi *Waterfall Plot*. Visualisasi ini menampilkan bagaimana nilai prediksi suatu provinsi terbentuk secara bertahap mulai dari nilai dasar (*base value*) hingga mencapai nilai prediksi akhir. Nilai dasar tersebut merepresentasikan rata-rata prediksi model pada seluruh data, kemudian setiap variabel determinan ditambahkan atau dikurangkan secara berurutan sesuai besar kontribusinya terhadap prediksi provinsi tersebut. Dengan demikian, grafik ini memperlihatkan proses pembentukan prediksi sebagai akumulasi kontribusi dari masing-masing variabel.

Secara visual, *Waterfall Plot* menyerupai diagram batang bertingkat yang bergerak naik atau turun dari satu titik awal menuju nilai akhir. Batang yang mengarah ke atas menunjukkan variabel yang meningkatkan nilai prediksi prevalensi stunting, sedangkan batang yang mengarah ke bawah menunjukkan variabel yang menurunkan nilai tersebut. Panjang setiap batang menggambarkan besar kecilnya pengaruh variabel terhadap hasil prediksi. Melalui penyajian ini, pembaca dapat secara langsung melihat faktor mana yang paling dominan membentuk nilai prediksi pada suatu provinsi, sehingga keputusan model tidak lagi terlihat sebagai proses yang tertutup atau sulit dipahami.

## 3.4 Lingkungan Pengembangan Model

Proses pembangunan model dan pengolahan data dilakukan dalam lingkungan bahasa pemrograman `Python` versi 3.10. Untuk menjaga reproduksibilitas penelitian, berikut adalah daftar pustaka (*library*) utama beserta versinya dan peran spesifiknya dalam sistem:

1. `scikit-learn` (v1.7.2), digunakan untuk implementasi algoritma *Random Forest*, pembagian data *Leave-One-Out Cross-Validation*, serta optimasi *hyperparameter*.
2. `shap` (v0.49.1), digunakan sebagai instrumen interpretasi model untuk menghitung nilai kontribusi tiap fitur melalui pendekatan *Shapley values*.
3. `pandas` (v2.3.2), digunakan untuk manipulasi struktur data, khususnya dalam proses agregasi dari data individu ke tingkat provinsi.
4. `numpy` (v2.3.3), mendukung operasi komputasi matriks dan pemrosesan *array* numerik yang efisien.
5. `matplotlib` (v3.10.6) & `seaborn` (v0.13.2), digunakan untuk memvisualisasikan distribusi variabel dan hasil interpretasi fitur secara grafis.
6. `scipy` (v1.16.2), digunakan untuk pengolahan statistik tingkat lanjut yang diperlukan dalam pembersihan data.

## 3.5 Ilustrasi Perhitungan Metode

Bagian ini menyajikan simulasi pemrosesan data SSGI 2024 oleh model untuk menghasilkan prediksi prevalensi *stunting*. Angka yang digunakan di sini adalah data hipotetis untuk menggambarkan alur kalkulasi dari *input* fitur hingga evaluasi akhir.

### 3.5.1 Prediksi *Random Forest Regression*

Dalam penelitian ini, prediksi prevalensi *stunting* untuk satu provinsi tidak ditentukan oleh satu pohon keputusan tunggal, melainkan melalui konsensus dari banyak pohon (*ensemble*). Setiap pohon dalam model akan memberikan estimasi angka prevalensi berdasarkan fitur *input* yang dipelajarinya.

Berikut adalah ilustrasi jika model terdiri dari 3 pohon keputusan, di mana masing-masing pohon memberikan estimasi angka *stunting* sebagai berikut:

Tabel 3.2 Data Hipotetis Output Pohon Keputusan

| **Pohon Keputusan** | ***Output* Prediksi ($h_i$)** |
|---|---|
| *Tree* 1 | 18.5 |
| *Tree* 2 | 17.9 |
| *Tree* 3 | 18.2 |

Nilai prediksi akhir ($\hat{y}$) untuk provinsi tersebut diperoleh dengan merata-ratakan seluruh *output* pohon menggunakan persamaan berikut:

$$\hat{y} = \frac{18.5 + 17.9 + 18.2}{3}$$

$$\hat{y} = \frac{54.6}{3}$$

$$\hat{y} = \mathbf{18.2}$$

Angka **18.2%** inilah yang menjadi prediksi final prevalensi *stunting* untuk provinsi tersebut.

### 3.5.2 Perhitungan *Error* Prediksi

Validasi akurasi dilakukan dengan membandingkan angka prediksi model terhadap data aktual SSGI. Selisih absolut antara kedua nilai ini menunjukkan seberapa jauh deviasi estimasi model untuk satu provinsi.

Misalkan data aktual dan hasil prediksi untuk sampel provinsi tersebut adalah:

Tabel 3.3 Data Hipotetis Aktual vs Prediksi

| **Data** | **Nilai (%)** |
|---|---|
| Aktual ($y$) | 20.0 |
| Prediksi ($\hat{y}$) | 18.2 |

Perhitungan deviasi atau *error* individu ($e$) adalah:

$$e = |y - \hat{y}|$$

Penyelesaian:

$$e = |20.0 - 18.2|$$

$$e = \mathbf{1.8}$$

Hasil ini menunjukkan bahwa prediksi model meleset sebesar **1.8 poin persentase** dari angka *stunting* yang sebenarnya.

### 3.5.3 Perhitungan Metrik Evaluasi

Untuk mengukur performa model secara menyeluruh terhadap seluruh provinsi di Indonesia, digunakan perhitungan agregat. Berikut adalah ilustrasi perhitungan menggunakan sampel data dari 3 provinsi (A, B, dan C).

Tabel 3.4 Data Hipotetis untuk Evaluasi Agregat

| **Sampel** | **Aktual** ($y$) | **Prediksi** ($\hat{y}$) | **Selisih** ($\|e\|$) | **Kuadrat** ($e^2$) |
|---|---|---|---|---|
| A | 20 | 18 | 2 | 4 |
| B | 15 | 16 | 1 | 1 |
| C | 25 | 23 | 2 | 4 |

**1. MAE**

*Mean Absolute Error* (MAE) dihitung untuk mengetahui rata-rata penyimpangan absolut prediksi *stunting* dalam satuan persen.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i|$$

Penyelesaian:

$$\text{MAE} = \frac{2 + 1 + 2}{3} = \mathbf{1.67}$$

Model memiliki rata-rata kesalahan prediksi sebesar **1.67 poin**.

**3. RMSE**

*Root Mean Squared Error* (RMSE) mengembalikan nilai kesalahan ke satuan asli (persentase) untuk menggambarkan standar deviasi dari residu prediksi model terhadap data SSGI.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Penyelesaian:

$$\text{RMSE} = \sqrt{\frac{4+1+4}{3}}$$

$$\text{RMSE} = \sqrt{3.00} \approx \mathbf{1.73}$$

Deviasi standar kesalahan model berada pada angka **1.73 poin**.

**4. MAPE**

*Mean Absolute Percentage Error* (MAPE) digunakan untuk melihat rasio kesalahan model relatif terhadap besaran angka *stunting* aktual di masing-masing provinsi.

$$\text{MAPE} = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Penyelesaian:

$$\text{MAPE} = \frac{100\%}{3}(0.10 + 0.067 + 0.08)$$

$$= \mathbf{8.22}\%$$

Rata-rata kesalahan model adalah sebesar **8.22%** dari nilai aktual.

## 3.6 Ilustrasi Rancangan Pengujian

Bagian ini menjabarkan skenario eksperimen yang dilakukan untuk melatih dan memvalidasi model. Mengingat jumlah observasi yang terbatas yaitu provinsi di Indonesia, strategi pembagian data dan pemilihan parameter menjadi krusial untuk mencegah *overfitting* dan memastikan hasil evaluasi yang objektif.

### 3.6.1 Skema *Leave-One-Out Cross Validation* (LOOCV)

Penelitian ini menerapkan metode *Leave-One-Out Cross Validation* (LOOCV) untuk memaksimalkan penggunaan data. Dalam skema ini, evaluasi dilakukan melalui $N$ kali iterasi, di mana pada setiap iterasi, satu provinsi disisihkan sebagai data uji (*testing set*) sementara sisa provinsi lainnya digunakan sebagai data latih (*training set*).

Berikut adalah ilustrasi pembagian data pada setiap iterasi pengujian:

Tabel 3.5 Ilustrasi Skema Pembagian Data LOOCV

| **Iterasi** | **Data Latih (N-1 Provinsi)** | **Data Uji (1 Provinsi)** |
|---|---|---|
| 1 | Prov 2, 3, ..., N | **Provinsi 1** |
| 2 | Prov 1, 3, ..., N | **Provinsi 2** |
| ... | ... | ... |
| N | Prov 1, 2, ..., N | **Provinsi N** |

Dengan mekanisme ini, model diuji pada setiap provinsi tepat satu kali tanpa bias pemilihan data, dan performa akhir dihitung dari rata-rata *error* seluruh iterasi.

### 3.6.2 *Hyperparameter Tuning*

Untuk mendapatkan konfigurasi model yang paling optimal dalam memprediksi *stunting*, dilakukan pencarian parameter terbaik menggunakan teknik *Grid Search*. Berbagai kombinasi parameter seperti jumlah pohon dan kedalaman pohon diuji performanya menggunakan skema LOOCV di atas.

Tabel berikut mengilustrasikan simulasi hasil pencarian parameter, di mana keputusan pemilihan didasarkan pada nilai rata-rata RMSE terendah.

Tabel 3.6 Data Hipotetis Hasil Tuning Parameter

| No | *n_estimators* | *max_depth* | RMSE | Keputusan |
|---|---|---|---|---|
| 1 | 100 | 5 | 2.10 | - |
| **2** | **200** | **5** | **1.85** | **Dipilih (Terbaik)** |
| 3 | 200 | 10 | 1.92 | - |

Berdasarkan ilustrasi Tabel 3.6, kombinasi nomor 2 dipilih karena menghasilkan tingkat kesalahan prediksi yang paling minim.

### 3.6.3 Pemilihan Model Final

Tahap terakhir adalah pembentukan model final untuk kebutuhan interpretasi fitur. Setelah parameter terbaik ditemukan (misal: *n_estimators*=200 dan *max_depth*=5), model tersebut tidak lagi dipisahkan antara data latih dan uji.

Sebagai langkah akhir, model dilatih ulang (*retraining*) menggunakan seluruh *dataset* penuh. Model yang telah mempelajari pola dari seluruh data provinsi inilah yang nantinya digunakan untuk analisis determinan penyebab *stunting* menggunakan metode SHAP pada Bab IV.

# BAB IV
# HASIL DAN PEMBAHASAN

## 4.1 Hasil Penelitian

Berisi hasil penelitian berdasarkan rancangan yang sudah dijelaskan pada Bab III, terutama dari Subbab **??**. Bagi yang membuat alat, jelaskan alat yang jadi dalam bentuk apa. Bagi yang membuat aplikasi, jelaskan aplikasi yang jadi dalam bentuk seperti apa. Jabarkan dalam bentuk pseudocode dan dijelaskan per bagian kodenya. Gunakan gambar dan tabel sebagai alat bantu menjelaskan hasil.

Contoh implementasi kode dapat ditulis menggunakan `\begin{lstlisting}`. Contoh kode dapat dilihat pada Kode 4.1.

Kode 4.1 Akuisisi Gambar

```
def process_dataset(dataset_path):
        image_files = glob(os.path.join(dataset_path, '*.png'))
        image_files.sort()
        for image_file in image_files:
                frame = cv2.imread(image_file)
                if frame is None:
                        continue
                frame_rgb = cv2.cvtColor(frame, cv2.COLOR_BGR2RGB)
                cv2.imshow('Frame', frame)
                if cv2.waitKey(1) & 0xFF == ord('q'):
                        break
        cv2.destroyAllWindows()
def main():
        datasets = get_all_dataset_folders(DATASET_ROOT)
        for dataset in datasets:
                process_dataset(dataset)
                print("print string")
```

## 4.2 Hasil Pengujian

Berikan hasil pengujian berdasarkan rancangan & skenario yang sudah direncanakan sebelumnya pada Subbab **??**.

Tabel 4.1 Data *dummy* Pengujian

| **Subjek** | **Hasil Prediksi (BPM)** | | | | | | | **GT** |
|---|---|---|---|---|---|---|---|---|
| | **F** | **NA** | **NO** | **RC** | **LC** | **M** | **C** | |
| 1 | 68 | 69 | 68 | 70 | 68 | 71 | 69 | 68 |
| 2 | 69 | 69 | 68 | 70 | 68 | 71 | 69 | 69 |
| 3 | 70 | 70 | 69 | 71 | 68 | 73 | 69 | 70 |
| 4 | 71 | 70 | 70 | 72 | 69 | 73 | 70 | 71 |
| 5 | 72 | 72 | 70 | 72 | 70 | 74 | 70 | 72 |

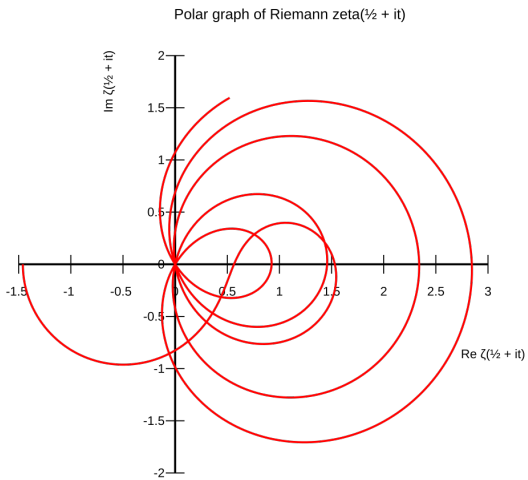


Gambar 4.1 Contoh Graf Pengujian

## 4.3 Analisis Hasil Penelitian

Berikan analisis hasil penelitian & pengujian, berupa data yang didapatkan dari penelitian & pengujian Tugas Akhir yang sudah anda kerjakan. Gunakan gambar dan tabel sebagai alat bantu menjelaskan analisis hasil. Data luaran penelitian yang dapat dianalisis berupa:

1. Hasil pengujian

2. Hasil kuesioner
3. Aplikasi yang dikembangkan

Analisis dapat membandingkan dengan hasil penelitian sebelumnya yang memiliki kemiripan topik.

# BAB V
# HASIL DAN PEMBAHASAN

## 5.1 Hasil Penelitian

Bagian ini menyajikan hasil penelitian yang diperoleh dari seluruh tahapan yang telah dilakukan. Proses penelitian meliputi ekstraksi dan analisis data Survei Status Gizi Indonesia (SSGI) tahun 2024 pada tingkat provinsi, dilanjutkan dengan tahap pra-pemrosesan data hingga pembangunan model prediktif. Model yang digunakan dalam penelitian ini adalah *Random Forest* untuk memprediksi prevalensi *stunting*, yang kemudian dikombinasikan dengan metode *SHAP* (*SHapley Additive exPlanations*) untuk menjelaskan kontribusi masing-masing variabel. Seluruh proses pemodelan dilakukan menggunakan skema validasi *Leave-One-Out Cross-Validation* (LOOCV) serta optimasi parameter melalui *GridSearchCV* guna memperoleh kinerja model yang optimal.

### 5.1.1 Analisis Deskriptif

Penelitian ini menggunakan data sekunder yang berasal dari laporan resmi Survei Status Gizi Indonesia (SSGI) tahun 2024 yang dipublikasikan oleh Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan RI. Data pada bentuk aslinya berupa rekapitulasi persentase berbagai indikator kesehatan, gizi, dan sosiodemografi yang tersebar dalam beberapa bagian laporan. Karena penelitian ini menggunakan pendekatan *machine learning* berbasis data tabular, format tersebut tidak dapat langsung digunakan sehingga diperlukan proses ekstraksi dan penyusunan ulang data. Proses ekstraksi dilakukan dengan memilih indikator yang relevan dan menyusunnya ke dalam bentuk tabel dengan baris dan kolom yang terstruktur. Hasilnya, data dibagi menjadi satu variabel target yaitu prevalensi *stunting* serta sejumlah variabel prediktor yang mencerminkan faktor-faktor seperti sanitasi, pola asuh, dan pendidikan ibu.

Dataset akhir yang digunakan dalam penelitian ini terdiri dari 38 baris yang mewakili seluruh provinsi di Indonesia. Setiap baris memuat nilai persentase dari variabel target dan variabel prediktor yang telah disusun dalam format yang seragam. Penyusunan ini bertujuan agar data dapat langsung digunakan dalam proses analisis menggunakan algoritma *machine learning*. Selain itu, format tabular ini memudahkan dalam melakukan tahap pra-pemrosesan dan seleksi fitur sebelum model dibangun. Dataset tersebut kemudian menjadi dasar utama dalam proses pelatihan dan evaluasi model yang dilakukan dalam penelitian ini.

### 5.1.2 Persiapan Data

Laporan Survei Status Gizi Indonesia (SSGI) tahun 2024 disajikan dalam bentuk dokumen *Portable Document Format* (PDF) yang memuat sekitar 5.189 tabel statistik yang berisi berbagai indikator kesehatan, gizi, serta kondisi sosial dan lingkungan. Data dalam laporan tersebut mencakup informasi terkait kesehatan ibu dan anak, pola asuh, akses layanan kesehatan, sanitasi, serta karakteristik demografi rumah tangga dengan fokus pada balita usia 0–59 bulan menggunakan pendekatan *cross-sectional*. Meskipun data tersedia pada beberapa tingkat wilayah seperti nasional, provinsi, dan kabupaten/kota, penelitian ini hanya menggunakan tingkat provinsi sebagai unit analisis untuk melihat perbedaan determinan *stunting* secara umum. Struktur data dalam bentuk laporan ini belum dapat langsung digunakan untuk pemodelan *machine learning*, sehingga diperlukan proses pengolahan lebih lanjut. Oleh karena itu, kondisi awal dan karakteristik data sebelum dilakukan ekstraksi disajikan pada Tabel 5.1.

Tabel 5.1 Kondisi Awal Dataset SSGI 2024

| No | Atribut | Keterangan Kondisi Awal |
|---|---|---|
| 1 | Sumber / Penerbit Data | Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan RI |
| 2 | Format File | Dokumen Laporan *Portable Document Format* (PDF) |
| 3 | Volume Data | ± 5.189 tabel statistik |
| 4 | Variabel Target (*Label*) | Angka prevalensi balita *stunted* (pendek) berdasarkan indeks Tinggi Badan menurut Umur (TB/U) |
| 5 | Cakupan Indikator (*Fitur*) | Kesehatan ibu dan anak, pola asuh, akses kesehatan, sanitasi, dan sosiodemografi |
| 6 | Populasi Target | Rumah tangga kelompok balita usia 0-59 bulan |
| 7 | Tingkat Agregasi Wilayah | Nasional, Provinsi (38 Provinsi), dan Kabupaten/Kota |
| 8 | Pendekatan Pengambilan | *Cross-sectional* (Satu titik waktu tertentu) |
| 9 | Format Nilai Data | Numerik dan Persentase (%) |

#### 5.1.2.1 Ekstraksi Data

Tahap ekstraksi data dilakukan untuk memindahkan informasi prevalensi dan indikator kesehatan dari dokumen PDF SSGI 2024 ke dalam bentuk data yang lebih terstruktur. Proses ini menggunakan fitur *Power Query* pada Microsoft Excel yang mampu membaca dan mengimpor tabel secara otomatis dari dokumen. Setelah seluruh tabel berhasil diambil, dilakukan penyaringan untuk memilih tabel yang sesuai dengan kebutuhan penelitian, khususnya yang memuat data

tingkat provinsi dan indikator determinan *stunting*. Setiap tabel yang dipilih kemudian diperiksa kembali dengan sumber aslinya untuk memastikan tidak terjadi kesalahan posisi data. Hasil dari tahap ini berupa kumpulan tabel mentah yang siap digunakan pada proses selanjutnya, yang dapat dilihat pada Tabel 5.2.

Tabel 5.2 Potongan Daftar Hasil Ekstraksi Tabel dari Laporan SSGI 2024

| No | Nomor Tabel Laporan | Indikator yang Diekstrak |
|---|---|---|
| 1 | Tabel 4.3 | Status Gizi Tinggi Badan menurut Umur (TB/U) |
| 2 | Tabel 5.15 | Pemeriksaan Kehamilan Ibu |
| 3 | Tabel 5.33 | Pemberian ASI Eksklusif 6 Bulan |
| 4 | Tabel 5.113 | Status Imunisasi Dasar Balita (12-23 Bulan) |
| 5 | Tabel 5.184 | Akses Sanitasi Rumah Tangga (RT) |

#### 5.1.2.2 Seleksi Fitur Determinan

Tahap seleksi fitur dilakukan untuk menentukan variabel yang akan digunakan dalam pemodelan. Proses ini dilakukan dengan memilih indikator yang relevan berdasarkan kajian literatur dan pedoman resmi terkait determinan *stunting*. Variabel yang dipilih mencakup beberapa aspek utama seperti prevalensi *stunting*, kondisi sosial ekonomi, sanitasi, serta pola asuh dan pelayanan kesehatan. Sementara itu, indikator yang tidak berhubungan langsung dengan kondisi gizi balita tidak disertakan dalam analisis. Melalui proses ini, diperoleh kumpulan fitur yang dianggap paling mewakili kondisi tiap provinsi, sebagaimana disajikan pada Tabel **??**.

Tabel 5.3 Potongan Daftar Hasil Seleksi Fitur Determinan *Stunting*

| No | Aspek Determinan | Nama Variabel (Fitur Asli Laporan) |
|---|---|---|
| 1 | *Outcome* (Target) | Prevalensi *Stunting* (%) |

| No | Aspek Determinan | Nama Variabel (Fitur Asli Laporan) |
|---|---|---|
| 2 | Kondisi Fisik Lahir | Persentase Berat Badan Lahir Rendah (BBLR) |
| 3 | Asupan Gizi Balita | Persentase Tidak Konsumsi Protein Hewani |
| 4 | Penyakit Infeksi | Persentase Balita TBC |
| 5 | Kapasitas Sosiodemografi | Persentase Pengetahuan *Stunting* Baik |

#### 5.1.2.3 Transformasi dan Agregasi Data

Tahap transformasi dan agregasi data merupakan proses penyatuan akhir sekaligus penyederhanaan struktur variabel agar memiliki makna dan skala yang konsisten saat dibandingkan antarprovinsi. Pada tahap ini, seluruh fitur yang telah diekstraksi digabungkan ke dalam satu matriks *dataframe* menggunakan nama provinsi sebagai kunci penghubung (*primary key*). Selain penggabungan tabel, dilakukan proses agregasi sistematis dengan mengombinasikan beberapa indikator yang memiliki kemiripan risiko, seperti menjumlahkan persentase kelompok usia kehamilan ekstrem menjadi satu atribut tunggal guna menghindari redundansi informasi. Seluruh variabel hasil agregasi tersebut tetap dipertahankan dalam satuan persentase untuk memastikan keseragaman format data sebelum diproses oleh algoritma pemodelan. Rincian mengenai sumber tabel laporan, alur operasi matematis yang diterapkan, hingga penamaan atribut baru yang masuk ke dalam *dataset* utama dapat dilihat secara lengkap pada Tabel 5.4.

Tabel 5.4 Skenario Transformasi dan Agregasi Fitur Determinan *Stunting*

| No | Nama Tabel Laporan | Alur Sistematis & Logika Agregasi | Nama Atribut Baru (CSV) |
|---|---|---|---|
| 1 | Tabel 4.3 (Status Gizi TB/U) | Menggabungkan persentase kategori *Severely Stunting* dan *Stunting* menjadi satu prevalensi target utama. | `prevalensi_stunting_persen` |
| 2 | Tabel 5.5 (Usia Ibu Memulai Kehamilan) | Menjumlahkan dua persentase kategori usia ekstrem, yakni kelompok usia < 21 tahun dan > 40 tahun. | `persen_usia_ibu_berisiko` |
| 3 | Tabel 5.184 (Akses Sanitasi RT) | Menjumlahkan nilai dari kategori: BABS Terbuka, BABS Tertutup, dan Akses Belum Layak. | `persen_akses_sanitasi_berisiko` |
| 4 | Tabel 5.33 (Pemberian ASI Eksklusif) | Menghitung nilai komplemen (100% dikurangi persentase ”Hanya ASI 0-5 Bulan”). | `persen_tidak_asi_eksklusif` |
| 5 | Tabel 5.113 (Status Imunisasi Dasar) | Menggabungkan persentase balita dengan status imunisasi ”Tidak Lengkap” dan ”Tidak Imunisasi”. | `persen_imunisasi_dasar_incomplete` |

### 5.1.3 Pra-pemrosesan dan Eksplorasi Data

Tahapan pra-pemrosesan data bertujuan untuk mengubah *dataset* mentah hasil ekstraksi SSGI 2024 menjadi format terstruktur yang bersih dan dapat diproses secara efektif oleh algoritma *machine learning*. Terdapat 58 kolom fitur

dalam *dataset* awal ini, namun tidak seluruh indikator tersebut memiliki kualitas data yang baik atau relevansi langsung dalam mendeteksi pola determinan *stunting*. Oleh sebab itu, penelitian ini melakukan serangkaian proses penyiapan lanjutan yang mengacu pada alur pra-pemrosesan, meliputi eksplorasi data, penanganan nilai hilang (*missing value*), hingga eliminasi variabel non-determinan. Sebagai gambaran, bentuk *dataset* mentah sebelum diproses lebih lanjut ditunjukkan pada Tabel 5.5. Adapun tahapan dari pra-pemrosesan data dijabarkan sebagai berikut.

Tabel 5.5 Cuplikan *Dataset* Mentah SSGI 2024 Sebelum Pra-pemrosesan

| **No** | **Provinsi** | **prevalensi_stunting_persen** | **persen_usia_ibu_berisiko** | **persen_bblr** | **...** |
|---|---|---|---|---|---|
| 1 | Aceh | 28,6 | 48,3 | 4,8 | ... |
| 2 | Sumatera Utara | 22,9 | 48,1 | 3,3 | ... |
| 3 | Sumatera Barat | 24,9 | 44,7 | 6,4 | ... |
| ... | ... | ... | ... | ... | ... |
| 39 | Indonesia | 19,8 | 40,4 | 6,5 | ... |

#### 5.1.3.1 Eksplorasi Data (EDA)

Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik distribusi data, memastikan kesesuaian tipe variabel, serta mengidentifikasi pola hubungan antarfitur sebelum proses pemodelan. Analisis awal difokuskan pada variabel target, yaitu persentase prevalensi *stunting*, di mana sebarannya divisualisasikan secara nasional untuk melihat ketimpangan antarwilayah. Hasil eksplorasi menunjukkan rentang prevalensi yang signifikan, dengan Provinsi Nusa Tenggara Timur mencatatkan angka tertinggi (37,0%) dan Bali berada pada posisi terendah (8,6%). Selanjutnya, dilakukan perhitungan matriks korelasi *Pearson* untuk meninjau hubungan linear antara 15 kandidat fitur

teratas dengan variabel target. Analisis ini mengungkap adanya korelasi positif yang sangat kuat antara *stunting* dengan kondisi fisik balita lainnya, seperti prevalensi *underweight* (0,93), serta kaitannya dengan indikator pelayanan kesehatan. Rincian implementasi kode program, beserta grafik distribusi dan *heatmap* korelasi yang dihasilkan dari tahapan ini, diuraikan berturut-turut pada Kode 4.1 serta urutan visualisasi pada Gambar 5.1, Gambar 5.2, dan Gambar 5.3.

**Kode 4.1** Implementasi Kode Eksplorasi Data (EDA)

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Memuat dataset dan konversi format koma menjadi desimal
df = pd.read_csv('SSGI_2024_dataset.csv')
for col in df.columns:
    if col != 'Provinsi' and df[col].dtype == 'object':
        df[col] = df[col].str.replace(',', '.', regex=False)
        df[col] = pd.to_numeric(df[col], errors='coerce')

# 2. Visualisasi Distribusi Target per Provinsi (Bar Chart)
df_clean = df.dropna(subset=['prevalensi_stunting_persen']) \
             .sort_values(by='prevalensi_stunting_persen')

plt.figure(figsize=(10, 12))
plt.barh(df_clean['Provinsi'],
     df_clean['prevalensi_stunting_persen'])
plt.title('Distribusi Prevalensi Stunting per Provinsi')
plt.xlabel('Persentase Stunting')
plt.ylabel('Provinsi')
plt.tight_layout()
plt.show()

# 3. Plot Distribusi Stunting (Histogram & KDE)
plt.figure(figsize=(10, 6))
sns.histplot(df_clean['prevalensi_stunting_persen'], kde=True,
     bins=10)
plt.title('Distribusi Persentase Stunting per Provinsi')
plt.xlabel('Persentase Stunting (%)')
plt.ylabel('Jumlah Provinsi')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

# 4. Analisis Korelasi dan Visualisasi Heatmap
correlation =
     df.corr(numeric_only=True)['prevalensi_stunting_persen'] \
                .sort_values(ascending=False)
top_15_vars = correlation.head(15).index

plt.figure(figsize=(10, 8))
sns.heatmap(df[top_15_vars].corr(numeric_only=True),
            annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Heatmap Korelasi 15 Variabel Teratas dengan Stunting')
plt.tight_layout()
plt.show()
```

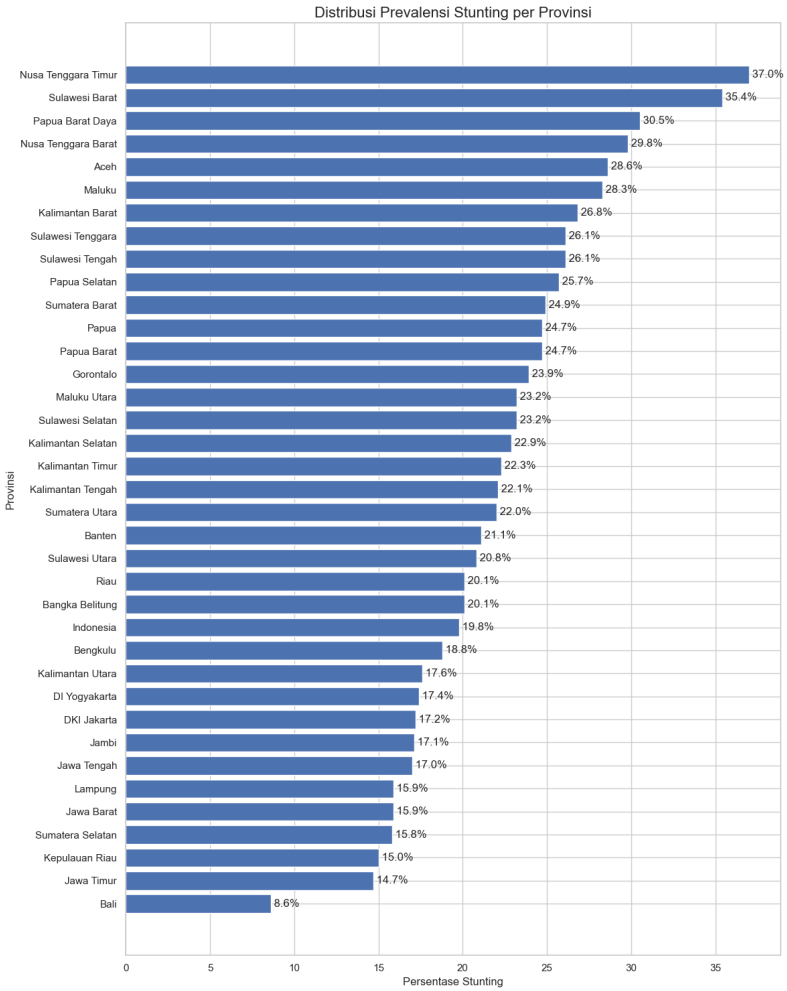


Gambar 5.1 Distribusi Prevalensi *Stunting* per Provinsi

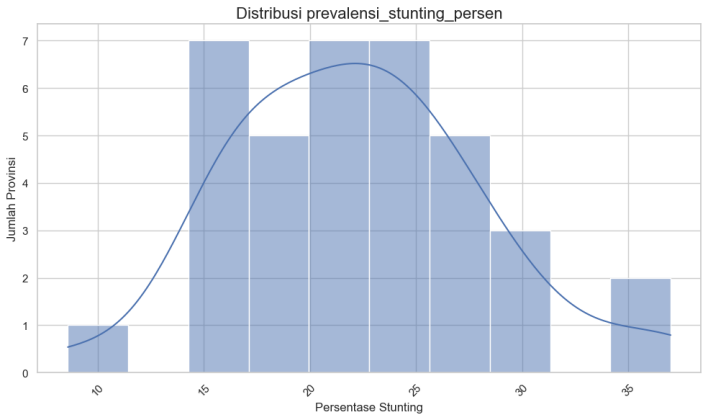


Gambar 5.2 Histogram Distribusi Data Target

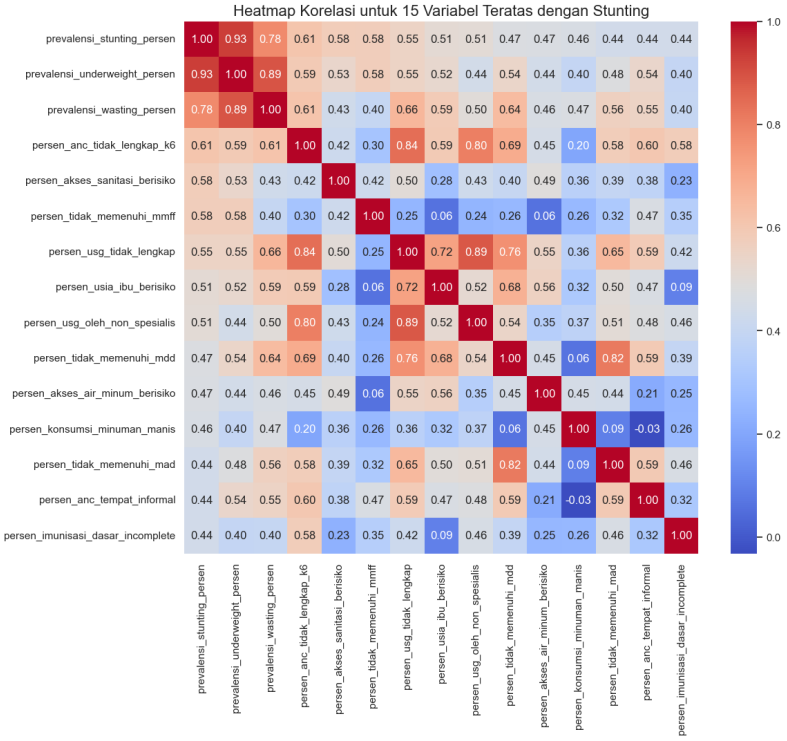


Gambar 5.3 *Heatmap* Korelasi 15 Variabel Teratas

#### 5.1.3.2 Penanganan *Missing Value*

Tahap penanganan *missing value* dilakukan untuk memastikan integritas data sebelum memasuki fase pemodelan. Berdasarkan hasil inspeksi pada data mentah SSGI 2024, ditemukan kekosongan data yang masif pada Provinsi Papua Tengah dan Papua Pegunungan sebagai wilayah pemekaran baru. Karena ketiadaan data tersebut bersifat struktural pada level observasi, metode *listwise deletion* diterapkan dengan menghapus kedua provinsi tersebut dari *dataset*. Selain itu, baris agregat "Indonesia" juga dieliminasi karena bukan merupakan entitas provinsi independen. Langkah ini memastikan bahwa *dataset* yang tersisa merupakan data lengkap (100% *complete*) tanpa memerlukan imputasi buatan. Implementasi kode dan ringkasan perubahan jumlah observasi ditunjukkan pada Kode 4.2 dan Tabel 5.6.

**Kode 4.2** Penghapusan Observasi dan Validasi *Missing Value*

```
# 1. Menghapus baris provinsi dengan data kosong dan agregat nasional
provinces_to_drop = ['Papua Tengah', 'Papua Pegunungan', 'Indonesia']

plot_data_clean = plot_data_clean[~plot_data_clean['Provinsi'] \
                                  .isin(provinces_to_drop)]

# 2. Validasi ketiadaan missing value
missing_values = plot_data_clean.isnull().sum()
missing_values = missing_values[missing_values > 0]

if len(missing_values) == 0:
    print("No missing values found in the dataset")
```

Tabel 5.6 Perbandingan Jumlah Observasi Sebelum dan Sesudah Pembersihan

| No | Kondisi *Dataset* | Jumlah Baris |
|---|---|---|
| 1 | Sebelum Penanganan *Missing Value* | 39 |
| 2 | Sesudah Penanganan *Missing Value* | 36 |

#### 5.1.3.3 Eliminasi Variabel Non-Determinan

Setelah pembersihan baris, dilakukan eliminasi fitur pada tingkat kolom untuk menghindari bias pemodelan. Fitur `prevalensi_underweight_persen` dan `prevalensi_wasting_persen` dihapus secara sengaja karena merupakan

indikator malnutrisi yang sangat berkorelasi dengan target *stunting*. Mempertahankan kedua variabel ini akan memicu *data leakage*, di mana model seolah-olah memiliki performa tinggi namun secara logika tidak valid dalam memetakan faktor penyebab (determinan) luar. Proses eliminasi ini dijabarkan pada Kode 4.3 dan perubahan dimensi kolomnya diringkas pada Tabel 5.7.

**Kode 4.3** Eliminasi Fitur untuk Mencegah *Data Leakage*

```
# Menghapus kolom underweight dan wasting
columns_to_drop = ['prevalensi_underweight_persen',
    'prevalensi_wasting_persen']
plot_data_clean = plot_data_clean.drop(columns=columns_to_drop)

print(f"Jumlah kolom setelah penghapusan:
    {len(plot_data_clean.columns)}")
```

Tabel 5.7 Perbandingan Jumlah Atribut Sebelum dan Sesudah Eliminasi

| No | Kondisi *Dataset* | Jumlah Kolom |
|---|---|---|
| 1 | Sebelum Eliminasi Variabel | 58 |
| 2 | Sesudah Eliminasi Variabel | 56 |

#### 5.1.3.4 Penetapan Variabel Penelitian

Tahap akhir pra-pemrosesan adalah penetapan matriks variabel penelitian yang siap masuk ke tahap pemodelan. *Dataset* final terdiri dari 36 provinsi dengan 54 fitur determinan numerik murni sebagai variabel independen ($X$) dan satu kolom target persentase prevalensi *stunting* ($y$). Kolom nama provinsi dipisahkan karena tidak berperan dalam perhitungan matematis algoritma *Random Forest*. Rincian pemisahan matriks ditunjukkan pada Kode 4.4, sedangkan struktur data finalnya direpresentasikan pada Tabel 5.8.

**Kode 4.4** Pemisahan Variabel Independen (X) dan Dependen (y)

```
# Menentukan target dan fitur prediktor
y = plot_data_clean['prevalensi_stunting_persen']
X = plot_data_clean.drop(['Provinsi', 'prevalensi_stunting_persen'],
    axis=1)

print("Dimensi X:", X.shape) # (36, 54)
print("Dimensi y:", y.shape) # (36,)
```

Tabel 5.8 Ilustrasi *Dataset* Final Pemodelan *Stunting*

| **Provinsi***(Index)* | **y: prevalensi_ stunting** | **X1: jarak_ hamil_ risiko** | **X2: usia_ ibu_ risiko** | **... (X54)** |
|---|---|---|---|---|
| Bali | 8,6 | 9,5 | 12,5 | ... |
| Jawa Timur | 14,7 | 10,4 | 13,1 | ... |
| Kep. Riau | 15,0 | 10,6 | 10,3 | ... |
| ... | ... | ... | ... | ... |

### 5.1.4 Pemodelan *Random Forest*

Setelah melalui serangkaian tahapan pra-pemrosesan data (*preprocessing*), langkah selanjutnya adalah pengembangan algoritma untuk memprediksi angka prevalensi *stunting*. Mengacu pada alur penelitian, rangkaian proses pengembangan model dibagi menjadi tiga tahapan utama, mulai dari pencarian parameter optimal (*hyperparameter tuning*), pelatihan model secara utuh (*fitting*), hingga diakhiri dengan evaluasi performa model. Adapun proses-proses tersebut dijabarkan sebagai berikut.

#### 5.1.4.1 *Hyperparameter Tuning* Berbasis *Cross Validation*

Mengingat dimensi *dataset* penelitian yang tergolong kecil (36 observasi), pembagian data latih (*training*) dan data uji (*testing*) konvensional berisiko menghasilkan variansi bias yang tinggi. Oleh karena itu, pendekatan *Leave-One-Out Cross-Validation* (LOOCV) diterapkan. Model dilatih sebanyak 36 kali, di mana pada setiap iterasinya, 35 data digunakan untuk pelatihan dan 1 data ditinggalkan untuk pengujian. Bersamaan dengan proses ini, dilakukan pencarian parameter terbaik menggunakan *Grid Search* terhadap 108 kombinasi parameter *Random Forest Regressor*. Evaluasi difokuskan untuk menekan nilai

*Mean Absolute Error* (MAE). Proses komputasi iteratif ini dijabarkan pada Kode 4.5, sedangkan hasil parameter terbaik yang didapatkan direpresentasikan pada Tabel 5.9.

**Kode 4.5** Pelaksanaan LOOCV dan *Grid Search*

```
from sklearn.model_selection import GridSearchCV, LeaveOneOut
from sklearn.ensemble import RandomForestRegressor

# Definisi kandidat parameter
param_grid = {
    'n_estimators': [50, 100, 150],
    'max_depth': [3, 5, 7, None],
    'min_samples_leaf': [1, 2, 3],
    'max_features': ['sqrt', 'log2', None]
}

model = RandomForestRegressor(random_state=42)
loocv = LeaveOneOut()
scorers = {'mae': 'neg_mean_absolute_error',
           'rmse': 'neg_root_mean_squared_error'}

# Eksekusi Grid Search dengan LOOCV
grid_search = GridSearchCV(
    estimator=model, param_grid=param_grid, cv=loocv,
    scoring=scorers, refit='mae', n_jobs=-1, verbose=2)

grid_search.fit(X, y)
```

Tabel 5.9 Hasil *Hyperparameter Tuning* Model *Random Forest*

| No | Nama Parameter | Nilai Optimal |
|---|---|---|
| 1 | n_estimators | 100 |
| 2 | max_depth | 5 |
| 3 | min_samples_leaf | 1 |
| 4 | max_features | log2 |

#### 5.1.4.2 Pelatihan Model Final

Parameter optimal yang diperoleh dari proses *tuning* dikonfigurasi ke dalam algoritma *Random Forest Regressor* yang baru. Model final ini kemudian dilatih kembali (*retrain*) menggunakan keseluruhan 36 baris *dataset* untuk mendapatkan pola pemetaan variabel fitur secara maksimal. Setelah model berhasil dilatih, dilakukan prediksi nilai prevalensi *stunting* guna membandingkan kedekatan nilai aktual target dengan nilai tebakan dari sistem. Rincian implementasi

deklarasi model dan prediksi dapat dilihat pada Kode 4.6. Selanjutnya, sintaksis untuk memvisualisasikan sebaran kedekatan tersebut ditunjukkan pada Kode 4.7, dengan hasil komparasi aktual-prediksi dicatat pada Tabel 5.10 dan Gambar 5.4.

**Kode 4.6** Pelatihan Model dan Eksekusi Prediksi

```
import pandas as pd
import matplotlib.pyplot as plt

# Deklarasi model final dengan parameter terbaik
best_params = grid_search.best_params_
model_final = RandomForestRegressor(**best_params, random_state=42)

# Melatih model dengan seluruh observasi
model_final.fit(X, y)

# Melakukan prediksi pada data
y_pred = model_final.predict(X)

# Menyusun DataFrame komparasi
comparison_df = pd.DataFrame({
    'Provinsi': plot_data_clean['Provinsi'],
    'Actual': y, 'Predicted': y_pred,
    'Difference': y - y_pred
}).sort_values('Actual')

pd.set_option('display.float_format', lambda x: '%.2f' % x)
```

Tabel 5.10 Cuplikan Perbandingan Nilai Aktual dan Prediksi

| No | Provinsi | Aktual | Prediksi | Selisih |
|---|---|---|---|---|
| 1 | Bali | 8,60 | 12,56 | -3,96 |
| 2 | Jawa Timur | 14,70 | 16,77 | -2,07 |
| 3 | Kep. Riau | 15,00 | 16,96 | -1,96 |
| ... | | | | |
| 35 | Sulawesi Barat | 35,40 | 31,28 | 4,12 |
| 36 | NTT | 37,00 | 33,82 | 3,18 |

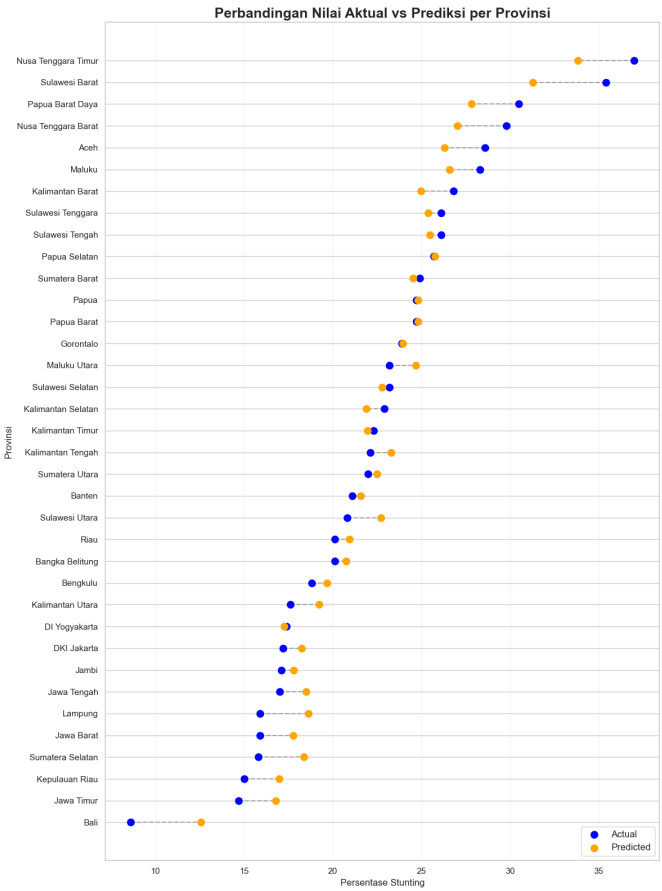


Gambar 5.4 Sebaran Nilai Aktual dan Prediksi *Stunting* per Provinsi

## 5.2 Evaluasi Performa Model

Tahapan pengujian dilakukan untuk mengukur besaran tingkat kesalahan (*error*) prediksi yang dihasilkan oleh model final. Pendekatan metrik yang digunakan mengacu pada perhitungan secara matematis antara nilai tebakan model (`y_pred`) dan data realita (`y`). Metrik utama yang digunakan terdiri dari *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), *R-squared* ($R^2$), dan *Mean Absolute Percentage Error* (MAPE). Perhitungan sintaksis dieksekusi pada Kode 4.8, di mana hasil rangkumannya dicatat pada Tabel 5.11.

**Kode 4.8** Perhitungan Metrik Evaluasi Regresi

```
from sklearn.metrics import mean_absolute_error, mean_squared_error,
    r2_score
import numpy as np

# Mengkalkulasi nilai metrik evaluasi
mae = mean_absolute_error(y, y_pred)
mse = mean_squared_error(y, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y, y_pred)
mape = np.mean(np.abs((y - y_pred) / y)) * 100

print(f"MAE: {mae:.2f} | RMSE: {rmse:.2f}")
print(f"R-squared: {r2:.4f} | MAPE: {mape:.2f}%")
```

Berdasarkan hasil evaluasi pada Tabel 5.11, model *Random Forest* mampu merekam pola *dataset* dengan nilai determinasi ($R^2$) sebesar 0,9090. Hal ini mengindikasikan bahwa model dapat menjelaskan 90,9% variabilitas penyebab *stunting* secara representatif. Di sisi lain, persentase deviasi prediksi yang ditunjukkan oleh nilai MAPE mencatatkan angka 7,22%, yang mengklasifikasikan performa model ke dalam kategori akurat.

Tabel 5.11 Hasil Pengujian Performa Model Regresi Final

| No | Metrik Evaluasi | Skor |
|---|---|---|
| 1 | *Mean Absolute Error* (MAE) | 1,40 |
| 2 | *Root Mean Squared Error* (RMSE) | 1,77 |
| 3 | *R-Squared* ($R^2$) | 0,9090 |
| 4 | *Mean Absolute Percentage Error* (MAPE) | 7,22% |

## 5.3 Analisis Hasil Pemodelan *Random Forest*

Setelah semua tahapan pembuatan model dan pengujian selesai dilakukan, bagian ini akan membahas hasil yang diperoleh. Analisis ini bertujuan untuk meninjau kecocokan pengaturan parameter, pola prediksi model, dan nilai evaluasinya. Pembahasan ini penting sebagai pengantar yang logis sebelum masuk ke tahap interpretasi fitur menggunakan SHAP. Rincian analisis tersebut dijelaskan pada poin-poin berikut.

### 5.3.1 Analisis Konfigurasi Parameter

Tahap konfigurasi parameter membahas kecocokan hasil *tuning* optimal yang sebelumnya telah dirangkum pada Tabel 5.9. Pemilihan nilai *max_depth* sebesar 5 menunjukkan bahwa pembatasan kedalaman pohon efektif untuk *dataset* dengan jumlah observasi yang sedikit. Langkah ini dilakukan untuk mencegah algoritma menghafal data latih secara berlebihan. Selain itu, penggunaan parameter *max_features* berupa *log2* memastikan setiap variabel memiliki kesempatan yang sama untuk dievaluasi pada tiap cabang pohon. Pengaturan ini membantu model agar belajar lebih baik dan terhindar dari masalah *overfitting*.

### 5.3.2 Analisis Pola Prediksi *Stunting* per Provinsi

Pola tebakan model dapat diamati melalui komparasi pada Tabel 5.10 dan visualisasi *scatter plot* pada Gambar 5.4. Secara umum, garis prediksi menunjukkan tren yang sejalan dengan nilai aslinya di sebagian besar wilayah. Namun, masih terdapat sedikit perbedaan estimasi pada provinsi dengan tingkat prevalensi terendah seperti Bali, dan tertinggi seperti Nusa Tenggara Timur. Hal ini wajar terjadi karena algoritma *Random Forest* bekerja dengan cara mengambil nilai rata-rata (*averaging*) dari banyak pohon keputusan. Cara kerja ini membuat prediksi model menjadi lebih stabil dan tidak mudah terpengaruh oleh data ekstrem (*outlier*), sehingga hasilnya tetap berada pada batas yang masuk akal secara statistik.

### 5.3.3 Analisis Metrik Evaluasi

Kualitas model dalam mengenali pola data dikonfirmasi oleh hasil pengujian performa pada Tabel 5.11. Koefisien determinasi ($R^2$) sebesar 0,9090 menunjukkan bahwa variabel-variabel yang digunakan sudah mampu menjelaskan 90,9% penyebab terjadinya *stunting*. Selain itu, nilai MAPE sebesar 7,22% berada di bawah batas toleransi kesalahan regresi, yaitu 10%. Tingkat

persentase kesalahan yang kecil ini membuktikan bahwa model sudah layak digunakan untuk kebutuhan estimasi angka prevalensi. Secara keseluruhan, algoritma menunjukkan hasil komputasi yang baik dalam memproses data SSGI 2024.

Nilai evaluasi yang didapatkan sudah memenuhi standar kelayakan. Namun, model prediksi ini memiliki batasan dalam hal transparansi. Algoritma berbasis *ensemble* memiliki sifat kotak hitam (*black-box*), sehingga proses pengambilan keputusannya tidak bisa dilihat secara langsung. Di sisi lain, diperlukan pemahaman mengenai fitur mana saja yang paling berpengaruh sebagai dasar rekomendasi penanganan *stunting*. Oleh karena itu, tahapan analisis selanjutnya akan menggunakan metode SHAP. Metode ini berguna untuk membedah model dan melihat seberapa besar pengaruh dari masing-masing fitur secara lebih jelas.

## 5.4 Interpretasi Model Menggunakan SHAP

Mengacu pada batasan algoritma *Random Forest* yang bersifat kotak hitam, tahapan ini difokuskan pada interpretasi hasil prediksi menggunakan *SHapley Additive exPlanations* (SHAP). Pendekatan ini digunakan untuk membedah besaran pengaruh dari masing-masing variabel independen terhadap angka prevalensi *stunting*. Analisis SHAP dalam penelitian ini dibagi menjadi dua ruang lingkup, yaitu analisis skala global dan analisis skala lokal. Pembagian ini bertujuan untuk melihat gambaran besar faktor penentu di tingkat nasional, sekaligus mengamati alasan spesifik di balik hasil prediksi pada masing-masing provinsi.

Proses interpretasi diawali dengan menginisialisasi objek pembaca model (*explainer*) ke dalam sistem. Karena *Random Forest* merupakan algoritma yang dibangun dari sekumpulan pohon keputusan, pustaka SHAP menyediakan fungsi khusus berupa `TreeExplainer` untuk membaca struktur model tersebut secara efisien. Setelah model berhasil dibaca, sistem akan menghitung matriks nilai SHAP untuk mengukur seberapa besar dorongan atau tarikan setiap

variabel terhadap hasil tebakan akhir. Rincian deklarasi algoritma SHAP beserta pengecekan dimensi *output*-nya ditunjukkan pada Kode 4.9.

**Kode 4.9** Inisialisasi *TreeExplainer* dan Ekstraksi Nilai SHAP

```
import shap
import numpy as np

# Inisialisasi SHAP explainer untuk model berbasis pohon
explainer = shap.TreeExplainer(model_final)
shap_values = explainer.shap_values(X)

# Pengecekan dimensi matriks SHAP values
print("Dimensi SHAP values:", np.shape(shap_values))
# Output: (36, 54)
```

### 5.4.1 Interpretasi Global (*Global Explanation*)

Interpretasi skala global bertujuan untuk melihat pola pengambilan keputusan model terhadap seluruh data observasi tingkat nasional. Pendekatan ini berfokus pada evaluasi dampak masing-masing variabel secara umum sebelum meninjau kasus pada wilayah yang lebih spesifik. Proses interpretasi model pada tahapan ini dibagi ke dalam tiga bentuk visualisasi utama. Visualisasi tersebut mencakup identifikasi urutan variabel penentu, pengamatan arah pengaruh fitur, dan peninjauan batas angka kritis dari indikator utama. Rincian penjelasan untuk masing-masing tahapan analisis ini diuraikan pada sub-subbab berikut.

#### 5.4.1.1 Tingkat Kepentingan Fitur (*Feature Importance Plot*)

Tahap awal interpretasi dilakukan dengan melihat tingkat kepentingan fitur melalui perhitungan rata-rata nilai absolut SHAP. Proses ini bertujuan untuk mengetahui variabel mana yang memiliki kontribusi paling besar terhadap prediksi model secara umum. Kode 4.10 menunjukkan implementasi fungsi `summary_plot` untuk menghasilkan diagram batang yang mengurutkan fitur-fitur tersebut. Hasil visualisasi dari kode tersebut kemudian ditampilkan pada Gambar 5.5. Melalui grafik ini, urutan indikator kesehatan yang menjadi penentu angka *stunting* di Indonesia dapat diidentifikasi secara urut.

**Kode 4.10** Visualisasi Tingkat Kepentingan Fitur Global

```
import matplotlib.pyplot as plt
```

```
# Visualisasi Bar Plot untuk 20 fitur paling berpengaruh
shap.summary_plot(shap_values, X, plot_type="bar",
                  max_display=20, show=False)

fig = plt.gcf()
fig.set_size_inches(10, 8)
plt.title("Rata-rata Dampak Absolut Fitur terhadap Stunting",
     fontsize=14)
plt.tight_layout()
plt.show()
```

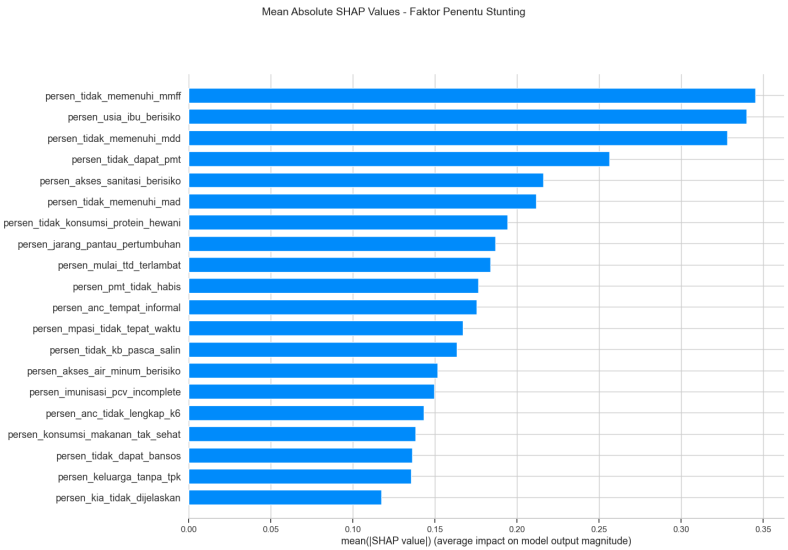


Gambar 5.5 Rata-Rata Dampak Absolut Fitur terhadap *Stunting* (*SHAP Bar Plot*)

Tabel 5.12 Keterangan Istilah Variabel pada *SHAP Bar Plot*

| No | Nama Variabel di Grafik | Keterangan / Makna Istilah |
|---|---|---|
| 1 | `persen_tidak_memenuhi_mmff` | *Minimum Milk Feeding Frequency* (Persentase balita non-ASI yang kurang asupan susu minimal 2 kali sehari). |
| 2 | `persen_tidak_memenuhi_mdd` | *Minimum Dietary Diversity* (Persentase balita yang kurang keberagaman jenis kelompok makanan harian). |
| 3 | `persen_cakupan_pmt` | Pemberian Makanan Tambahan (Bantuan pangan gizi untuk balita atau ibu hamil berisiko). |
| 4 | `persen_tidak_memenuhi_mad` | *Minimum Acceptable Diet* (Gabungan indikator frekuensi makan dan keberagaman jenis makanan minimal). |
| 5 | `persen_cakupan_ttd` | Tablet Tambah Darah (Suplemen zat besi untuk mencegah anemia pada ibu hamil atau remaja putri). |
| 6 | `persen_kunjungan_anc` | *Antenatal Care* (Pelayanan pemeriksaan kesehatan ibu selama masa kehamilan oleh tenaga medis). |
| 7 | `persen_pendampingan_tpk` | Tim Pendamping Keluarga (Tim yang mendampingi keluarga berisiko *stunting* di tingkat desa/kelurahan). |
| 8 | `persen_kepemilikan_kia` | Kesehatan Ibu dan Anak (Merujuk pada kepemilikan dan penggunaan Buku KIA untuk pemantauan kesehatan). |
| 9 | `persen_usia_ibu_berisiko` | Persentase ibu melahirkan pada usia berisiko (di bawah 20 tahun atau di atas 35 tahun). |

Gambar 5.5 menunjukkan bahwa variabel `persen_tidak_memenuhi_mmff` atau *Minimum Milk Feeding Frequency* menjadi faktor yang paling dominan dalam model. Indikator ini merepresentasikan persentase balita non-ASI yang tidak mendapatkan asupan susu minimal dua kali dalam sehari. Selain itu, faktor usia ibu yang berisiko dan kurangnya *Minimum Dietary Diversity* (MDD) atau variasi kelompok jenis makanan harian juga menempati posisi tiga besar. Temuan ini mengindikasikan bahwa pemenuhan frekuensi susu dan keberagaman gizi anak memiliki dampak yang lebih besar terhadap prevalensi *stunting* dibandingkan variabel fasilitas kesehatan. Identifikasi peringkat ini menjadi landasan untuk melakukan analisis yang lebih mendalam pada tahapan distribusi arah pengaruh variabel selanjutnya.

#### 5.4.1.2 Arah dan Distribusi Dampak Fitur (*Summary Plot*)

Tahapan analisis selanjutnya difokuskan pada pengamatan arah pengaruh dari masing-masing variabel terhadap hasil keluaran model. Pemetaan arah distribusi ini dilakukan dengan mengeksekusi Kode 4.11 untuk menghasilkan visualisasi *SHAP Summary Plot*. Hasil komputasi dari kode tersebut ditampilkan dalam bentuk grafik sebaran pada Gambar 5.6. Karena visualisasi ini menggunakan urutan fitur yang identik dengan tahapan sebelumnya, pembaca dapat merujuk kembali pada Tabel 4.1 untuk melihat keterangan label. Grafik ini menggunakan parameter gradasi warna untuk merepresentasikan angka asli pada data, di mana merah berarti tinggi dan biru berarti rendah.

**Kode 4.11** Visualisasi Arah dan Distribusi Dampak Fitur

```
import matplotlib.pyplot as plt

# Visualisasi sebaran arah pengaruh fitur (Summary Plot/Beeswarm)
shap.summary_plot(shap_values, X, show=False)

fig = plt.gcf()
fig.set_size_inches(10, 8)
plt.title("Arah dan Distribusi Dampak Fitur (Summary Plot)",
     fontsize=14)
plt.tight_layout()
plt.show()
```

Gambar 5.6 Arah dan Distribusi Dampak Fitur terhadap *Stunting* (*SHAP Summary Plot*)

Berdasarkan Gambar 5.6, terlihat jelas bagaimana tiga variabel utama memberikan dorongan kenaikan terhadap tebakan prevalensi model. Pada variabel `persen_tidak_memenuhi_mmff`, sebaran titik berwarna merah mendominasi area di sebelah kanan garis tegak (nol). Pola serupa juga ditemukan secara konsisten pada variabel persentase usia ibu berisiko dan kurangnya pemenuhan MDD. Sebaran ini membuktikan bahwa semakin tinggi persentase masalah kelengkapan gizi dan risiko usia ibu, maka prediksi kasus *stunting*

di suatu wilayah akan bertambah. Hasil distribusi warna yang sejalan dengan teori kesehatan ini menandakan bahwa algoritma telah berhasil memetakan pola sebab-akibat dengan akurat.

#### 5.4.1.3 Analisis Ketergantungan Fitur (*Dependence Plot*)

Langkah terakhir dalam analisis skala global adalah membedah distribusi nilai dari lima variabel dengan peringkat tertinggi. Pendekatan ini dilakukan menggunakan visualisasi *SHAP Dependence Plot* untuk mencari titik batas perubahan pengaruh pada masing-masing indikator. Eksekusi sintaksis perulangan untuk menghasilkan kelima grafik tersebut secara berurutan ditunjukkan pada Kode 4.12. Visualisasi yang dihasilkan kemudian dianalisis untuk melihat pada rentang angka berapa suatu variabel mulai merubah arah keputusan model. Penjelasan rincian dari setiap grafik dijabarkan pada paragraf-paragraf di bawah ini.

**Kode 4.12** Visualisasi Ketergantungan Lima Fitur Teratas

```
import matplotlib.pyplot as plt

# Daftar 5 fitur teratas berdasarkan SHAP
top5_features = [
    "persen_tidak_memenuhi_mmff",
    "persen_usia_ibu_berisiko",
    "persen_tidak_memenuhi_mdd",
    "persen_tidak_dapat_pmt",
    "persen_akses_sanitasi_berisiko"
]

# Visualisasi dependence plot per fitur
for feature in top5_features:
    plt.figure(figsize=(7, 5))
    shap.dependence_plot(
        feature, shap_values, X,
        interaction_index=None,
        show=False
    )
    plt.title(f"SHAP Dependence Plot - {feature.replace('_', '
     ').title()}", fontsize=13, pad=10)
    plt.xlabel("Nilai Fitur", fontsize=11)
    plt.ylabel("SHAP Value (Pengaruh terhadap Risiko Stunting)",
     fontsize=11)
    plt.tight_layout()
    plt.show()
```

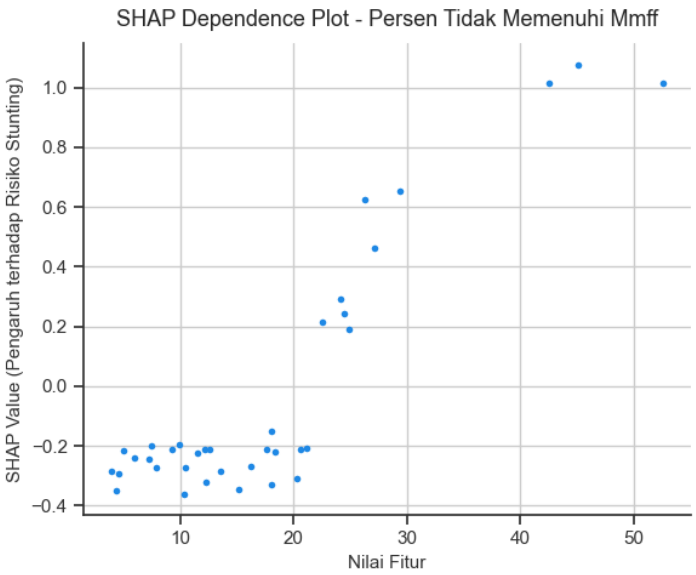


Gambar 5.7 *Dependence Plot* Variabel Persen Tidak Memenuhi MMFF

Gambar 5.7 menampilkan grafik ketergantungan untuk fitur persentase tidak memenuhi MMFF. Berdasarkan sebaran titik pada visualisasi tersebut, nilai SHAP berada secara stabil di area negatif saat angka observasi berada di bawah 22%. Namun, terdapat lonjakan drastis yang menyeberangi sumbu nol menuju area positif ketika persentase fitur melampaui ambang batas 22% hingga 25%. Semakin nilai persentase menjauhi batas tersebut ke arah kanan, dorongan terhadap risiko prediksi *stunting* menjadi semakin tinggi secara signifikan. Pola ini membuktikan bahwa kurangnya asupan susu pada balita non-ASI memiliki batas toleransi maksimal di kisaran 22% sebelum memicu lonjakan kasus.

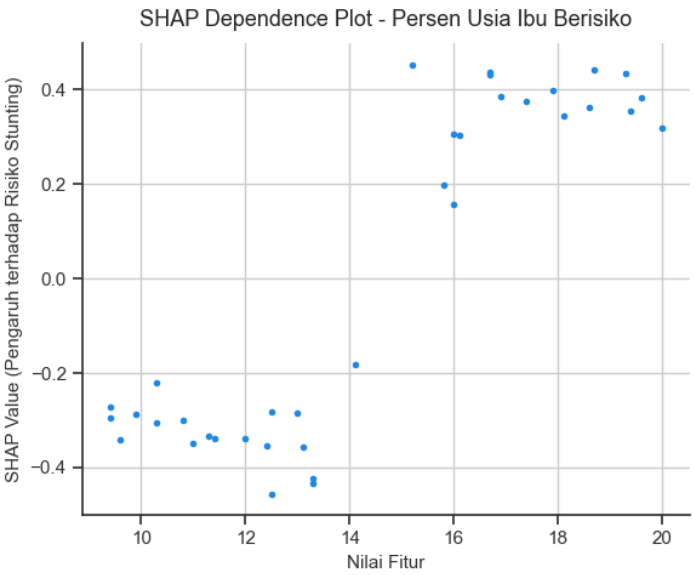


Gambar 5.8 *Dependence Plot* Variabel Persen Usia Ibu Berisiko

Visualisasi ketergantungan untuk persentase usia ibu berisiko ditunjukkan pada Gambar 5.8. Grafik ini memperlihatkan pola lonjakan nilai SHAP yang tegas ketika angka asli fitur melewati ambang batas 14%. Pada rentang persentase di bawah 14%, dampak yang diberikan cenderung bernilai negatif atau menekan angka prediksi. Sebaliknya, ketika persentase wilayah menyentuh angka 15% ke atas, hasil tebakan langsung mendapat dorongan positif yang memicu kenaikan prediksi. Karakteristik ini mengindikasikan bahwa intervensi pencegahan kehamilan pada usia berisiko sebaiknya diupayakan agar tidak melampaui batas 14%.

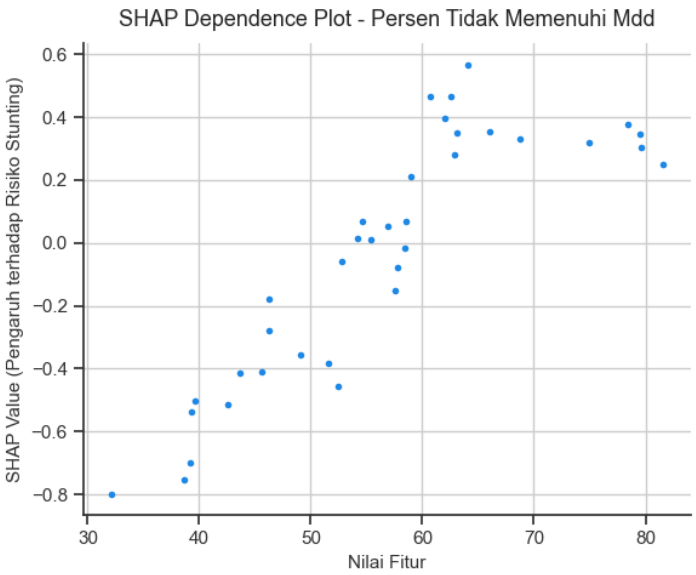


Gambar 5.9 *Dependence Plot* Variabel Persen Tidak Memenuhi MDD

Analisis ketergantungan untuk persentase balita tidak memenuhi MDD dapat diamati melalui sebaran titik pada Gambar 5.9. Indikator keberagaman makanan ini menunjukkan pola hubungan naik yang sejalan dengan peningkatan nilai aslinya. Titik kritis dari variabel ini terlihat secara jelas berada di sekitar angka 55% ketika melewati sumbu nol. Semakin nilai persentase bergerak menjauhi ambang batas tersebut menuju angka 80%, risiko prevalensi yang ditebak oleh model menjadi semakin tinggi. Pola distribusi ini menegaskan bahwa peningkatan masalah keberagaman asupan gizi secara proporsional akan menambah tinggi prediksi kasus di suatu wilayah.

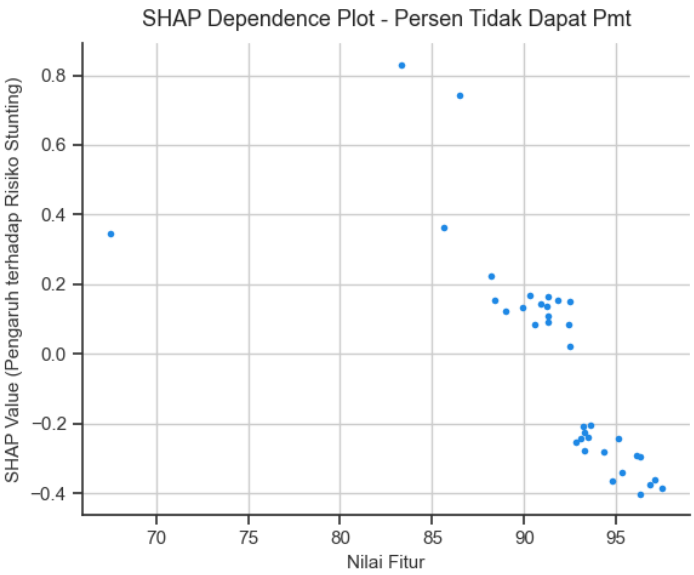


Gambar 5.10 *Dependence Plot* Variabel Persen Tidak Dapat PMT

Gambar 5.10 membedah sebaran dampak dari variabel persentase sasaran yang tidak mendapatkan Pemberian Makanan Tambahan (PMT). Persebaran data pada visualisasi ini menunjukkan tarikan nilai SHAP yang tinggi saat angka asli fitur berada di bawah 85%. Ketika persentase fitur mendekati rentang 90% hingga 95%, dampak variabel mulai melemah dan berpindah ke area nol hingga negatif. Karakteristik bentuk ini memperlihatkan dinamika kontribusi ketiadaan PMT yang tidak selalu lurus berbanding dengan prediksi hasil. Hasil pemetaan batas persentase ini memberikan informasi pendukung untuk mengevaluasi pemerataan bantuan PMT di wilayah observasi.

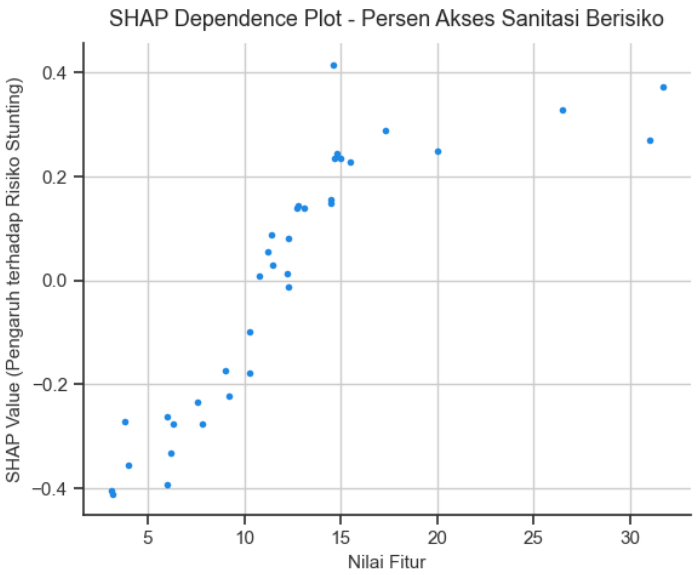


Gambar 5.11 *Dependence Plot* Variabel Persen Akses Sanitasi Berisiko

Grafik ketergantungan kelima yang membedah persentase akses sanitasi berisiko ditampilkan pada Gambar 5.11. Distribusi titik data pada sumbu vertikal memperlihatkan kecenderungan pergerakan naik secara berkelanjutan. Variabel sanitasi mulai memberikan sumbangsih positif terhadap peningkatan prediksi *stunting* ketika angkanya melewati batas kritis 10%. Pada persentase di bawah angka batas tersebut, nilai perhitungan SHAP berada di area negatif yang mendeskripsikan penurunan angka tebakan. Pemetaan dari model ini membuktikan bahwa wilayah observasi perlu menekan persentase ketiadaan akses sanitasi layak di bawah batas 10%.

## 5.5 Analisis Hasil Penelitian

### 5.5.1 Interpretasi Global (*Global Explanation*)

- **Peringkat Variabel:** Analisis fitur paling determinan secara nasional menggunakan *SHAP Bar Plot*.
- **Arah Kontribusi:** Analisis *SHAP Summary Plot* untuk melihat bagaimana

kondisi variabel yang memburuk (titik merah) mendorong kenaikan angka *stunting*.

### 5.5.2 Interpretasi Lokal (*Local Explanation*)

- **Bedah Provinsi:** Analisis spesifik pada provinsi dengan prevalensi ekstrem menggunakan *SHAP Waterfall Plot*.
- **Mekanisme Prediksi:** Menjelaskan pergeseran dari nilai rata-rata nasional (*Base Value*) menuju nilai prediksi akhir akibat dorongan faktor lokal (balok merah/biru).

### 5.5.3 Pembahasan dan Rekomendasi Kebijakan

- **Kesesuaian Teori:** Konfirmasi temuan *multiplier effect* antarvariabel *stunting* dengan pedoman gizi Kementerian Kesehatan.
- **Rekomendasi Spesifik:** Usulan intervensi kebijakan gizi yang tidak dipukul rata, melainkan disesuaikan dengan akar masalah terbesar di masing-masing provinsi berdasarkan *Waterfall Plot*.

# DAFTAR PUSTAKA


[1] J. C. Waterlow, "Classification and definition of protein-calorie malnutrition," *British Medical Journal*, vol. 3, no. 5826, pp. 566–569, 1972.

[2] D. H. Said and A. Rahmah, "Pencegahan stunting melalui edukasi gaya hidup sehat dan penguatan ekonomi," *Jurnal Pembelajaran Pemberdayaan Masyarakat (JP2M)*, vol. 5, no. 2, pp. 349–358, 2024, 2721-5148.

[3] R. Rahagia, N. Sriyanah, I. A. Tyarini, A. Lontaan, and M. Yunus, "Upaya Pencegahan Stunting Berbasis Edukasi dan Sosialisasi," *Abdimas Polsaka: Jurnal Pengabdian Kepada Masyarakat*, vol. 2, no. 1, 2023, 2829-162X.

[4] Kementerian Kesehatan RI, "Survei Status Gizi Indonesia (SSGI) 2024 Dalam Angka," Kementerian Kesehatan RI, tech. rep., 2025.

[5] Badan Kebijakan Pembangunan Kesehatan, "Survei Kesehatan Indonesia (SKI) 2023 Dalam Angka," Kementerian Kesehatan RI, tech. rep., 2023.

[6] Kementerian Sekretariat Negara RI, "Strategi Nasional Percepatan Pencegahan dan Penurunan Stunting 2025-2029," Kementerian Sekretariat Negara RI, tech. rep., 2024.

[7] H. Supriyanto, "Implementasi Kebijakan Penurunan Stunting di Kecamatan Salem Kabupaten Brebes," *Jurnal Multidisiplin Indonesia*, vol. 2, no. 2, 2023, 2964-9048.

[8] A. S. Saleh, T. Hasan, and U. K. S. Saleh, "Edukasi Penerapan Gizi Seimbang Masa Kehamilan Berbasis Pangan Lokal Sebagai Pencegahan Stunting," *AHMAR METAKARYA: JURNAL*

*PENGABDIAN MASYARAKAT*, vol. 2, no. 2, pp. 49–53, 2023, 2807-3576.

[9] A. B. Zemariam et al., "Prediction of stunting and its socioeconomic determinants among adolescent girls in Ethiopia using machine learning algorithms," *PLOS ONE*, vol. 20, no. 1, e0316452, 2025.

[10] T. Tamanna, S. Mahmud, N. Salma, M. M. Hossain, and M. R. Karim, "Identifying determinants of malnutrition in under-five children in Bangladesh: insights from the BDHS-2022 cross-sectional study," *Scientific Reports*, vol. 15, no. 14336, 2025.

[11] M. A. E. Pratama, S. Hendra, H. R. Ngemba, R. Nur, R. Azhar, and R. Laila, "Comparison of Machine Learning Algorithms for Predicting Stunting Prevalence in Indonesia," *SISFOKOM Journal (Information and Computer Systems)*, vol. 13, no. 2, pp. 200–209, 2024.

[12] S. Pande, R. Singh, and A. Kumar, "Analyzing determinants from both compositional and contextual level impeding desired linear growth of children in Indian context," *BMC Nutrition*, vol. 9, p. 89, 2023.

[13] H. W. Jemil, S. W. Semayneh, A. B. Kassaw, and K. D. Gashu, "Predicting severe stunting and its determinants among under-five in Eastern African Countries: A machine learning algorithms," *PLoS ONE*, vol. 21, no. 1, e0340221, 2026.

[14] BKKBN, *Peraturan Badan Kependudukan dan Keluarga Berencana Nasional Nomor 12 Tahun 2021 tentang Rencana Aksi Nasional Percepatan Penurunan Angka Stunting Indonesia Tahun 2021-2024*, Berita Negara Republik Indonesia Tahun 2021 Nomor 1188, Jakarta, 2021.

[15] Kementerian Kesehatan RI, *Peraturan Menteri Kesehatan Republik Indonesia Nomor 2 Tahun 2020 tentang Standar Antropometri Anak*, Berita Negara Republik Indonesia Tahun 2020 Nomor 2, Jakarta, 2020.

[16] World Health Organization, *WHO Child Growth Standards: Methods and Development*. Geneva: World Health Organization, 2006.

[17] World Health Organization, "Childhood Stunting: Context, Causes and Consequences Framework," World Health Organization, tech. rep., 2013, Akses daring pada 2 Februari 2026.

[18] I. D. Id, *Machine Learning: Teori, Studi Kasus dan Implementasi Menggunakan Python*, 1st ed. Pekanbaru: UR PRESS, 2021, ISBN: 978-632-255-092-6.

[19] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*, 2nd ed. New York: Springer, 2021.

[20] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[21] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009, p. 588.

[22] Q. Zhou, Q. Zhao, P. Zhu, and Z. Huang, "Pest Bird Density Forecast of Transmission Lines by Random Forest Regression Model and Line Transect Method," *Proceedings of [Nama Konferensi/Jurnal jika diketahui, misal: IEEE International Conference on...]*, Jiangmen Power Supply Bureau of Guangdong Power Grid, 2020.

[23] H. Shen, H. Zhao, and Y. Jiang, "Machine Learning Algorithms for Predicting Stunting among Under-Five Children in Papua New Guinea," *Children*, vol. 10, no. 10, p. 1638, 2023.

[24] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd. Melbourne: OTexts, 2021.

[25] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in Python*. Springer Nature, 2023.

[26] J.-O. Irisson, A. D'Hervé, C. M. Guigand, L. Stemmann, and F. Lombard, "Iterative spatial leave-one-out cross-validation and gap-filling based data augmentation for supervised learning applications in marine remote sensing," *GIScience & Remote Sensing*, vol. 59, no. 1, pp. 1281–1300, 2022.

[27] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Boston: Morgan Kaufmann, 2012, ISBN: 978-0-12-381479-1.

[28] M. Kutlu, T. B. Donmez, and C. Freeman, "Machine learning interpretability in diabetes risk assessment: a SHAP analysis," *Computers and Electronics in Medicine*, 2024, Also available at University of Southampton ePrints.

[29] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017, pp. 4765–4774.

[30] U. Orji and E. Ukwandu, "Machine learning for an explainable cost prediction of medical insurance," *Machine Learning with Applications*, vol. 15, p. 100 516, 2024.

[31] G.-W. Cha, H.-J. Moon, and Y.-C. Kim, "Comparison of Random Forest and Gradient Boosting Machine Models for Predicting Demolition Waste Based on Small Datasets and Categorical Variables," *International Journal of Environmental Research and Public Health*, vol. 18, no. 16, p. 8530, 2021.

[32] M. Fatmawati, B. A. Herlambang, and N. Q. Nada, "Random Forest Algorithm for Toddler Nutritional Status Classification," *Journal of Applied Informatics and Computing (JAIC)*, vol. 8, no. 2, pp. 428–433, 2024.

# LAMPIRAN

## A Dataset

Penelitian ini menggunakan data sekunder dari laporan Survei Status Gizi Indonesia (SSGI) tahun 2024. Sebagai bagian dari studi pendahuluan, data telah melalui tahap ekstraksi dan agregasi awal untuk memastikan ketersediaan variabel determinan. Berikut adalah rincian akses data:

1. **Sumber Data Mentah (Laporan Resmi):** Buku Laporan Survei Status Gizi Indonesia (SSGI) Tahun 2024 oleh Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan:
   https://www.badankebijakan.kemkes.go.id/survei-status-gizi-indonesia-ssgi-2024/
2. **Draf Dataset Pra-pemrosesan (Studi Pendahuluan):** Dataset tabular yang telah diekstraksi berbasis provinsi yang siap digunakan dalam eksperimen pemodelan:
   https://bit.ly/Dataset_SSGI_2024