

**ANALISIS DETERMINAN PENYEBAB *STUNTING* PROVINSI
DI INDONESIA: APLIKASI MODEL *RANDOM FOREST* DAN
INTERPRETASI SHAP PADA DATA SSGI TAHUN 2024**

TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di
Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut
Teknologi Sumatera

Oleh:

Cindy Nadila Putri

122140002



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN
2026**

KATA PENGANTAR

Puji syukur kehadiran Allah SWT, yang atas rahmat dan karunia-Nya, penulis dapat menyelesaikan Tugas Akhir berjudul "Analisis Determinan Penyebab Stunting Provinsi di Indonesia: Aplikasi Model Random Forest dan Interpretasi SHAP pada Data SSGI Tahun 2024". Tugas Akhir ini disusun guna memenuhi salah satu syarat kelulusan Program Studi Teknik Informatika, Institut Teknologi Sumatera.

Penulis menyampaikan ucapan terima kasih kepada Bapak Martin Clinton Tosima Manullang, Ph.D., selaku dosen pembimbing atas bimbingan, arahan, masukan, dan motivasi yang diberikan selama proses penyusunan Tugas Akhir ini.

Rasa terima kasih yang tak terhingga penulis sampaikan kepada orang tua dan keluarga penulis atas doa dan dukungannya. Penulis juga berterima kasih kepada seluruh sahabat dan rekan seperjuangan atas kerja sama dan semangat selama masa perkuliahan.

Penulis menyadari Tugas Akhir ini masih jauh dari sempurna, oleh karena itu kritik dan saran yang membangun sangat diharapkan demi perbaikan. Semoga Tugas Akhir ini dapat memberikan manfaat bagi para pembaca.

DAFTAR ISI

KATA PENGANTAR	ii
DAFTAR ISI	iii
DAFTAR TABEL	vi
DAFTAR GAMBAR	vii
DAFTAR RUMUS	ix
DAFTAR KODE	xi
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian	5
1.4 Batasan Masalah	5
1.5 Manfaat Penelitian	6
1.6 Sistematika Penulisan	7
BAB II TINJAUAN PUSTAKA	9
2.1 Tinjauan Pustaka	9
2.2 Dasar Teori	14
2.2.1 <i>Stunting</i>	14
2.2.2 Determinan <i>Stunting</i>	15
2.2.3 Survei Status Gizi Indonesia (SSGI)	17
2.2.4 <i>Machine Learning</i>	18
2.2.5 <i>Supervised Learning</i>	19
2.2.5.1 Regresi	19
2.2.6 <i>Random Forest Regression</i>	20

2.2.7	<i>Feature Selection</i>	21
2.2.8	Transformasi Data	22
2.2.9	Agregasi Data	22
2.2.10	Metrik Evaluasi Regresi	23
2.2.11	<i>Cross Validation</i>	24
2.2.12	<i>Leave-One-Out Cross Validation (LOOCV)</i>	25
2.2.13	Interpretabilitas Model	26
2.2.14	SHAP (<i>SHapley Additive exPlanations</i>)	27
BAB III METODE PENELITIAN		28
3.1	Alur Penelitian	28
3.2	Langkah Penelitian	29
3.2.1	Persiapan Data	30
3.2.1.1	Ekstraksi Data	31
3.2.1.2	Seleksi Fitur Determinan	32
3.2.1.3	Transformasi dan Agregasi Data	32
3.2.2	Pra-pemrosesan Data	34
3.2.2.1	Representasi Dataset Penelitian	34
3.2.3	Pemodelan <i>Random Forest</i>	35
3.2.3.1	<i>Hyperparameter Tuning</i> Berbasis <i>Cross Validation</i> ..	36
3.2.3.2	Pelatihan Model Final	37
3.2.4	Evaluasi Performa Model	38
3.3	Interpretasi Hasil dengan SHAP	39
3.3.1	Interpretasi Global	40
3.3.2	Interpretasi Lokal	41
3.3.2.1	Pemilihan Sampel Provinsi	41
3.3.2.2	Visualisasi dan Analisis <i>Waterfall Plot</i>	42
3.4	Lingkungan Pengembangan Model	42
3.5	Ilustrasi Perhitungan Metode	43

3.5.1	Prediksi <i>Random Forest Regression</i>	43
3.5.2	Perhitungan <i>Error</i> Prediksi	44
3.5.3	Perhitungan Metrik Evaluasi	45
3.6	Ilustrasi Rancangan Pengujian	46
3.6.1	Skema <i>Leave-One-Out Cross Validation</i> (LOOCV)	47
3.6.2	<i>Hyperparameter Tuning</i>	47
3.6.3	Pemilihan Model Final	48
BAB IV	HASIL DAN PEMBAHASAN	49
4.1	Hasil Penelitian	49
4.1.1	Analisis Deskriptif	49
4.1.2	Persiapan Data	50
4.1.2.1	Ekstraksi Data	51
4.1.2.2	Seleksi Fitur Determinan	52
4.1.2.3	Transformasi dan Agregasi Data	53
4.1.3	Pra-pemrosesan dan Eksplorasi Data	54
4.1.3.1	Eksplorasi Data (EDA)	55
4.1.3.2	Penanganan <i>Missing Value</i>	60
4.1.3.3	Eliminasi Variabel Non-Determinan	60
4.1.3.4	Penetapan Variabel Penelitian	61
4.1.4	Pemodelan <i>Random Forest</i>	62
4.1.4.1	<i>Hyperparameter Tuning</i> Berbasis <i>Cross Validation</i> ..	62
4.1.4.2	Pelatihan Model Final	65
4.2	Evaluasi Performa Model	67
4.3	Analisis Hasil Pemodelan <i>Random Forest</i>	69
4.3.1	Analisis Konfigurasi Parameter	69
4.3.2	Analisis Pola Prediksi <i>Stunting</i> per Provinsi	69
4.3.3	Analisis Metrik Evaluasi	70
4.4	Interpretasi Model Menggunakan SHAP	71

- 4.4.1 Interpretasi Global (*Global Explanation*) 72
 - 4.4.1.1 Tingkat Kepentingan Fitur (*Feature Importance Plot*) 72
 - 4.4.1.2 Arah dan Distribusi Dampak Fitur (*Summary Plot*).. 75
 - 4.4.1.3 Analisis Ketergantungan Fitur (*Dependence Plot*)... 77
- 4.4.2 Interpretasi Lokal (*Local Explanation*) 85
 - 4.4.2.1 Kriteria Pemilihan Sampel Wilayah 85
 - 4.4.2.2 Analisis Skala Lokal (*Waterfall Plot*) 87
- DAFTAR PUSTAKA..... 94**
- LAMPIRAN..... 98**
 - A Dataset..... 98

DAFTAR TABEL

Tabel 2.1	Ringkasan Penelitian Terdahulu	12
Tabel 3.1	Distribusi Variabel Determinan Stunting berdasarkan Kategori	35
Tabel 3.2	Data Hipotetis Output Pohon Keputusan	44
Tabel 3.3	Data Hipotetis Aktual vs Prediksi	44
Tabel 3.4	Data Hipotetis untuk Evaluasi Agregat	45
Tabel 3.5	Ilustrasi Skema Pembagian Data LOOCV	47
Tabel 3.6	Data Hipotetis Hasil Tuning Parameter	48
Tabel 4.1	Kondisi Awal Dataset SSGI 2024	51
Tabel 4.2	Contoh Hasil Ekstraksi Tabel dari Laporan SSGI 2024	52
Tabel 4.3	Contoh Variabel Hasil Seleksi Fitur Determinan <i>Stunting</i> ..	52
Tabel 4.4	Contoh Skenario Transformasi dan Agregasi Fitur Determinan <i>Stunting</i>	54
Tabel 4.5	Gambaran <i>Dataset</i> Mentah SSGI 2024 Sebelum Pra-pemrosesan	55
Tabel 4.6	Perbandingan Jumlah Observasi Sebelum dan Sesudah Pembersihan	60
Tabel 4.7	Perbandingan Jumlah Atribut Sebelum dan Sesudah Eliminasi	61
Tabel 4.8	Ilustrasi <i>Dataset</i> Final Pemodelan <i>Stunting</i>	62
Tabel 4.9	Hasil <i>Hyperparameter Tuning</i> Model <i>Random Forest</i>	64
Tabel 4.10	Cuplikan Perbandingan Nilai Aktual dan Prediksi	66
Tabel 4.11	Hasil Evaluasi Performa Model Regresi Final	68
Tabel 4.12	Keterangan Istilah Variabel pada <i>SHAP Bar Plot</i>	73

DAFTAR GAMBAR

Gambar 2.1	Kerangka Konseptual Faktor Penyebab <i>Stunting</i> [17]	16
Gambar 2.2	Struktur Umum <i>Random Forest Regression</i> [22]	20
Gambar 2.3	Skema Partisi Data pada LOOCV [25]	25
Gambar 3.1	Diagram Alir Penelitian	28
Gambar 3.2	Alur Penyiapan Data	31
Gambar 3.3	Alur Pra-pemrosesan Data	34
Gambar 3.4	Alur Pembangunan Model <i>Random Forest Regression</i> . . .	36
Gambar 3.5	Alur Interpretasi Model dengan SHAP	39
Gambar 4.1	Distribusi Prevalensi <i>Stunting</i> per Provinsi	57
Gambar 4.2	Histogram Distribusi Data Target	58
Gambar 4.3	<i>Heatmap</i> Korelasi 15 Variabel Teratas	59
Gambar 4.4	Kurva Pelatihan dan Validasi pada Proses <i>Hyperparameter Tuning</i>	65
Gambar 4.5	Sebaran Nilai Aktual dan Prediksi <i>Stunting</i> per Provinsi .	67
Gambar 4.6	Rata-Rata Dampak Absolut Fitur terhadap <i>Stunting</i> (<i>SHAP Bar Plot</i>)	73
Gambar 4.7	Arah dan Distribusi Dampak Fitur terhadap <i>Stunting</i> (<i>SHAP Summary Plot</i>)	76
Gambar 4.8	<i>Dependence Plot</i> Variabel Persen Tidak Memenuhi MMFF	78
Gambar 4.9	<i>Dependence Plot</i> Variabel Persen Usia Ibu Berisiko	79
Gambar 4.10	<i>Dependence Plot</i> Variabel Persen Tidak Memenuhi MDD	81
Gambar 4.11	<i>Dependence Plot</i> Variabel Persen Tidak Dapat PMT	82
Gambar 4.12	<i>Dependence Plot</i> Variabel Persen Akses Sanitasi Berisiko	84
Gambar 4.13	<i>Waterfall Plot</i> Prediksi <i>Stunting</i> Provinsi Lampung	88
Gambar 4.14	<i>Waterfall Plot</i> Prediksi <i>Stunting</i> Provinsi Aceh	89
Gambar 4.15	<i>Waterfall Plot</i> Prediksi <i>Stunting</i> Provinsi Sumatera Utara	90

Gambar 4.16 *Waterfall Plot* Prediksi *Stunting* Provinsi Nusa Tenggara

Timur 91

Gambar 4.17 *Waterfall Plot* Prediksi *Stunting* Provinsi Bali 92

Gambar 4.18 *Waterfall Plot* Prediksi *Stunting* Provinsi Jawa Barat 93

DAFTAR RUMUS

Rumus 2.1	Rumus perhitungan Z-score antropometri	15
Rumus 2.2	Persamaan dasar regresi linear	19
Rumus 2.3	Rata-rata prediksi pada Random Forest Regression	20
Rumus 2.4	Rumus Mean Absolute Error (MAE)	23
Rumus 2.5	Rumus Root Mean Square Error (RMSE)	23
Rumus 2.6	Rumus Mean Absolute Percentage Error (MAPE)	24
Rumus 2.7	Rumus Koefisien Determinasi (R^2)	24

DAFTAR KODE

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kualitas sumber daya manusia yang unggul sangat ditentukan oleh status gizi dan kesehatan yang optimal pada masa pertumbuhan. Di Indonesia, pencapaian kualitas tersebut masih terhambat oleh tingginya prevalensi masalah gizi kronis atau yang dikenal sebagai *stunting*. Istilah *stunting* pertama kali diperkenalkan dalam literatur medis pada tahun 1972 untuk mengklasifikasikan kondisi perlambatan pertumbuhan linear akibat malnutrisi kronis [1]. Masalah ini telah menjadi perhatian serius karena dampaknya yang meluas, terutama pada anak-anak sebagai generasi penerus bangsa. Berbagai faktor, seperti pola hidup, akses terhadap makanan bergizi, serta kualitas pelayanan kesehatan, turut berkontribusi terhadap tingginya prevalensi masalah ini.

Penyakit *stunting* merupakan kondisi di mana tubuh mengalami kekurangan gizi secara berlebihan dan terjadi pada rentang waktu yang cukup lama [2]. Dampak dari masalah ini akan mengakibatkan kendala pertumbuhan pada anak sehingga tinggi badan anak cenderung menjadi lebih pendek. Tak hanya memengaruhi pertumbuhan fisik, kondisi *stunting* juga akan berpengaruh ke dalam aspek pertumbuhan lainnya seperti mental, intelektual, dan kognitif anak [3]. Oleh karena itu, penting untuk memahami faktor-faktor yang menyebabkan terjadinya *stunting* agar dapat mengambil langkah-langkah pencegahan yang efektif.

Di Indonesia, kasus *stunting* terjadi pada balita usia 0-5 tahun berada pada persentase sebesar 19,8% menurut Survei Status Gizi Indonesia (SSGI) [4]. Meskipun telah mengalami penurunan dari tahun sebelumnya yaitu angka 21,5%, hasil ini menunjukkan bahwa target pemerintah Indonesia yaitu menurunkan prevalensi *stunting* sampai 14,4% di tahun 2029 masih belum tercapai [5],

[6]. Kondisi ini menegaskan bahwa stunting masih menjadi permasalahan kesehatan masyarakat yang memerlukan perhatian serius dan pendekatan yang komprehensif. Selain itu, upaya penanganan stunting tidak hanya berfokus pada penurunan angka prevalensi, tetapi juga pada pemahaman faktor-faktor yang memengaruhi terjadinya kondisi tersebut secara lebih mendalam.

Stunting dapat berasal dari faktor-faktor yang sangat kompleks dilihat dari aspek sosial, biologis, maupun lingkungan. Faktor-faktor seperti kurangnya asupan gizi, buruknya sanitasi, serta keterbatasan akses terhadap layanan kesehatan sering kali tidak berdiri sendiri, melainkan memiliki hubungan yang saling memengaruhi satu sama lain [7], [8]. Dalam konteks analisis data, keterkaitan antarvariabel ini berpotensi menimbulkan hubungan yang kuat atau tumpang tindih, sehingga penting untuk dipertimbangkan dalam proses pemodelan. Selain itu, faktor lain seperti tingkat edukasi ibu dan kondisi kehamilan, termasuk kejadian berat badan lahir rendah (BBLR), juga berkontribusi terhadap risiko stunting di kemudian hari [8]. Hal ini dapat mengakibatkan terjadinya *stunting* di kemudian hari. Meskipun berbagai faktor risiko tersebut bersifat umum, intensitas dan dampaknya ternyata sangat bervariasi bergantung pada kondisi geografis dan sosiodemografi masing-masing daerah.

Tingkat *stunting* di Indonesia sendiri dinilai tidak merata di seluruh wilayah. Beberapa provinsi seperti Bali dan DI Yogyakarta menunjukkan angka prevalensi yang relatif rendah, berbanding terbalik dengan provinsi Nusa Tenggara Timur dan Sulawesi Barat yang mencatat angka jauh lebih tinggi [4]. Situasi yang timpang ini menunjukkan adanya variasi faktor determinan yang memengaruhi kejadian *stunting* di tiap daerah, baik dari segi sosial, ekonomi, pendidikan, maupun kondisi lingkungan [9]. Faktor lainnya seperti status gizi ibu, akses terhadap layanan kesehatan, dan sanitasi dasar memiliki kontribusi yang berbeda-beda pada setiap wilayah. Adanya variasi faktor risiko ini mengindikasikan bahwa pendekatan penanganan yang bersifat generalis memiliki keterbatasan

dalam menjangkau akar masalah di tiap daerah, sehingga dibutuhkan landasan data yang spesifik per wilayah untuk mendukung perumusan strategi intervensi yang lebih presisi dan tepat sasaran. Maka dari itu, diperlukan analisis yang lebih mendalam untuk memahami faktor-faktor yang paling berpengaruh untuk situasi *stunting* tiap provinsi.

Mengingat kompleksitas faktor determinan yang memengaruhi kejadian *stunting*, metode analisis statistik konvensional sering kali memiliki keterbatasan dalam menangkap pola hubungan antarvariabel yang rumit. Oleh karena itu, pendekatan komputasi modern berbasis *Machine Learning* kini menjadi alternatif solusi yang krusial untuk memetakan faktor risiko dengan akurasi yang lebih tinggi. Pemanfaatan algoritma cerdas ini memungkinkan pengolahan data dalam skala besar sekaligus mengungkap interaksi non-linear yang sulit dideteksi oleh metode tradisional. Efektivitas pendekatan tersebut telah terbukti secara empiris dalam studi yang berhasil mengidentifikasi determinan utama malnutrisi di negara berkembang dengan performa prediksi yang sangat kompetitif [10].

Penelitian sebelumnya menerapkan algoritma *machine learning* untuk memprediksi *stunting* pada kalangan remaja di Ethiopia dan menunjukkan bahwa pendekatan tersebut mampu menangkap hubungan kompleks antarvariabel [9]. Namun, penelitian ini dilakukan pada kelompok usia dan wilayah tertentu, sehingga konteks penerapannya masih terbatas. Di Indonesia, pendekatan serupa telah mulai dikembangkan, salah satunya oleh Pratama *et al.* (2024) yang membandingkan beberapa algoritma dalam memprediksi prevalensi *stunting* tingkat provinsi dan menemukan bahwa *Random Forest* memberikan performa terbaik [11]. Studi tersebut memberikan gambaran awal mengenai potensi model prediktif dalam analisis *stunting* di Indonesia.

Meskipun studi di Indonesia tersebut telah berhasil membangun model prediksi *stunting*, fokus utamanya masih terbatas pada pencapaian metrik akurasi dan belum mengurai interaksi antarvariabel secara mendalam. Di sisi lain, pemanfaatan algoritma interpretabilitas seperti *SHAP* umumnya masih

berpusat pada studi kasus di luar negeri yang memiliki karakteristik demografi jauh berbeda dari kondisi lokal. Oleh karena itu, riset yang memanfaatkan data nasional terbaru untuk memadukan performa prediksi dengan penjelasan kontribusi fitur (*feature contribution*) secara transparan masih sangat minim. Menjawab *research gap* tersebut, penelitian ini mengusulkan pendekatan yang tidak sekadar berfokus pada hasil akhir dari model *black-box*, tetapi juga mampu membedah arah dan besaran pengaruh setiap variabel determinan secara logis.

Untuk mengatasi keterbatasan tersebut, penelitian ini menggunakan algoritma *Random Forest* yang dikombinasikan dengan metode interpretabilitas SHAP (*SHapley Additive exPlanations*). Pemilihan *Random Forest* tidak hanya didasarkan pada performa prediksi yang telah ditunjukkan pada penelitian sebelumnya, tetapi juga pada kemampuannya dalam menangani hubungan non-linear serta interaksi kompleks antarvariabel yang umum ditemukan pada data kesehatan populasi. Selain itu, model ini relatif stabil terhadap variabel yang saling berkorelasi dan tidak bergantung pada asumsi distribusi tertentu, sehingga sesuai untuk karakteristik data agregat SSGI. Sementara itu, SHAP digunakan untuk menjelaskan kontribusi masing-masing fitur terhadap hasil prediksi model [10]. Melalui pendekatan ini, setiap faktor dapat dinilai apakah ia meningkatkan atau menurunkan kemungkinan terjadinya stunting pada suatu wilayah. Dengan demikian, kombinasi antara *Random Forest* dan SHAP tidak hanya memberikan hasil prediksi yang akurat, tetapi juga penjelasan yang dapat dipahami secara intuitif oleh pengambil keputusan. Pendekatan ini memberikan nilai tambah dalam analisis kebijakan berbasis data, terutama untuk menentukan prioritas intervensi di daerah dengan tingkat *stunting* tinggi.

Menjawab permasalahan tersebut, penelitian ini diarahkan untuk mengidentifikasi faktor-faktor determinan utama yang memengaruhi prevalensi *stunting* antar provinsi di Indonesia menggunakan data SSGI tahun 2024 melalui pendekatan *Random Forest* yang diinterpretasikan dengan SHAP. Penelitian ini berfokus pada dua aspek utama, yaitu menilai performa model dalam

memprediksi tingkat *stunting* serta memahami peran masing-masing variabel terhadap hasil prediksi. Hasil penelitian diharapkan dapat memberikan dasar empiris bagi pemerintah dan pemangku kebijakan dalam merancang strategi intervensi gizi yang lebih efektif dan berbasis bukti ilmiah.

1.2 Rumusan Masalah

Berdasarkan pemaparan latar belakang, dihasilkan rumusan masalah pada penelitian yang akan dijabarkan pada poin berikut:

1. Faktor apa saja yang menjadi determinan utama penyebab *stunting* antar provinsi di Indonesia berdasarkan data SSGI tahun 2024?
2. Bagaimana performa model *Random Forest* dalam memprediksi prevalensi *stunting* antar provinsi di Indonesia?
3. Bagaimana interpretasi SHAP digunakan untuk menjelaskan kontribusi masing-masing faktor terhadap hasil prediksi model *Random Forest*?

1.3 Tujuan Penelitian

Setelah penjabaran rumusan masalah, pada penelitian ini dibuat tujuan penelitian yaitu sebagai berikut:

1. Mengidentifikasi faktor-faktor determinan utama penyebab *stunting* antar provinsi di Indonesia berdasarkan data SSGI tahun 2024.
2. Menganalisis performa model *Random Forest* dalam memprediksi prevalensi *stunting* antar provinsi di Indonesia.
3. Menerapkan interpretasi SHAP untuk menjelaskan kontribusi masing-masing faktor terhadap hasil prediksi model *Random Forest*.

1.4 Batasan Masalah

Agar penelitian tidak terlalu luas dan tidak keluar dari pokok permasalahan, maka ditentukan batasan oleh beberapa poin berikut:

1. Data yang digunakan untuk penelitian ini terbatas pada Survei Status Gizi Indonesia (SSGI) tahun 2024 yang telah dipublikasikan oleh Kementerian

Kesehatan RI. Perlu diketahui bahwa penelitian ini tidak menggunakan data tambahan dari sumber lain. Sehingga penelitian yang dilakukan bukan analisis *time-series* antartahun dan memiliki ruang lingkup spasial terbatas pada 38 provinsi di Indonesia sesuai ketersediaan data.

2. Populasi yang diambil untuk menjadi fokus penelitian ini adalah anak balita usia 0-59 bulan (5 tahun), sesuai dengan sasaran pengukuran prevalensi *stunting* pada SSGI.
3. Variabel yang digunakan untuk penelitian ini mencakup berbagai faktor yang memiliki potensi untuk memengaruhi prevalensi penyebab *stunting*, seperti karakteristik balita, karakteristik ibu, serta kondisi rumah tangga yang meliputi status gizi, pendidikan, ekonomi, dan akses terhadap fasilitas kesehatan, air bersih, serta sanitasi. variabel-variabel ini merupakan sebagian dari indikator yang tersedia dalam dataset SSGI tahun 2024 dan dipilih berdasarkan relevansi terhadap topik penelitian.
4. Analisis yang dilakukan pada penelitian ini difokuskan pada tingkat provinsi di Indonesia, sehingga hasilnya mencerminkan kondisi agregat dan tidak mempertimbangkan variasi di tingkat kabupaten/kota atau individu.
5. Model yang digunakan untuk penelitian ini adalah algoritma *Random Forest* untuk memprediksi prevalensi *stunting*, dengan interpretasi hasil menggunakan metode SHAP (*SHapley Additive exPlanations*) untuk memahami kontribusi setiap variabel terhadap prediksi prevalensi *stunting*.
6. Penelitian ini berfokus pada analisis faktor determinan penyebab *stunting*, bukan pada pengembangan sistem prediksi *stunting* secara *real-time* atau aplikasi praktis lainnya.

1.5 Manfaat Penelitian

Penelitian ini dilaksanakan dengan harapan dapat memberikan manfaat sebagai berikut:

1. Bagi masyarakat, penelitian ini memberikan informasi empiris mengenai faktor determinan utama yang memengaruhi prevalensi *stunting* antarprovinsi di Indonesia. Selain itu, hasil interpretasi model menggunakan SHAP dapat membantu menjelaskan kontribusi masing-masing faktor secara lebih jelas, sehingga dapat digunakan sebagai dasar dalam penyusunan strategi intervensi gizi yang lebih tepat sasaran sesuai karakteristik wilayah.
2. Bagi peneliti, penelitian ini memberikan pemahaman mengenai penerapan model *Random Forest* dalam memprediksi prevalensi *stunting* serta pemanfaatan metode interpretabilitas SHAP untuk menjelaskan hasil prediksi model pada data kesehatan masyarakat.
3. Bagi akademisi, penelitian ini dapat menjadi referensi dalam pengembangan analisis data kesehatan menggunakan pendekatan *machine learning*, khususnya dalam mengintegrasikan model prediktif dengan metode interpretasi untuk menghasilkan analisis yang lebih komprehensif.

1.6 Sistematika Penulisan

Secara keseluruhan, struktur penulisan laporan ini disusun untuk memberikan gambaran umum setiap tahapan penelitian mengenai analisis determinan penyebab *stunting* di provinsi-provinsi di Indonesia. Setiap bab disusun secara sistematis agar pembahasan mengenai penerapan model *Random Forest* dan interpretasi SHAP pada data SSGI tahun 2024 dapat diikuti dengan runtut dan mudah dipahami.

Bab I

Bab I berisi pendahuluan. Pendahuluan menguraikan latar belakang, rumusan masalah, tujuan, manfaat, batasan masalah dan sistematika penulisan dari penelitian.

Bab II

Bab II berisi tinjauan pustaka. Pada bab ini akan dibahas teori-teori mengenai *stunting*, faktor-faktor determinan penyebab *stunting*, Survei Status Gizi Indonesia (SSGI), serta penerapan algoritma *machine learning* khususnya *Random Forest* pada model prediksi risiko *stunting*. Selain itu, bab ini juga membahas hasil penelitian terdahulu yang relevan sebagai landasan konseptual dan pembeda penelitian ini dari studi yang telah dilakukan sebelumnya.

Bab III

Bab ini menjelaskan metode yang akan digunakan dalam penelitian, termasuk sumber dan jenis data, variabel penelitian, tahapan pengolahan data, serta rancangan model analisis menggunakan *Random Forest* dan SHAP. Selain itu, bab ini juga menjelaskan mengenai teknik evaluasi model serta prosedur interpretasi hasil untuk mengidentifikasi faktor determinan utama penyebab *stunting*.

Bab IV

Bab ini menguraikan hasil analisis data, performa model *Random Forest*, hasil interpretasi SHAP, serta pembahasan mengenai faktor-faktor determinan yang memiliki pengaruh prevalensi *stunting* antar provinsi di Indonesia.

Bab V

Bab V berisi Kesimpulan dan saran. Pada bab ini akan diberikan kesimpulan dari hasil penelitian yang menjawab rumusan masalah berdasarkan hasil analisis yang telah dilakukan sebelumnya. Saran-saran juga diberikan sebagai masukan bagi pihak terkait dan peneliti selanjutnya untuk pengembangan kebijakan dan penelitian lanjutan di bidang *stunting*.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Bagian ini memaparkan tinjauan terhadap delapan jurnal utama yang menjadi acuan dan rujukan dalam pelaksanaan penelitian ini. Jurnal-jurnal tersebut memberikan landasan mengenai pemilihan algoritma, penggunaan variabel determinan, serta metode evaluasi model yang diterapkan dalam tugas akhir ini.

1. Pande *et al.* [12] pada tahun 2023 meneliti faktor-faktor penentu pertumbuhan linear anak di India guna memahami penyebab masalah gizi kronis. Studi ini menggunakan pendekatan *multilevel mixed-effect logistic regression* untuk menguji pengaruh variabel dari tingkat individu hingga lingkungan komunitas dengan memanfaatkan data NFHS-5 yang mencakup lebih dari 146 ribu balita. Hasil analisis menunjukkan bahwa prevalensi *stunting* mencapai angka 36%, di mana faktor individu seperti jenis kelamin laki-laki dan berat lahir rendah terbukti meningkatkan risiko secara signifikan. Lingkungan dengan tingkat kemiskinan tinggi meningkatkan kemungkinan *stunting* hingga 68% pada tingkat komunitas, sedangkan komunitas dengan literasi tinggi justru mampu menurunkan risiko tersebut secara efektif. Penelitian ini menjadi referensi yang relevan karena memberikan landasan empiris bahwa variabel sosial-ekonomi dan lingkungan memiliki kontribusi besar terhadap kejadian *stunting*, selaras dengan variabel yang akan dianalisis dalam penelitian ini.
2. Zemariam *et al.* [9] pada tahun 2025 mengkaji kemampuan berbagai algoritma *machine learning* untuk memprediksi status *stunting* serta determinan sosial-ekonominya pada remaja perempuan di Ethiopia. Penelitian ini membandingkan kinerja delapan algoritma berbeda,

termasuk *Random Forest*, dengan menerapkan teknik penyeimbangan data (*SMOTE*) serta seleksi fitur algoritma Boruta untuk menyaring variabel yang paling informatif. Hasil evaluasi menunjukkan bahwa *Random Forest* menjadi model dengan performa terbaik dibandingkan algoritma lainnya, mencatatkan akurasi sebesar 77% dan nilai AUC mencapai 85%. Model ini juga berhasil mengidentifikasi bahwa faktor wilayah, indeks kekayaan rendah, serta minimnya pendidikan formal merupakan prediktor utama kejadian *stunting*. Temuan ini mendukung penelitian ini karena membuktikan efektivitas *Random Forest* dalam menangani data survei kesehatan yang kompleks, serta kemampuannya dalam menyoroti kontribusi variabel sosial-ekonomi terhadap isu gizi secara akurat.

3. Jemil *et al.* [13] pada tahun 2026 bertujuan memprediksi kejadian *severe stunting* serta determinan utamanya pada balita di 12 negara Afrika Timur. Studi ini membandingkan kinerja delapan algoritma klasifikasi dengan menerapkan teknik *SMOTE* untuk penyeimbangan data serta *Stratified 10-Fold Cross-Validation* sebagai metode evaluasi menggunakan data DHS dengan sampel lebih dari 76 ribu anak. Hasil eksperimen menempatkan *Random Forest* sebagai model terbaik dengan akurasi mencapai 87% dan nilai AUC sebesar 0,83. Studi ini berhasil mengungkap bahwa faktor seperti kurangnya ASI eksklusif, status ekonomi rendah, serta sanitasi buruk merupakan pemicu utama risiko *stunting* parah melalui analisis interpretabilitas (SHAP). Referensi ini krusial bagi penelitian ini karena memberikan validasi empiris mengenai keandalan kombinasi *Random Forest* dan metode SHAP dalam membedah faktor risiko malnutrisi secara mendetail.
4. Tamanna *et al.* [10] pada tahun 2025 memanfaatkan data *Bangladesh Demographic and Health Survey* (BDHS) untuk mengevaluasi determinan berbagai bentuk malnutrisi, termasuk *stunting*, *wasting*, dan *underweight*. Studi ini menerapkan algoritma Boruta untuk seleksi fitur sebelum

menguji performa berbagai model *machine learning*, seperti *Random Forest*, *XGBoost*, dan *SVM*, dalam memprediksi status gizi balita. Hasil evaluasi menunjukkan bahwa *Random Forest* mampu memodelkan kondisi malnutrisi secara kompetitif, dengan akurasi prediksi *stunting* mencapai 64,19% dan *wasting* sebesar 76,68%. Penelitian ini juga mengidentifikasi bahwa pendidikan ibu, indeks kekayaan, serta fasilitas sanitasi merupakan prediktor utama status gizi anak melalui analisis nilai SHAP. Temuan ini memperkuat landasan penelitian ini karena membuktikan bahwa *Random Forest* efektif digunakan untuk memodelkan masalah gizi yang kompleks, sekaligus menegaskan peran krusial variabel sosial-ekonomi yang akan menjadi fokus analisis pada tingkat provinsi di Indonesia.

5. Pratama *et al.* [11] pada tahun 2024 membandingkan efektivitas berbagai algoritma *machine learning* untuk memprediksi prevalensi *stunting* tingkat provinsi di Indonesia dalam konteks nasional. Studi ini menguji performa model seperti *SVR*, *GAM*, dan *Random Forest* menggunakan metrik evaluasi regresi dengan memanfaatkan dataset gabungan dari Survei Status Gizi Indonesia (SSGI) tahun 2021–2022 dan data publikasi resmi lainnya. Hasilnya menunjukkan bahwa *Random Forest Regression* memberikan kinerja paling unggul dengan nilai R^2 sebesar 0,703 dan tingkat kesalahan (MAPE) di bawah 10%. Korelasi kuat antara akses sanitasi layak dan kemiskinan terhadap angka prevalensi juga terkonfirmasi dalam penelitian tersebut. Temuan ini menjadi landasan empiris yang krusial bagi penelitian ini, karena membuktikan bahwa *Random Forest* merupakan metode yang tangguh untuk menangani karakteristik data agregat SSGI, sehingga relevan untuk diterapkan kembali pada data terbaru tahun 2024.

Ringkasan sistematis dari seluruh jurnal rujukan ditampilkan pada Tabel 2.1 untuk mempermudah pemetaan posisi penelitian terhadap studi-studi terdahulu. Tabel ini merangkum aspek-aspek kunci yang meliputi judul, metode, serta temuan utama guna memperjelas perbedaan pendekatan dan kontribusi kebaruan

dalam penelitian ini.

Tabel 2.1 Ringkasan Penelitian Terdahulu

No.	Judul & Penulis	Masalah	Metode	Hasil Utama
1.	Pande <i>et al.</i> [12] (2023): <i>Analyzing determinants from both compositional and contextual level impeding desired linear growth of children in Indian context</i>	Identifikasi determinan <i>stunting</i> anak (individu & kontekstual) di India.	<i>Multilevel Mixed-Effect Logistic Regression.</i>	Prevalensi <i>stunting</i> 36%; faktor risiko utama meliputi jenis kelamin laki-laki, BBLR, dan kemiskinan komunitas; literasi tinggi menjadi faktor protektif.
2	Zemariam <i>et al.</i> [9] (2025): <i>Prediction of stunting and its socioeconomic determinants among</i>	Prediksi <i>stunting</i> pada remaja	<i>Random Forest (RF),</i>	RF menjadi model terbaik (Akurasi 77%, AUC 85%).

No.	Judul & Penulis	Masalah	Metode	Hasil Utama
	<i>adolescent girls in Ethiopia using machine learning algorithms</i>	perempuan di Ethiopia beserta faktor sosial-ekonominya.	SMOTE, Boruta.	Faktor dominan: wilayah, indeks kekayaan rendah, dan kurangnya pendidikan.
3.	Jemil <i>et al.</i> [13] (2026): <i>Predicting severe stunting and its determinants among under-five in Eastern African Countries: A machine learning algorithms</i>	Prediksi kejadian <i>severe stunting</i> balita di 12 negara Afrika Timur.	RF, SMOTE, <i>Stratified 10-Fold CV</i> , SHAP.	RF unggul dengan Akurasi 87% dan AUC 0.83. SHAP mengungkap determinan kunci: kurang ASI eksklusif, ekonomi lemah, dan sanitasi buruk.
4	Tamanna <i>et al.</i> [10] (2025): <i>Identifying determinants of malnutrition in under-five children in</i>	Evaluasi determinan malnutrisi	Boruta <i>Feature Selection</i> ,	RF kompetitif dengan akurasi <i>stunting</i> 64,19%

No.	Judul & Penulis	Masalah	Metode	Hasil Utama
	<i>Bangladesh: insights from the BDHS-2022 cross-sectional study</i>	(<i>stunting, wasting</i>) pada balita di Bangladesh.	RF, XGBoost.	dan <i>wasting</i> 76,68%. Determinan utama: pendidikan ibu, kekayaan, dan sanitasi.
5.	Pratama <i>et al.</i> [11] (2024): <i>Comparison of Machine Learning Algorithms for Predicting Stunting Prevalence in Indonesia</i>	Prediksi prevalensi <i>stunting</i> tingkat provinsi di Indonesia (Data SSGI).	<i>Random Forest Regression</i> , SVR, GAM.	<i>RF Regression</i> terbaik ($R^2 = 0,703$, MAPE $\leq 10\%$). Menunjukkan korelasi kuat antara sanitasi layak dan kemiskinan terhadap prevalensi.

2.2 Dasar Teori

Sebelum dilakukannya sebuah penelitian, diperlukan adanya dasar teori yang memiliki kaitan erat dengan topik penelitian. Teori yang diterapkan untuk penelitian harus berupa data atau informasi yang bersifat fakta disertai dengan referensi informasi dari media seperti jurnal, buku, penelitian, dan informasi dari sumber yang dapat dipertanggungjawabkan.

2.2.1 *Stunting*

Stunting merupakan kondisi kegagalan pertumbuhan pada anak akibat kekurangan gizi kronis serta infeksi berulang dalam jangka waktu lama [14]. Secara teknis, kondisi ini diukur menggunakan indeks Tinggi Badan menurut

Umur (TB/U) dengan ambang batas nilai $Z\text{-score} < -2\sigma$ (Standar Deviasi) yang dihitung dari perkalian rata-rata populasi dan koefisien variasi [15], [16]. Penentuan status *stunting* melalui perhitungan $Z\text{-score}$ secara matematis dinyatakan sebagai berikut:

$$Z = \frac{y - M}{M \times S}$$

(Rumus 2.1)

Keterangan:

- Z : Nilai $z\text{-score}$ yang dihasilkan untuk menentukan status gizi.
- y : Nilai hasil pengukuran riil (panjang badan atau tinggi badan anak).
- M : Nilai *Median* referensi populasi untuk umur dan jenis kelamin tertentu.
- S : Nilai *Coefficient of Variation* (koefisien variasi) populasi untuk umur & jenis kelamin tertentu.

Kondisi ini memiliki dampak jangka pendek berupa penurunan daya tahan tubuh, serta dampak jangka panjang yang menghambat perkembangan kognitif anak [14]. Hal tersebut menjadikannya sebagai masalah multidimensi yang dipengaruhi oleh interaksi kompleks antara pola asuh, nutrisi, hingga faktor lingkungan. Karakteristik data yang dipengaruhi oleh variabel lintas sektor ini memerlukan pendekatan komputasi untuk mengidentifikasi pola determinan secara lebih akurat. Melalui pemodelan yang tepat, hubungan antar-variabel ini dapat diinterpretasikan untuk mendukung strategi intervensi yang lebih efektif di tingkat wilayah.

2.2.2 Determinan *Stunting*

Determinan *stunting* merupakan sekumpulan faktor risiko yang secara langsung maupun tidak langsung memengaruhi kegagalan pertumbuhan pada anak [17]. Faktor-faktor ini saling berinteraksi mulai dari tingkat asupan nutrisi individu hingga kondisi lingkungan tempat tinggal. Penentuan variabel determinan dalam penelitian ini merujuk pada kerangka konseptual yang

ditetapkan oleh *World Health Organization* (WHO), yang membagi faktor risiko menjadi tingkat konteks sosial, politik, serta faktor rumah tangga dan lingkungan [17]. Visualisasi kerangka faktor risiko tersebut disajikan pada Gambar 2.1 untuk memberikan gambaran menyeluruh mengenai hierarki penyebabnya.



Gambar 2.1 Kerangka Konseptual Faktor Penyebab *Stunting* [17]

Indikator kesehatan ibu dan anak menjadi variabel utama yang diukur melalui cakupan layanan kesehatan di suatu provinsi. Hal ini mencakup variabel seperti prevalensi ibu hamil risiko tinggi, cakupan pemberian ASI eksklusif, hingga pemenuhan imunisasi dasar lengkap [4]. Merujuk pada Gambar 2.1, variabel-variabel tersebut merepresentasikan kualitas pengasuhan dan asupan

yang merupakan faktor penyebab langsung di tingkat populasi. Tinggi rendahnya capaian indikator ini mencerminkan sejauh mana perlindungan kesehatan dasar telah terimplementasi secara merata di suatu wilayah.

Variabel sosial ekonomi dan lingkungan yang direpresentasikan melalui indikator makro juga memberikan kontribusi besar terhadap fluktuasi angka *stunting*. Akses terhadap infrastruktur dasar, seperti air minum aman dan sanitasi layak, serta tingkat kemiskinan wilayah menjadi variabel kunci dalam dimensi ini [11], [14]. Faktor-faktor tersebut bertindak sebagai determinan dasar yang memengaruhi kemampuan masyarakat dalam mengelola sumber daya kesehatan secara kolektif. Identifikasi terhadap seluruh variabel risiko ini diperlukan sebagai landasan dalam tahap pemilihan fitur (*feature selection*) pada pemodelan regresi.

2.2.3 Survei Status Gizi Indonesia (SSGI)

Survei Status Gizi Indonesia (SSGI) merupakan instrumen nasional utama yang digunakan oleh pemerintah untuk memantau status gizi balita secara berkala [4]. Survei ini bertujuan untuk menyediakan data prevalensi *stunting* yang akurat dan representatif dari tingkat nasional hingga kabupaten/kota [4]. Dalam penelitian ini, laporan resmi SSGI digunakan sebagai sumber primer untuk mengekstraksi variabel target dan prediktor pada skala provinsi. Penggunaan publikasi resmi ini menjamin bahwa basis analisis yang digunakan telah melalui proses validasi teknis oleh lembaga berwenang sebelum digunakan sebagai masukan model.

Indikator yang dikumpulkan dalam SSGI mencakup intervensi gizi spesifik dan intervensi gizi sensitif yang disajikan dalam bentuk proporsi populasi [4]. Indikator spesifik meliputi layanan kesehatan langsung, sedangkan indikator sensitif mencakup faktor pendukung seperti kualitas lingkungan dan sanitasi [4]. Metodologi perolehan datanya dilakukan melalui pengukuran antropometri yang terstandarisasi guna menghasilkan estimasi angka yang konsisten antarwilayah.

Proses standardisasi ini penting untuk meminimalisir bias pengukuran yang mungkin terjadi saat pengambilan sampel di lapangan secara masif.

Data hasil SSGI memiliki karakteristik nilai kontinu dalam rentang 0–100 persen yang merepresentasikan capaian makro di 38 provinsi di Indonesia [4]. Struktur data berbasis persentase ini memastikan konsistensi satuan pengukuran di seluruh variabel, sehingga mempermudah proses komputasi tanpa terkendala perbedaan skala. Karakteristik data agregat ini memberikan perspektif populasi yang luas untuk mendukung analisis kebijakan di tingkat daerah. Format data numerik yang seragam tersebut selanjutnya akan diproses menggunakan algoritma pembelajaran mesin untuk melakukan estimasi prevalensi.

2.2.4 Machine Learning

Machine Learning merupakan cabang dari kecerdasan buatan yang memungkinkan sistem untuk mempelajari pola secara mandiri dari kumpulan data tanpa melalui pemrograman instruksi secara eksplisit [18]. Teknologi ini bekerja dengan membangun model statistik yang mampu mengenali tren tersembunyi guna melakukan generalisasi pada data baru. Di bidang kesehatan, pendekatan ini sangat berguna untuk menganalisis hubungan antar variabel yang kompleks dan sering kali bersifat non-linear. Penggunaan algoritma ini berpotensi menghasilkan estimasi yang lebih adaptif terhadap kompleksitas data dibandingkan dengan pendekatan statistik tradisional [18].

Prinsip kerja yang paling relevan dalam pemetaan faktor kesehatan adalah *supervised learning*, di mana model dilatih menggunakan pasangan data masukan dan target yang sudah diketahui nilainya [18]. Melalui proses pelatihan ini, algoritma akan mencoba menemukan fungsi pemetaan paling optimal untuk meminimalkan kesalahan prediksi. Pendekatan ini secara khusus dapat diterapkan dalam bentuk regresi jika variabel yang diprediksi berupa nilai kontinu, seperti angka prevalensi *stunting* di tingkat provinsi. Pemodelan ini menjadi dasar teknis sebelum melakukan implementasi algoritma yang lebih

spesifik guna mendapatkan performa prediksi yang stabil dan akurat.

2.2.5 *Supervised Learning*

Supervised learning adalah kategori dalam pembelajaran mesin yang beroperasi menggunakan pasangan data masukan dan target yang telah memiliki label atau nilai kebenaran sebelumnya [18]. Dalam mekanismenya, algoritma akan mempelajari fungsi pemetaan antara fitur masukan (*input*) dan variabel target (*output*) untuk meminimalkan selisih kesalahan prediksi. Peran fitur dalam proses ini sangat krusial, karena kualitas informasi yang dikandung oleh fitur akan menentukan kemampuan model dalam mengenali karakteristik unik dari data [18]. Tujuan akhir dari model ini adalah untuk memprediksi label atau nilai pada data baru dengan tingkat akurasi yang optimal berdasarkan pengalaman pelatihan. Berdasarkan tipe variabel targetnya, *supervised learning* dapat diklasifikasikan lebih spesifik menjadi tugas klasifikasi atau tugas regresi.

2.2.5.1 **Regresi**

Pendekatan regresi dalam *machine learning* digunakan secara khusus untuk menangani permasalahan di mana variabel target yang diprediksi merupakan nilai kontinu atau numerik [18]. Berbeda dengan klasifikasi yang mengelompokkan data ke dalam kategori diskrit, regresi berfokus pada estimasi hubungan kuantitatif antar variabel untuk menghasilkan keluaran dalam rentang angka tertentu. Ilustrasi dasar dari hubungan ini dapat digambarkan melalui persamaan regresi linear sederhana sebagai berikut:


$$y = \beta_0 + \beta_1 x + \epsilon$$

(Rumus 2.2)

Di mana y adalah variabel target, x adalah fitur masukan, β adalah koefisien model, dan ϵ merupakan *error* [19]. Penggunaan metode regresi ini memungkinkan peneliti untuk memodelkan fenomena numerik seperti angka prevalensi dengan tingkat presisi yang terukur.

2.2.6 Random Forest Regression

Random Forest Regression merupakan algoritma *ensemble learning* yang bekerja dengan membangun sekumpulan pohon keputusan (*decision trees*) secara independen selama tahap pelatihan [20]. Algoritma ini menerapkan mekanisme *bootstrap aggregating (bagging)* dan seleksi fitur acak untuk menciptakan variasi antar pohon guna meningkatkan stabilitas model. Perbedaan utama *Random Forest* untuk regresi dibandingkan klasifikasi terletak pada *output* akhirnya yang merupakan nilai rata-rata dari seluruh prediksi pohon [21]. Struktur model ini dapat diilustrasikan sebagai berikut:



Gambar 2.2 Struktur Umum *Random Forest Regression* [22]

Secara matematis, hasil prediksi akhir ($\hat{y}$) dari total K pohon keputusan dapat dirumuskan sebagai:

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K f_k(x)$$

(Rumus 2.3)

Nilai prediksi akhir $\hat{y}$ diperoleh dengan menghitung rata-rata aritmatika dari luaran fungsi $f_k(x)$ yang dihasilkan oleh K buah pohon keputusan yang dibangun secara independen dalam *ensemble* [20], [21]. Model ini dikenal tangguh dalam menangani data non-linear dan memiliki ketahanan terhadap *outlier* di dalam dataset [20]. Setelah model berhasil dibangun dan melakukan prediksi, kinerjanya harus diukur secara objektif melalui evaluasi model regresi.

2.2.7 Feature Selection

Feature selection merupakan proses pemilihan variabel yang paling relevan untuk digunakan dalam pembangunan model prediktif guna mengurangi kompleksitas data, meningkatkan efisiensi komputasi, serta membantu model mempelajari pola yang lebih representatif tanpa terganggu oleh variabel yang redundan [19]. Secara umum, proses seleksi fitur dimulai dari identifikasi seluruh kandidat variabel, dilanjutkan dengan peninjauan relevansi berdasarkan hubungan teoritis maupun keterkaitan statistik terhadap variabel target, serta penyederhanaan variabel yang memiliki informasi tumpang tindih agar tidak menimbulkan bias dalam pembelajaran model [18], [21]. Tahapan ini bertujuan untuk memastikan bahwa setiap variabel yang digunakan memiliki keterkaitan yang logis dengan kondisi kesehatan masyarakat, sehingga model yang dibangun mampu memberikan gambaran yang sesuai dengan realitas di lapangan. Selain itu, kualitas data seperti konsistensi satuan, kelengkapan nilai, dan potensi korelasi tinggi antar fitur juga diperiksa untuk menghindari redundansi informasi. Himpunan variabel terpilih yang telah dinyatakan relevan selanjutnya perlu disesuaikan bentuk dan skalanya melalui tahap transformasi data agar siap digunakan dalam proses pemodelan.

2.2.8 Transformasi Data

Transformasi data merupakan prosedur modifikasi nilai data asli ke dalam format tertentu guna meningkatkan performa algoritma pembelajaran mesin [21]. Proses ini mencakup pembersihan data dari nilai pencilan (*outliers*) guna menjamin distribusi data yang lebih stabil hingga rekayasa fitur melalui pembentukan variabel baru agar lebih representatif. Dalam analisis data kesehatan, transformasi sering kali diperlukan untuk memastikan bahwa variabel yang digunakan memiliki keterkaitan konseptual yang kuat terhadap fenomena yang diteliti [21], [23]. Keberhasilan transformasi akan menentukan kualitas representasi informasi yang kemudian dapat diproses lebih lanjut untuk menghasilkan model yang akurat. Setelah data ditransformasi, informasi tersebut dapat digunakan sebagai dasar dalam melakukan interpretasi hasil pada tahap analisis selanjutnya.

2.2.9 Agregasi Data

Agregasi data adalah proses pengumpulan dan perangkuman data dari tingkat individu menjadi format kelompok atau unit yang lebih besar, seperti wilayah administratif [19]. Dalam konteks spasial, agregasi memungkinkan peneliti untuk melihat representasi makro dari suatu populasi yang sering kali lebih stabil dan bermakna untuk kebijakan publik dibandingkan data individu yang fluktuatif. Meskipun memberikan keunggulan dalam penyederhanaan informasi, agregasi memiliki keterbatasan berupa hilangnya variasi detail di tingkat mikro [18]. Namun, penggunaan data agregat efektif untuk memetakan determinan kesehatan masyarakat pada lingkup wilayah seperti provinsi. Data agregat yang telah tersusun rapi ini kemudian siap digunakan sebagai masukan bagi algoritma *Random Forest Regression*.

2.2.10 Metrik Evaluasi Regresi

Evaluasi model regresi bertujuan untuk mengukur sejauh mana prediksi yang dihasilkan oleh model mendekati nilai aktual dari data observasi [18]. Proses ini dilakukan untuk mengetahui tingkat presisi model dalam memberikan estimasi angka prevalensi berdasarkan variabel-variabel indikator yang digunakan. Terdapat beberapa metrik statistik utama yang umum digunakan dalam mengevaluasi performa tersebut, antara lain *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), *Mean Absolute Percentage Error* (MAPE), serta Koefisien Determinasi (R^2). Masing-masing metrik memberikan perspektif berbeda mengenai besaran kesalahan dan kualitas kecocokan model terhadap variasi data yang tersedia [19]. Berikut adalah penjabaran dari metrik-metrik statistik yang digunakan:

1. *Mean Absolute Error* (MAE) MAE mengukur rata-rata selisih absolut antara nilai aktual dengan nilai prediksi tanpa memperhatikan arah kesalahannya [21].

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

(Rumus 2.4)

Pada rumus tersebut, n adalah jumlah data, y_i merupakan nilai aktual, dan $\hat{y}_i$ adalah nilai hasil prediksi model.

2. *Root Mean Square Error* (RMSE) RMSE memberikan bobot lebih besar pada kesalahan yang besar dengan cara mengkuadratkan selisih sebelum dirata-ratakan dan diakarkan [11].

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

(Rumus 2.5)

Keterangan simbol pada rumus ini adalah n sebagai jumlah sampel, y_i sebagai nilai observasi asli, dan $\hat{y}_i$ sebagai estimasi nilai dari model.

3. *Mean Absolute Percentage Error* (MAPE) MAPE menunjukkan besarnya kesalahan prediksi dalam bentuk persentase relatif terhadap nilai aktualnya

[24].

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

(Rumus 2.6)

Variabel y_i melambangkan data aktual, $\hat{y}_i$ adalah data prediksi, dan n menunjukkan total observasi yang dihitung.

4. Koefisien Determinasi (R^2) R^2 mengukur seberapa besar proporsi varians pada variabel dependen yang dapat dijelaskan oleh variabel independen dalam model [25].

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

(Rumus 2.7)

Simbol y_i adalah nilai aktual, $\hat{y}_i$ adalah nilai prediksi, dan $\bar{y}$ merupakan nilai rata-rata dari seluruh data aktual.


Pemilihan metrik yang tepat sangat menentukan interpretasi peneliti terhadap akurasi model yang dikembangkan. Untuk menjamin bahwa nilai evaluasi tersebut tidak bersifat bias, diperlukan prosedur validasi yang ketat melalui *cross validation*.

2.2.11 Cross Validation

Cross validation merupakan teknik validasi model yang bertujuan untuk menilai kemampuan generalisasi model pada dataset yang independen [21]. Prosedur ini dilakukan dengan membagi data menjadi bagian latih (*training set*) dan bagian uji (*testing set*) secara berulang dengan skema tertentu. Tujuan utamanya adalah untuk mengurangi bias evaluasi yang mungkin muncul jika model hanya diuji pada satu bagian data acak saja [19]. Melalui proses ini, peneliti dapat memperoleh estimasi performa model yang lebih stabil dan objektif. Salah satu varian dari teknik ini yang intensif dan sistematis adalah *Leave-One-Out Cross Validation* (LOOCV).

2.2.12 *Leave-One-Out Cross Validation (LOOCV)*

Leave-One-Out Cross Validation (LOOCV) merupakan bentuk ekstrem dari *K-Fold Cross Validation* di mana jumlah lipatan (*fold*) sama dengan jumlah total sampel data (N) [19]. Dalam setiap iterasinya, satu sampel digunakan sebagai data uji sementara $N - 1$ sampel lainnya digunakan sebagai data latih, dan proses ini diulang sebanyak N kali. Skema ini cocok digunakan untuk dataset dengan jumlah sampel yang kecil karena mampu memaksimalkan penggunaan data untuk pelatihan model [19]. Kelebihan utamanya adalah menghasilkan estimasi yang hampir tidak bias, meskipun membutuhkan biaya komputasi yang lebih tinggi jika jumlah data meningkat. Mekanisme perulangan pada skema evaluasi ini dapat dilihat secara visual pada Gambar 2.3.



Gambar 2.3 Skema Partisi Data pada LOOCV [25]

Berdasarkan Gambar 2.3, pada setiap baris iterasi, blok berwarna biru merepresentasikan himpunan data latih (*training set*) yang berjumlah $N - 1$ sampel. Sementara itu, satu blok kecil berwarna jingga menunjukkan sampel tunggal yang dialokasikan sebagai data uji (*testing set*). Posisi blok jingga ini akan terus bergeser secara berurutan pada setiap iterasi ke bawah, sehingga menjamin bahwa seluruh N sampel tepat satu kali mendapat giliran untuk dievaluasi.

Ketangguhan skema evaluasi LOOCV ini tidak hanya berlaku pada data tabular standar, tetapi juga telah diakui keandalannya dalam studi pemodelan

observasi yang memuat unsur kewilayahan atau spasial, sebagaimana dibuktikan oleh Irisson *et al.* (2022) [26]. Dalam studinya, mereka mengimplementasikan skema *leave-one-out* untuk mengevaluasi model prediktif pada dataset observasi kelautan yang tersebar di berbagai lokasi geografis dengan jumlah sampel yang sangat terbatas. Pendekatan tersebut terbukti secara efektif mampu mencegah *overfitting* dan meminimalkan bias estimasi pada data berskala regional. Karakteristik tantangan spasial tersebut relevan dengan pemodelan pada penelitian ini. Oleh karena itu, penerapan LOOCV pada agregasi data 38 provinsi di Indonesia dinilai sebagai pendekatan yang paling optimal untuk memastikan bahwa setiap unit wilayah mendapatkan kesempatan yang sama untuk diuji secara adil, tanpa khawatir model akan kekurangan proporsi data latih.

Meskipun model telah tervalidasi dengan baik, kompleksitas algoritma *ensemble* sering kali menciptakan hambatan dalam memahami alasan di balik sebuah prediksi, yang dikenal sebagai masalah *black-box*.

2.2.13 Interpretabilitas Model

Interpretabilitas model merujuk pada sejauh mana manusia dapat memahami alasan dan proses pengambilan keputusan di balik keluaran sebuah algoritma [27]. Masalah *black-box* sering kali ditemukan pada algoritma kompleks seperti *Random Forest*, di mana hubungan antar variabel sulit dijelaskan secara intuitif. Di bidang kesehatan, interpretasi menjadi aspek yang sangat krusial karena pembuat kebijakan perlu mengetahui variabel apa yang paling memengaruhi suatu kondisi [28]. Penjelasan model dapat dibagi menjadi *global explanation* untuk tren populasi secara menyeluruh dan *local explanation* untuk kasus spesifik. Untuk menjembatani kebutuhan interpretasi pada model kompleks tersebut, metode SHAP menjadi salah satu solusi yang paling banyak digunakan.

2.2.14 SHAP (*SHapley Additive exPlanations*)

SHAP (*SHapley Additive exPlanations*) merupakan metode interpretasi model yang didasarkan pada teori permainan kooperatif (*cooperative game theory*) untuk menjelaskan kontribusi setiap fitur terhadap prediksi tertentu [29]. Secara konseptual, metode ini mengibaratkan model prediksi sebagai sebuah "permainan", dan variabel-variabel determinan yang digunakan adalah "pemain" yang bekerja sama. Nilai Shapley kemudian menghitung seberapa besar kontribusi rata-rata atau "andil" masing-masing variabel terhadap hasil akhir prediksi, dengan mempertimbangkan semua kemungkinan kombinasi fitur yang ada. Pendekatan ini memastikan distribusi atribusi yang adil, sehingga peneliti dapat memahami arah dan kekuatan pengaruh setiap variabel secara intuitif [29].


Keunggulan utama SHAP terletak pada konsistensi teoritisnya serta kemampuannya untuk memberikan visualisasi yang jelas, baik untuk menjelaskan pola secara keseluruhan (global) maupun kasus spesifik per wilayah (lokal). Keandalan SHAP dalam membuka "kotak hitam" (*black box*) model *machine learning* telah divalidasi secara luas lintas disiplin ilmu. Selain di sektor kesehatan, fleksibilitas metode ini juga telah terbukti tangguh dalam membedah data berdimensi tinggi di bidang lain, seperti analisis risiko pada asuransi medis [30]. Keberhasilan implementasi di berbagai domain kompleks tersebut menegaskan bahwa nilai Shapley merupakan standar yang andal untuk mengukur kontribusi variabel. Melalui penerapan metode ini, hasil prediksi prevalensi *stunting* tidak hanya menjadi sekadar angka, tetapi juga memberikan wawasan presisi mengenai faktor determinan utama di tiap wilayah.

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini dirancang untuk menganalisis faktor-faktor determinan penyebab *stunting* pada tingkat provinsi di Indonesia dengan memanfaatkan data sekunder *Annual Report* SSGI tahun 2024. Pendekatan yang digunakan mengombinasikan pemodelan *machine Learning* regresi menggunakan *Random Forest* dan metode interpretasi model SHAP. Model ini dibangun menggunakan dataset agregat tingkat provinsi yang memuat berbagai indikator status gizi balita serta faktor determinan yang mencakup aspek kesehatan ibu dan anak, pola asuh, layanan kesehatan, penyakit, perlindungan sosial, dan kondisi sanitasi. Penelitian ini bertujuan untuk mengidentifikasi faktor determinan utama yang berkontribusi terhadap tingginya prevalensi *stunting* antar provinsi, serta memberikan pemahaman yang bersifat interpretatif sebagai dasar perumusan kebijakan dan intervensi gizi yang lebih tepat sasaran. Secara garis besar, tahapan penelitian digambarkan dalam diagram alir (*flowchart*) pada Gambar 3.1.



Gambar 3.1 Diagram Alir Penelitian

Berdasarkan Gambar 3.1, alur penelitian disusun secara sistematis yang diawali dengan tahap identifikasi masalah mengenai urgensi penanganan *stunting* di Indonesia dan kompleksitas faktor determinan yang mempengaruhinya di tingkat provinsi. Tahap ini didukung oleh studi literatur mendalam untuk memahami variabel-variabel determinan multidimensi yang mencakup berbagai aspek, serta metode pengolahan data dan pemodelan *machine learning* yang relevan. Berlandaskan pemahaman tersebut, selanjutnya dilakukan pengumpulan dataset yang bersumber dari Laporan Tahunan SSGI tahun 2024. Laporan Tahunan SSGI 2024 kemudian digunakan untuk menyiapkan dataset agregat tingkat provinsi yang memuat variabel target (prevalensi *stunting*) dan variabel fitur (faktor determinan). Data mentah yang diperoleh selanjutnya diproses melalui tahapan pra-pemrosesan data yang meliputi pembersihan data, penyaringan data, dan pemisahan variabel target dan fitur.

Setelah data siap, tahap berikutnya adalah pembangunan model regresi menggunakan algoritma *Random Forest*. Proses ini mencakup penentuan parameter terbaik melalui *Grid Search* dan validasi silang (*Cross Validation*) untuk memastikan performa model yang optimal. Model yang telah dilatih kemudian dievaluasi kinerjanya menggunakan metrik statistik seperti MAE, RMSE, MAPE, serta koefisien determinasi (R^2 Score). Langkah terakhir adalah menginterpretasikan hasil prediksi model *Random Forest* menggunakan SHAP untuk mengetahui kontribusi setiap fitur determinan terhadap angka *stunting*, baik secara global skala nasional maupun lokal per provinsi.


3.2 Langkah Penelitian

Tahapan penelitian disusun secara sistematis untuk menjawab rumusan masalah yang telah ditetapkan. Secara garis besar, alur penelitian terdiri dari identifikasi masalah, studi literatur, penyiapan data, pra-pemrosesan, pembangunan model, hingga evaluasi dan interpretasi hasil. Penjelasan rinci mengenai masing-masing tahapan diuraikan sebagai berikut.

3.2.1 Persiapan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang bersumber dari Laporan Publikasi SSGI tahun 2024 yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia [4]. Laporan ini disajikan dalam bentuk dokumen PDF dan memuat informasi statistik yang komprehensif, mencakup ± 5.189 tabel statistik yang menggambarkan indikator kesehatan ibu dan anak, pola asuh, akses pelayanan kesehatan, kondisi sanitasi dan lingkungan, serta karakteristik demografi rumah tangga. Secara spesifik, populasi target dalam survei ini difokuskan pada rumah tangga kelompok balita usia 0-59 bulan, dengan data yang disajikan menggunakan pendekatan *cross-sectional* untuk menggambarkan kondisi kesehatan pada satu titik waktu tertentu. Seluruh informasi statistik tersebut disajikan dalam bentuk numerik atau persentase yang merepresentasikan prevalensi kejadian di wilayah terkait.

Informasi dalam laporan SSGI 2024 disajikan dalam berbagai tingkat agregasi wilayah, mulai dari data nasional, provinsi, hingga rincian kabupaten/kota. Dari berbagai tingkatan tersebut, penelitian ini membatasi unit analisis pada skala provinsi guna menganalisis variabilitas determinan *stunting* antarwilayah secara makro. Namun, kompleksitas struktur data ini menyebabkan data tidak dapat langsung digunakan sebagai *dataset* penelitian kuantitatif tanpa melalui proses penyiapan data terlebih dahulu. Oleh karena itu, diperlukan suatu tahapan penyiapan data untuk mengekstraksi, menyeleksi, dan menyusun kembali informasi yang relevan agar diperoleh *dataset* terstruktur yang sesuai dengan tujuan penelitian. Alur penyiapan data yang dilakukan dalam penelitian ini ditunjukkan pada Gambar 3.2.



Gambar 3.2 Alur Penyiapan Data

Alur penyiapan data pada Gambar 3.2 menggambarkan tahapan yang dilakukan untuk mengonversi data mentah SSGI 2024 dalam bentuk PDF menjadi *dataset* terstruktur yang siap digunakan pada tahap pra-pemrosesan dan pemodelan. Penjelasan lebih lanjut mengenai masing-masing tahapan penyiapan data diuraikan sebagai berikut:

3.2.1.1 Ekstraksi Data

Tahap pertama difokuskan pada pengumpulan data mentah dari laporan SSGI 2024 yang tersedia dalam bentuk dokumen PDF dengan ribuan tabel statistik yang kompleks. Mengingat data tersebar dalam berbagai sub-bab laporan, dilakukan identifikasi manual terlebih dahulu untuk memetakan nomor halaman tabel yang memuat indikator determinan *stunting* dan prevalensi gizi balita. Informasi dari tabel-tabel tersebut kemudian diekstraksi dan dikonversi dari bentuk dokumen statis menjadi lembar kerja digital (*spreadsheet*) yang lebih fleksibel. Proses ekstraksi data ini tidak dilakukan secara otomatisasi penuh melainkan melalui pendekatan ekstraksi selektif. Tabel-tabel yang memuat variabel determinan *stunting* untuk skala provinsi dipilah secara terpisah dan dikonversi ke dalam format *spreadsheet* menggunakan fitur Power Query pada Microsoft Excel yang memungkinkan penyeleksian dan transformasi tabel dari dokumen statis secara presisi. Karena data asli menggunakan pendekatan *cross-sectional* dengan banyak kategori, proses ekstraksi dilakukan dengan memastikan angka persentase yang diambil sesuai dengan label baris dan kolom

yang benar.

Pada tahap ini juga ditetapkan skala analisis yang digunakan dalam penelitian, yaitu skala provinsi sebagai representasi kondisi nasional. Pemilihan skala provinsi dilakukan dengan mempertimbangkan tujuan penelitian yang berfokus pada pemetaan faktor determinan *stunting* secara makro. Berdasarkan keputusan tersebut, seluruh tabel yang dianalisis dibatasi pada tabel tingkat provinsi yang tersedia dalam laporan SSGI 2024.

3.2.1.2 Seleksi Fitur Determinan

Tahap seleksi fitur dilakukan untuk menentukan variabel determinan *stunting* yang relevan dari 100 tabel tingkat provinsi hasil ekstraksi data SSGI 2024. Proses seleksi ini mempertimbangkan kesesuaian variabel dengan tujuan penelitian, keterwakilan indikator determinan, serta potensi redundansi informasi antar tabel. Variabel yang bersifat terlalu rinci, deskriptif kategori, atau tidak lagi informatif pada tingkat agregasi provinsi dieliminasi dan, apabila memungkinkan, direpresentasikan melalui variabel status atau skor risiko komposit.

Pendekatan seleksi ini diterapkan untuk menyesuaikan karakteristik data dengan tingkat analisis penelitian, yaitu pada level provinsi, sehingga kompleksitas yang tidak diperlukan dapat dikurangi tanpa menghilangkan makna substantif indikator. Berdasarkan proses tersebut, sebanyak 71 tabel dipertahankan dan digunakan sebagai dasar pembentukan fitur penelitian. Hasil seleksi ini menghasilkan *dataset* yang lebih ringkas, informatif, dan relevan dalam mengidentifikasi faktor-faktor determinan *stunting* antarprovinsi.

3.2.1.3 Transformasi dan Agregasi Data

Setelah melalui proses seleksi tabel, langkah selanjutnya adalah transformasi data untuk memastikan setiap variabel yang terbentuk memiliki representasi informasi yang kuat terhadap risiko *stunting*. Pada tahap ini, tidak semua informasi dari tabel mentah digunakan secara langsung; sebaliknya,

dilakukan peninjauan ulang untuk menetapkan satu indikator yang paling representatif dari setiap tabel. Untuk tabel yang hanya memuat indikator tunggal, nilai persentase diadopsi langsung sebagai fitur numerik. Namun, pada tabel yang memiliki kategori majemuk, dilakukan strategi transformasi khusus dengan memilih indikator yang mencerminkan risiko tertinggi atau melakukan penggabungan kategori agar menghasilkan variabel baru yang lebih ringkas dan substantif.

Selanjutnya, proses agregasi dilakukan untuk menyederhanakan struktur data sehingga seluruh variabel memiliki skala yang seragam dan mudah dibandingkan antar provinsi. Pada tabel yang memiliki lebih dari satu kategori indikator, proses agregasi dilakukan melalui pendekatan penggabungan indikator berbasis risiko. Sebagai contoh, pada tabel usia kehamilan ibu yang terdiri dari kategori usia <21 tahun, 21–39 tahun, dan >40 tahun, hanya kategori yang merepresentasikan kondisi berisiko yang dipertahankan. Nilai persentase ibu dengan usia kehamilan <20 tahun dan >35 tahun dijumlahkan untuk membentuk satu variabel baru yang merepresentasikan proporsi kehamilan berisiko pada usia ekstrem. Secara matematis, proses ini dapat dinyatakan sebagai berikut:


$$X_{\text{risiko usia kehamilan}} = X_{<20} + X_{>35}$$

Di mana $X_{<20}$ adalah persentase kehamilan usia di bawah 20 tahun dan $X_{>35}$ adalah persentase kehamilan usia di atas 35 tahun. Pendekatan serupa diterapkan pada tabel lain yang memiliki kategori majemuk, dengan prinsip utama mempertahankan indikator yang memiliki relevansi risiko terhadap kejadian *stunting* serta menghindari redundansi informasi antarvariabel. Seluruh variabel direpresentasikan dalam bentuk persentase guna menjaga konsistensi satuan data dan memudahkan proses pemodelan. Hasil dari tahap ini adalah *dataset* terstruktur berbasis provinsi yang siap digunakan sebagai input pada tahapan analisis selanjutnya.

3.2.2 Pra-pemrosesan Data

Setelah proses penyiapan dan pembentukan *dataset* terstruktur selesai dilakukan, tahap selanjutnya adalah pra-pemrosesan data. Tahapan ini bertujuan untuk memastikan bahwa data yang digunakan sebagai input model memiliki kualitas yang baik, konsisten, dan layak secara statistik sebelum masuk ke proses pemodelan *machine learning*. Mengingat *dataset* disusun dari hasil ekstraksi dan transformasi data sekunder, terdapat potensi munculnya permasalahan seperti nilai kosong atau ketidakkonsistenan format.

Alur pra-pemrosesan data ditunjukkan pada Gambar 3.3. Proses ini diawali dengan pemuatan *dataset* ke dalam lingkungan komputasi serta pemeriksaan struktur dan konsistensi data. Selanjutnya dilakukan *Exploratory Data Analysis* (EDA) untuk memperoleh gambaran umum karakteristik data. Tahap akhir pra-pemrosesan mencakup eliminasi variabel non-determinan serta penetapan prevalensi *stunting* sebagai variabel target (*y*) dan indikator determinan sebagai variabel prediktor (*X*).



Gambar 3.3 Alur Pra-pemrosesan Data

3.2.2.1 Representasi Dataset Penelitian

Dataset yang digunakan dalam penelitian ini bersumber dari Laporan Publikasi SSGI tahun 2024 yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia [4]. Data tersebut merupakan data sekunder berskala nasional yang menyajikan berbagai indikator status gizi, kesehatan ibu dan anak,

serta kondisi lingkungan dan sosial ekonomi pada tingkat provinsi. Setelah melalui tahap penyiapan dan seleksi data, diperoleh satu dataset terstruktur yang terdiri dari 56 variabel independen dan satu variabel dependen berupa prevalensi *stunting*. Untuk memudahkan pemahaman struktur data dan menjaga konsistensi analisis determinan, seluruh variabel independen kemudian dikelompokkan ke dalam beberapa kategori tematik berdasarkan karakteristik indikator yang diwakilinya.

Tabel 3.1 Distribusi Variabel Determinan Stunting berdasarkan Kategori


No	Kategori Variabel	Jumlah Fitur
1	Riwayat Kehamilan dan Kelahiran	15
2	Riwayat Pemberian ASI dan MP-ASI	17
3	Akses dan Pemanfaatan Pelayanan Kesehatan	9
4	Imunisasi dan Morbiditas Balita	8
5	Kepemilikan dan Pemanfaatan Jaminan Kesehatan	2
6	Pendampingan Keluarga dan Pengetahuan Stunting	4
7	Kontrasepsi Pasca Bersalin	1
8	Bantuan Sosial	1
9	Akses Air Minum dan Sanitasi	4
Total		56

Tabel 3.1 menunjukkan bahwa variabel determinan yang digunakan dalam penelitian ini didominasi oleh indikator terkait riwayat kehamilan, pola pemberian makan bayi dan anak, serta akses pelayanan kesehatan. Komposisi ini mencerminkan pendekatan multidimensi dalam menganalisis *stunting*, di mana faktor biologis, perilaku, layanan kesehatan, serta kondisi lingkungan dianalisis secara simultan. Pengelompokan ini juga menjadi dasar dalam interpretasi model, khususnya pada tahap analisis kontribusi fitur menggunakan SHAP.

3.2.3 Pemodelan *Random Forest*

Setelah melalui tahapan penyiapan dan pra-pemrosesan data, *dataset* yang telah bersih dan terstruktur selanjutnya digunakan pada tahap pemodelan. Pada penelitian ini, pendekatan yang digunakan adalah *Random Forest Regression* untuk memodelkan hubungan antara variabel determinan *stunting* dan nilai

prevalensi *stunting* pada tingkat provinsi yang memiliki nilai numerik kontinu. Pemilihan metode ini didasarkan pada kemampuannya dalam menangani data dengan jumlah fitur yang relatif banyak serta hubungan non-linier antarvariabel tanpa asumsi distribusi data yang ketat [23]. Alur proses pemodelan disajikan secara ringkas pada Gambar 3.4.



Gambar 3.4 Alur Pembangunan Model *Random Forest Regression*

3.2.3.1 *Hyperparameter Tuning Berbasis Cross Validation*

Tahap awal pembangunan model difokuskan pada pencarian konfigurasi model yang paling optimal melalui strategi validasi yang ketat. Mengingat keterbatasan jumlah sampel data yang hanya tersedia pada tingkat provinsi, penelitian ini menerapkan metode *Leave-One-Out Cross Validation* (LOOCV) sebagai pengganti pembagian data latih-uji konvensional [31]. Dalam skema ini, proses pelatihan dilakukan secara iteratif sebanyak jumlah sampel, di mana pada setiap iterasi, satu provinsi digunakan sebagai data uji sementara provinsi sisanya menjadi data latih. Pendekatan ini dipilih untuk memaksimalkan pemanfaatan informasi dari data yang terbatas serta menghasilkan estimasi performa model yang tidak bias terhadap pemilihan acak data uji tertentu.

Bersamaan dengan proses validasi LOOCV, dilakukan optimasi kinerja model melalui mekanisme *Hyperparameter Tuning* menggunakan metode *Grid*

SearchCV. Tahap ini bertujuan untuk mencari kombinasi parameter terbaik dari algoritma Random Forest, meliputi jumlah pohon keputusan (*n_estimators*), batas kedalaman maksimal pohon (*max_depth*), jumlah sampel minimum pada simpul daun (*min_samples_leaf*), serta jumlah fitur maksimal yang dipertimbangkan pada setiap pemecahan simpul (*max_features*), guna menghasilkan model dengan tingkat kesalahan prediksi terendah. Eksplorasi ruang parameter ini dinilai krusial untuk mencegah terjadinya *overfitting*¹ yang sering menjadi kendala pada dataset berskala kecil [32]. Kombinasi parameter yang menghasilkan nilai rata-rata *Root Mean Squared Error* (RMSE) terendah selama proses validasi silang kemudian ditetapkan sebagai konfigurasi model optimal.

3.2.3.2 Pelatihan Model Final

Setelah parameter optimal diperoleh dari tahap validasi, langkah selanjutnya adalah pembangunan model final (*final model fitting*). Pada tahap ini, model *Random Forest* dilatih ulang menggunakan keseluruhan *dataset* provinsi yang tersedia dengan menerapkan parameter terbaik hasil optimasi sebelumnya. Tujuannya adalah untuk menangkap pola data secara utuh tanpa menyisakan data untuk pengujian, karena evaluasi performa telah diselesaikan pada tahap validasi silang. Model terbaik ini kemudian digunakan untuk memetakan hubungan non-linier yang kompleks antara seluruh variabel determinan dengan prevalensi *stunting*.

Selain menghasilkan prediksi angka prevalensi, model final ini memiliki fungsi krusial untuk mengekstraksi nilai kepentingan fitur (*feature importance*). Nilai ini mengkuantifikasi kontribusi relatif setiap indikator determinan terhadap hasil prediksi model secara global. Informasi mengenai bobot kontribusi fitur inilah yang nantinya menjadi landasan utama dalam analisis prioritas intervensi

¹*Overfitting* merupakan kondisi saat model terlalu mempelajari *noise* data latih sehingga kehilangan kemampuan generalisasi pada data baru.

penanganan *stunting* pada tahap interpretasi hasil menggunakan metode SHAP.

3.2.4 Evaluasi Performa Model

Evaluasi performa model dilakukan untuk mengukur sejauh mana model *Random Forest Regression* mampu memprediksi prevalensi *stunting* secara akurat pada tingkat provinsi. Mengingat penelitian ini bersifat regresi, digunakan beberapa metrik evaluasi berbasis kesalahan prediksi dan kekuatan penjelasan model. Penggunaan lebih dari satu metrik bertujuan untuk memberikan gambaran performa model secara komprehensif, baik dari sisi rata-rata kesalahan absolut, sensitivitas terhadap kesalahan besar, maupun kemampuan model dalam menjelaskan variasi data target. Seluruh metrik dievaluasi pada skema validasi silang yang telah ditetapkan pada tahap pemodelan.

1. *Mean Absolute Error (MAE)*

MAE digunakan untuk mengukur rata-rata selisih absolut antara nilai prevalensi *stunting* hasil prediksi model dengan nilai aktual pada masing-masing provinsi. Metrik ini memberikan gambaran kesalahan prediksi secara langsung dalam satuan persentase, sehingga memudahkan interpretasi seberapa jauh hasil prediksi model menyimpang dari data SSGI 2024 yang sebenarnya.

2. *Root Mean Squared Error (RMSE)*

RMSE digunakan sebagai indikator utama akurasi model karena mengembalikan nilai kesalahan ke dalam skala yang sama dengan prevalensi *stunting*. Dalam konteks penelitian ini, RMSE membantu menilai seberapa besar deviasi prediksi model terhadap nilai aktual *stunting* antarprovinsi secara keseluruhan.

3. *R-squared (R^2)*

Koefisien determinasi R^2 digunakan untuk mengukur sejauh mana variasi prevalensi *stunting* antarprovinsi dapat dijelaskan oleh variabel determinan yang dimasukkan ke dalam model. Metrik ini memberikan gambaran


kemampuan model dalam menangkap hubungan kompleks antara faktor kesehatan ibu, balita, dan lingkungan dengan tingkat *stunting*.

4. *Mean Absolute Percentage Error (MAPE)*

MAPE digunakan untuk mengukur kesalahan prediksi dalam bentuk persentase relatif terhadap nilai aktual prevalensi *stunting*. Metrik ini membantu melihat konsistensi performa model antarprovinsi, terutama ketika terdapat perbedaan tingkat *stunting* yang cukup besar antara satu wilayah dan wilayah lainnya.

3.3 Interpretasi Hasil dengan SHAP

Interpretasi keputusan model *Random Forest* yang bersifat *black-box* dilakukan menggunakan metode SHAP guna mengidentifikasi besaran pengaruh faktor determinan secara transparan. Analisis mencakup tinjauan global skala nasional dan tinjauan lokal spesifik per provinsi. Alur kerja analisis interpretabilitas model ini diilustrasikan pada Gambar 3.5.



Gambar 3.5 Alur Interpretasi Model dengan SHAP

3.3.1 Interpretasi Global

Interpretasi global bertujuan untuk memberikan gambaran menyeluruh mengenai faktor-faktor yang paling dominan mempengaruhi prevalensi *stunting* di tingkat nasional. Analisis ini menggabungkan nilai SHAP mutlak dari seluruh sampel data untuk mengidentifikasi hirarki kepentingan fitur serta pola hubungan umum antara determinan dan kejadian *stunting*. Dalam penelitian ini, interpretasi global diuraikan melalui dua komponen visualisasi utama:

1. *Feature Importance Plot*

Visualisasi berbentuk diagram batang ini mengurutkan variabel determinan berdasarkan rata-rata nilai absolut SHAP. Perhitungan tersebut dinyatakan secara matematis melalui rumus $\frac{1}{n} \sum_{i=1}^n |\phi_i^{(j)}|$. Grafik ini berfungsi untuk melihat tingkat kepentingan setiap fitur terhadap keluaran model secara keseluruhan. Pengurutan posisi fitur dilakukan tanpa memandang arah pengaruh variabel tersebut, baik yang bernilai positif maupun negatif. Variabel yang berada di posisi paling atas merupakan indikator dengan dampak paling besar terhadap hasil tebakan algoritma.

2. *Summary Plot (Beeswarm)*

Visualisasi ini merupakan bentuk distribusi nilai SHAP yang menyajikan arah pengaruh setiap variabel terhadap hasil prediksi. Grafik beeswarm menggunakan gradasi warna untuk membedakan besaran nilai asli dari sebuah observasi. Titik berwarna merah merepresentasikan nilai fitur yang tinggi, sedangkan titik biru merepresentasikan nilai fitur yang rendah. Posisi titik di sebelah kanan sumbu nol menandakan adanya dorongan peningkatan pada prediksi prevalensi *stunting*. Sebaliknya, sebaran titik di sebelah kiri sumbu nol menunjukkan bahwa variabel tersebut membantu menurunkan angka tebakan *stunting*.

3. *Dependence Plot*

Visualisasi ini berbentuk grafik pencar (*scatter plot*) yang bertugas

membedah pola pengaruh dari satu variabel spesifik secara lebih rinci. Sumbu mendatar pada grafik ini menampilkan angka asli dari fitur yang sedang dianalisis. Sementara itu, sumbu vertikal menunjukkan besaran nilai SHAP yang dihasilkan oleh perubahan angka pada fitur tersebut. Visualisasi ini berguna untuk melihat ambang batas (*threshold*) di mana sebuah indikator mulai merubah keputusan model secara drastis. Melalui grafik ini, peneliti dapat mengamati bentuk hubungan sebab-akibat secara langsung antara variabel masukan dan target keluaran.

3.3.2 Interpretasi Lokal

Interpretasi lokal dilakukan untuk memahami mekanisme prediksi model *Random Forest* pada tingkat wilayah spesifik, yaitu provinsi. Berbeda dengan interpretasi global yang menyoroti pola umum secara nasional, pendekatan ini berfokus pada kontribusi variabel determinan terhadap prediksi prevalensi *stunting* pada masing-masing provinsi. Analisis ini penting karena faktor dominan penyebab *stunting* dapat bervariasi antarwilayah meskipun memiliki tingkat prevalensi yang relatif serupa. Alur interpretasi lokal menggunakan metode SHAP dalam penelitian ini ditunjukkan pada Gambar 3.5.

3.3.2.1 Pemilihan Sampel Provinsi

Mengingat interpretasi lokal bersifat mendalam dan kontekstual, tidak seluruh provinsi dianalisis secara individual. Oleh karena itu, dilakukan pemilihan sampel provinsi yang bertujuan untuk merepresentasikan variasi kondisi *stunting* di Indonesia. Pemilihan sampel didasarkan pada distribusi nilai prevalensi *stunting* hasil prediksi model, sehingga mencakup provinsi dengan tingkat prevalensi relatif tinggi, rendah, serta kondisi menengah. Hal ini didasarkan pada distribusi nilai prevalensi *stunting* hasil prediksi model, yakni dengan memilih secara spesifik provinsi yang memiliki tingkat prevalensi tertinggi (mewakili nilai maksimum), tingkat prevalensi terendah (mewakili

nilai minimum), serta tingkat prevalensi menengah (mewakili nilai median). Pendekatan ini memungkinkan analisis yang lebih terfokus tanpa mengurangi representativitas karakteristik wilayah secara nasional.

3.3.2.2 Visualisasi dan Analisis *Waterfall Plot*

Setelah sampel provinsi ditetapkan, interpretasi lokal dilakukan menggunakan visualisasi *Waterfall Plot*. Visualisasi ini menampilkan bagaimana nilai prediksi suatu provinsi terbentuk secara bertahap mulai dari nilai dasar (*base value*) hingga mencapai nilai prediksi akhir. Nilai dasar tersebut merepresentasikan rata-rata prediksi model pada seluruh data, kemudian setiap variabel determinan ditambahkan atau dikurangkan secara berurutan sesuai besar kontribusinya terhadap prediksi provinsi tersebut. Dengan demikian, grafik ini memperlihatkan proses pembentukan prediksi sebagai akumulasi kontribusi dari masing-masing variabel.

Secara visual, *Waterfall Plot* menyerupai diagram batang bertingkat yang bergerak naik atau turun dari satu titik awal menuju nilai akhir. Batang yang mengarah ke atas menunjukkan variabel yang meningkatkan nilai prediksi prevalensi stunting, sedangkan batang yang mengarah ke bawah menunjukkan variabel yang menurunkan nilai tersebut. Panjang setiap batang menggambarkan besar kecilnya pengaruh variabel terhadap hasil prediksi. Melalui penyajian ini, pembaca dapat secara langsung melihat faktor mana yang paling dominan membentuk nilai prediksi pada suatu provinsi, sehingga keputusan model tidak lagi terlihat sebagai proses yang tertutup atau sulit dipahami.

3.4 Lingkungan Pengembangan Model

Proses pembangunan model dan pengolahan data dilakukan dalam lingkungan bahasa pemrograman Python versi 3.10. Untuk menjaga reproduksibilitas penelitian, berikut adalah daftar pustaka (*library*) utama beserta versinya dan peran spesifiknya dalam sistem:

1. `scikit-learn` (v1.7.2), digunakan untuk implementasi algoritma *Random Forest*, pembagian data *Leave-One-Out Cross-Validation*, serta optimasi *hyperparameter*.
2. `shap` (v0.49.1), digunakan sebagai instrumen interpretasi model untuk menghitung nilai kontribusi tiap fitur melalui pendekatan *Shapley values*.
3. `pandas` (v2.3.2), digunakan untuk manipulasi struktur data, khususnya dalam proses agregasi dari data individu ke tingkat provinsi.
4. `numpy` (v2.3.3), mendukung operasi komputasi matriks dan pemrosesan *array* numerik yang efisien.
5. `matplotlib` (v3.10.6) & `seaborn` (v0.13.2), digunakan untuk memvisualisasikan distribusi variabel dan hasil interpretasi fitur secara grafis.
6. `scipy` (v1.16.2), digunakan untuk pengolahan statistik tingkat lanjut yang diperlukan dalam pembersihan data.

3.5 Ilustrasi Perhitungan Metode

Bagian ini menyajikan simulasi pemrosesan data SSGI 2024 oleh model untuk menghasilkan prediksi prevalensi *stunting*. Angka yang digunakan di sini adalah data hipotetis untuk menggambarkan alur kalkulasi dari *input* fitur hingga evaluasi akhir.

3.5.1 Prediksi *Random Forest Regression*

Dalam penelitian ini, prediksi prevalensi *stunting* untuk satu provinsi tidak ditentukan oleh satu pohon keputusan tunggal, melainkan melalui konsensus dari banyak pohon (*ensemble*). Setiap pohon dalam model akan memberikan estimasi angka prevalensi berdasarkan fitur *input* yang dipelajarinya.

Berikut adalah ilustrasi jika model terdiri dari 3 pohon keputusan, di mana masing-masing pohon memberikan estimasi angka *stunting* sebagai berikut:

Tabel 3.2 Data Hipotetis Output Pohon Keputusan

Pohon Keputusan	Output Prediksi (h_i)
Tree 1	18.5
Tree 2	17.9
Tree 3	18.2

Nilai prediksi akhir ($\hat{y}$) untuk provinsi tersebut diperoleh dengan merata-ratakan seluruh *output* pohon menggunakan persamaan berikut:

$$\hat{y} = \frac{18.5 + 17.9 + 18.2}{3}$$

$$\hat{y} = \frac{54.6}{3}$$

$$\hat{y} = \mathbf{18.2}$$

Angka **18.2%** inilah yang menjadi prediksi final prevalensi *stunting* untuk provinsi tersebut.

3.5.2 Perhitungan *Error* Prediksi

Validasi akurasi dilakukan dengan membandingkan angka prediksi model terhadap data aktual SSGI. Selisih absolut antara kedua nilai ini menunjukkan seberapa jauh deviasi estimasi model untuk satu provinsi.

Misalkan data aktual dan hasil prediksi untuk sampel provinsi tersebut adalah:

Tabel 3.3 Data Hipotetis Aktual vs Prediksi

Data	Nilai (%)
Aktual (y)	20.0
Prediksi ($\hat{y}$)	18.2

Perhitungan deviasi atau *error* individu (e) adalah:

$$e = |y - \hat{y}|$$

Penyelesaian:

$$e = |20.0 - 18.2|$$

$$e = 1.8$$

Hasil ini menunjukkan bahwa prediksi model meleset sebesar **1.8 poin persentase** dari angka *stunting* yang sebenarnya.

3.5.3 Perhitungan Metrik Evaluasi

Untuk mengukur performa model secara menyeluruh terhadap seluruh provinsi di Indonesia, digunakan perhitungan agregat. Berikut adalah ilustrasi perhitungan menggunakan sampel data dari 3 provinsi (A, B, dan C).

Tabel 3.4 Data Hipotetis untuk Evaluasi Agregat

Sampel	Aktual (y)	Prediksi ($\hat{y}$)	Selisih ($ e $)	Kuadrat (e^2)
A	20	18	2	4
B	15	16	1	1
C	25	23	2	4

1. MAE

Mean Absolute Error (MAE) dihitung untuk mengetahui rata-rata penyimpangan absolut prediksi *stunting* dalam satuan persen.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Penyelesaian:

$$\text{MAE} = \frac{2 + 1 + 2}{3} = 1.67$$

Model memiliki rata-rata kesalahan prediksi sebesar **1.67 poin**.

3. RMSE

Root Mean Squared Error (RMSE) mengembalikan nilai kesalahan ke satuan asli (persentase) untuk menggambarkan standar deviasi dari residu prediksi model terhadap data SSGI.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Penyelesaian:

$$\text{RMSE} = \sqrt{\frac{4 + 1 + 4}{3}}$$

$$\text{RMSE} = \sqrt{3.00} \approx \mathbf{1.73}$$

Deviasi standar kesalahan model berada pada angka **1.73 poin**.

4. MAPE

Mean Absolute Percentage Error (MAPE) digunakan untuk melihat rasio kesalahan model relatif terhadap besaran angka *stunting* aktual di masing-masing provinsi.

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Penyelesaian:

$$\begin{aligned} \text{MAPE} &= \frac{100\%}{3} (0.10 + 0.067 + 0.08) \\ &= \mathbf{8.22\%} \end{aligned}$$

Rata-rata kesalahan model adalah sebesar **8.22%** dari nilai aktual.

3.6 Ilustrasi Rancangan Pengujian

Bagian ini menjabarkan skenario eksperimen yang dilakukan untuk melatih dan memvalidasi model. Mengingat jumlah observasi yang terbatas yaitu provinsi di Indonesia, strategi pembagian data dan pemilihan parameter menjadi krusial untuk mencegah *overfitting* dan memastikan hasil evaluasi yang objektif.

3.6.1 Skema *Leave-One-Out Cross Validation* (LOOCV)

Penelitian ini menerapkan metode *Leave-One-Out Cross Validation* (LOOCV) untuk memaksimalkan penggunaan data. Dalam skema ini, evaluasi dilakukan melalui N kali iterasi, di mana pada setiap iterasi, satu provinsi disisihkan sebagai data uji (*testing set*) sementara sisa provinsi lainnya digunakan sebagai data latih (*training set*).

Berikut adalah ilustrasi pembagian data pada setiap iterasi pengujian:

Tabel 3.5 Ilustrasi Skema Pembagian Data LOOCV

Iterasi	Data Latih (N-1 Provinsi)	Data Uji (1 Provinsi)
1	Prov 2, 3, ..., N	Provinsi 1
2	Prov 1, 3, ..., N	Provinsi 2
...	...	...
N	Prov 1, 2, ..., N	Provinsi N

Dengan mekanisme ini, model diuji pada setiap provinsi tepat satu kali tanpa bias pemilihan data, dan performa akhir dihitung dari rata-rata *error* seluruh iterasi.

3.6.2 *Hyperparameter Tuning*

Untuk mendapatkan konfigurasi model yang paling optimal dalam memprediksi *stunting*, dilakukan pencarian parameter terbaik menggunakan teknik *Grid Search*. Berbagai kombinasi parameter seperti jumlah pohon dan kedalaman pohon diuji performanya menggunakan skema LOOCV di atas.

Tabel berikut mengilustrasikan simulasi hasil pencarian parameter, di mana keputusan pemilihan didasarkan pada nilai rata-rata RMSE terendah.

Tabel 3.6 Data Hipotetis Hasil Tuning Parameter

No	<i>n_estimators</i>	<i>max_depth</i>	RMSE	Keputusan
1	100	5	2.10	-
2	200	5	1.85	Dipilih (Terbaik)
3	200	10	1.92	-

Berdasarkan ilustrasi Tabel 3.6, kombinasi nomor 2 dipilih karena menghasilkan tingkat kesalahan prediksi yang paling minim.

3.6.3 Pemilihan Model Final

Tahap terakhir adalah pembentukan model final untuk kebutuhan interpretasi fitur. Setelah parameter terbaik ditemukan (misal: *n_estimators*=200 dan *max_depth*=5), model tersebut tidak lagi dipisahkan antara data latih dan uji.

Sebagai langkah akhir, model dilatih ulang (*retraining*) menggunakan seluruh *dataset* penuh. Model yang telah mempelajari pola dari seluruh data provinsi inilah yang nantinya digunakan untuk analisis determinan penyebab *stunting* menggunakan metode SHAP pada Bab IV.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Penelitian

Bagian ini menyajikan hasil penelitian yang diperoleh dari seluruh tahapan yang telah dilakukan. Proses penelitian meliputi ekstraksi dan analisis data SSGI tahun 2024 pada tingkat provinsi, dilanjutkan dengan tahap pra-pemrosesan data hingga pembangunan model prediktif. Model yang digunakan dalam penelitian ini adalah *Random Forest* untuk memprediksi prevalensi *stunting*, yang kemudian dikombinasikan dengan metode *SHAP* untuk menjelaskan kontribusi masing-masing variabel. Seluruh proses pemodelan dilakukan menggunakan skema validasi LOOCV serta optimasi parameter melalui *GridSearchCV* untuk memperoleh kinerja model yang optimal.

4.1.1 Analisis Deskriptif

Penelitian ini menggunakan data sekunder yang berasal dari laporan resmi SSGI tahun 2024 yang dipublikasikan oleh Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan RI. Data pada bentuk aslinya berupa rekapitulasi persentase berbagai indikator kesehatan, gizi, dan sosiodemografi yang tersebar dalam beberapa bagian laporan. Karena penelitian ini menggunakan pendekatan *machine learning* berbasis data tabular, format tersebut tidak dapat langsung digunakan sehingga diperlukan proses ekstraksi dan penyusunan ulang data. Proses ekstraksi dilakukan dengan memilih indikator yang relevan dan menyusunnya ke dalam bentuk tabel dengan baris dan kolom yang terstruktur. Hasilnya, data dibagi menjadi satu variabel target yaitu prevalensi *stunting* serta sejumlah variabel prediktor yang mencerminkan faktor-faktor seperti sanitasi, pola asuh, dan pendidikan ibu.

Dataset akhir yang digunakan dalam penelitian ini terdiri dari 38 baris yang

mewakili seluruh provinsi di Indonesia. Setiap baris memuat nilai persentase dari variabel target dan variabel prediktor yang telah disusun dalam format yang seragam. Penyusunan ini bertujuan agar data dapat langsung digunakan dalam proses analisis menggunakan algoritma *machine learning*. Selain itu, format tabular ini memudahkan dalam melakukan tahap pra-pemrosesan dan seleksi fitur sebelum model dibangun. Dataset tersebut kemudian menjadi dasar utama dalam proses pelatihan dan evaluasi model yang dilakukan dalam penelitian ini.

4.1.2 Persiapan Data

Laporan SSGI tahun 2024 disajikan dalam bentuk dokumen *Portable Document Format* (PDF) yang memuat sekitar 5.189 tabel statistik yang berisi berbagai indikator kesehatan, gizi, serta kondisi sosial dan lingkungan. Data dalam laporan tersebut mencakup informasi terkait kesehatan ibu dan anak, pola asuh, akses layanan kesehatan, sanitasi, serta karakteristik demografi rumah tangga dengan fokus pada balita usia 0–59 bulan menggunakan pendekatan *cross-sectional*. Meskipun data tersedia pada beberapa tingkat wilayah seperti nasional, provinsi, dan kabupaten/kota, penelitian ini hanya menggunakan tingkat provinsi sebagai unit analisis untuk melihat perbedaan determinan *stunting* secara umum. Struktur data dalam bentuk laporan ini belum dapat langsung digunakan untuk pemodelan *machine learning*, sehingga diperlukan proses pengolahan lebih lanjut. Oleh karena itu, kondisi awal dan karakteristik data sebelum dilakukan ekstraksi disajikan pada Tabel 4.1.

Tabel 4.1 Kondisi Awal Dataset SSGI 2024

No	Atribut	Keterangan Kondisi Awal
1	Sumber / Penerbit Data	Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan RI
2	Format File	Dokumen Laporan <i>Portable Document Format</i> (PDF)
3	Volume Data	± 5.189 tabel statistik
4	Variabel Target (<i>Label</i>)	Angka prevalensi balita <i>stunted</i> (pendek) berdasarkan indeks Tinggi Badan menurut Umur (TB/U)
5	Cakupan Indikator (<i>Fitur</i>)	Kesehatan ibu dan anak, pola asuh, akses kesehatan, sanitasi, dan sosiodemografi
6	Populasi Target	Rumah tangga kelompok balita usia 0-59 bulan
7	Tingkat Agregasi Wilayah	Nasional, Provinsi (38 Provinsi), dan Kabupaten/Kota
8	Pendekatan Pengambilan	<i>Cross-sectional</i> (Satu titik waktu tertentu)
9	Format Nilai Data	Numerik dan Persentase (%)

4.1.2.1 Ekstraksi Data

Tahap ekstraksi data dilakukan untuk memindahkan informasi prevalensi dan indikator kesehatan dari dokumen PDF SSGI 2024 ke dalam bentuk data yang lebih terstruktur. Proses ini menggunakan fitur *Power Query* pada Microsoft Excel yang mampu membaca dan mengimpor tabel secara otomatis dari dokumen. Setelah seluruh tabel berhasil diambil, dilakukan penyaringan untuk memilih tabel yang sesuai dengan kebutuhan penelitian, khususnya yang memuat data

tingkat provinsi dan indikator determinan *stunting*. Setiap tabel yang dipilih kemudian diperiksa kembali dengan sumber aslinya untuk memastikan tidak terjadi kesalahan posisi data. Hasil dari tahap ini berupa kumpulan tabel mentah yang siap digunakan pada proses selanjutnya, yang dapat dilihat pada Tabel 4.2.

Tabel 4.2 Contoh Hasil Ekstraksi Tabel dari Laporan SSGI 2024

No	Nomor Tabel Laporan	Indikator yang Diekstrak
1	Tabel 4.3	Status Gizi Tinggi Badan menurut Umur (TB/U)
2	Tabel 5.15	Pemeriksaan Kehamilan Ibu
3	Tabel 5.33	Pemberian ASI Eksklusif 6 Bulan
4	Tabel 5.113	Status Imunisasi Dasar Balita (12-23 Bulan)
5	Tabel 5.184	Akses Sanitasi Rumah Tangga (RT)

4.1.2.2 Seleksi Fitur Determinan

Tahap seleksi fitur dilakukan untuk menentukan variabel yang akan digunakan dalam pemodelan. Proses ini dilakukan dengan memilih indikator yang relevan berdasarkan kajian literatur dan pedoman resmi terkait determinan *stunting*. Variabel yang dipilih mencakup beberapa aspek utama seperti prevalensi *stunting*, kondisi sosial ekonomi, sanitasi, serta pola asuh dan pelayanan kesehatan. Sementara itu, indikator yang tidak berhubungan langsung dengan kondisi gizi balita tidak disertakan dalam analisis. Melalui proses ini, diperoleh kumpulan fitur yang dianggap paling mewakili kondisi tiap provinsi, sebagaimana disajikan pada Tabel 4.3.

Tabel 4.3 Contoh Variabel Hasil Seleksi Fitur Determinan *Stunting*

No	Aspek Determinan	Nama Variabel (Fitur Asli Laporan)
1	<i>Outcome</i> (Target)	Prevalensi <i>Stunting</i> (%)

No	Aspek Determinan	Nama Variabel (Fitur Asli Laporan)
2	Kondisi Fisik Lahir	Persentase Berat Badan Lahir Rendah (BBLR)
3	Asupan Gizi Balita	Persentase Tidak Konsumsi Protein Hewani
4	Penyakit Infeksi	Persentase Balita TBC
5	Kapasitas Sosiodemografi	Persentase Pengetahuan <i>Stunting</i> Baik

4.1.2.3 Transformasi dan Agregasi Data

Tahap transformasi dan agregasi data merupakan proses penyatuan akhir sekaligus penyederhanaan struktur variabel agar memiliki makna dan skala yang konsisten saat dibandingkan antarprovinsi. Pada tahap ini, fitur yang telah diekstraksi digabungkan ke dalam satu matriks *dataframe* menggunakan nama provinsi sebagai kunci penghubung (*primary key*). Selain penggabungan tabel, dilakukan proses agregasi sistematis dengan mengombinasikan beberapa indikator yang memiliki kemiripan risiko, seperti menjumlahkan persentase kelompok usia kehamilan ekstrem menjadi satu atribut tunggal guna menghindari redundansi informasi. Seluruh variabel hasil agregasi tersebut tetap dipertahankan dalam satuan persentase untuk memastikan keseragaman format data sebelum diproses oleh algoritma pemodelan. Rincian mengenai sumber tabel laporan, alur operasi matematis yang diterapkan, hingga penamaan atribut baru yang masuk ke dalam *dataset* utama dapat dilihat secara lengkap pada Tabel 4.4.

Tabel 4.4 Contoh Skenario Transformasi dan Agregasi Fitur Determinan *Stunting*

No	Nama Tabel Laporan	Alur Sistematis & Logika Agregasi	Nama Atribut Baru (CSV)
1	Tabel 4.3 (Status Gizi TB/U)	Menggabungkan persentase kategori <i>Severely Stunting</i> dan <i>Stunting</i> menjadi satu prevalensi target utama.	prevalensi_ stunting_ persen
2	Tabel 5.5 (Usia Ibu Memulai Kehamilan)	Menjumlahkan dua persentase kategori usia ekstrem, yakni kelompok usia < 21 tahun dan > 40 tahun.	persen_ usia_ ibu_ berisiko
3	Tabel 5.184 (Akses Sanitasi RT)	Menjumlahkan nilai dari kategori: BABS Terbuka, BABS Tertutup, dan Akses Belum Layak.	persen_ akses_ sanitasi_ berisiko
4	Tabel 5.33 (Pemberian ASI Eksklusif)	Menghitung nilai komplemen (100% dikurangi persentase "Hanya ASI 0-5 Bulan").	persen_ tidak_ asi_ eksklusif
5	Tabel 5.113 (Status Imunisasi Dasar)	Menggabungkan persentase balita dengan status imunisasi "Tidak Lengkap" dan "Tidak Imunisasi".	persen_ imunisasi_ dasar_ incomplete

4.1.3 Pra-pemrosesan dan Eksplorasi Data

Tahapan pra-pemrosesan data bertujuan untuk mengubah *dataset* mentah hasil ekstraksi SSGI 2024 menjadi format terstruktur yang bersih dan dapat diproses secara efektif oleh algoritma *machine learning*. Terdapat 58 kolom fitur

dalam *dataset* awal ini, namun tidak seluruh indikator tersebut memiliki kualitas data yang baik atau relevansi langsung dalam mendeteksi pola determinan *stunting*. Oleh sebab itu, penelitian ini melakukan serangkaian proses penyiapan lanjutan yang mengacu pada alur pra-pemrosesan, meliputi eksplorasi data, penanganan nilai hilang (*missing value*), hingga eliminasi variabel non-determinan. Sebagai gambaran, bentuk *dataset* mentah sebelum diproses lebih lanjut ditunjukkan pada Tabel 4.5. Adapun tahapan dari pra-pemrosesan data dijabarkan sebagai berikut.

Tabel 4.5 Gambaran *Dataset* Mentah SSGI 2024 Sebelum Pra-pemrosesan

No	Provinsi	prevalensi_ stunting_ persen	persen_ usia_ibu_ berisiko	persen_ bblr	...
1	Aceh	28,6	48,3	4,8	...
2	Sumatera Utara	22,9	48,1	3,3	...
3	Sumatera Barat	24,9	44,7	6,4	...
...	...	...	...	...	...
39	Indonesia	19,8	40,4	6,5	...

4.1.3.1 Eksplorasi Data (EDA)

Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik distribusi data, memastikan kesesuaian tipe variabel, serta mengidentifikasi pola hubungan antarfitur sebelum proses pemodelan. Analisis awal difokuskan pada variabel target, yaitu persentase prevalensi *stunting*, di mana sebarannya divisualisasikan secara nasional untuk melihat ketimpangan antarwilayah. Hasil eksplorasi menunjukkan rentang prevalensi yang signifikan, dengan Provinsi Nusa Tenggara Timur mencatatkan angka tertinggi (37,0%) dan Bali berada pada posisi terendah (8,6%). Adapun secara distribusi frekuensi, visualisasi histogram menunjukkan bahwa mayoritas provinsi di Indonesia

memiliki tingkat prevalensi yang terkonsentrasi pada rentang 15% hingga 30%. Selanjutnya, dilakukan perhitungan matriks korelasi *Pearson* untuk meninjau hubungan linear antara 15 kandidat fitur teratas dengan variabel target. Analisis ini mengungkap adanya korelasi positif yang sangat kuat antara *stunting* dengan kondisi fisik balita lainnya, seperti prevalensi *underweight* (0,93), serta kaitannya dengan indikator pelayanan kesehatan. Rincian implementasi kode program, beserta grafik distribusi dan *heatmap* korelasi yang dihasilkan dari tahapan ini, diuraikan berturut-turut pada Kode 4.1 serta urutan visualisasi pada Gambar 4.1, Gambar 4.2, dan Gambar 4.3.

Kode 4.1 Implementasi Kode Eksplorasi Data (EDA)

```


1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4
5 # 1. Memuat dataset dan konversi format koma menjadi desimal
6 df = pd.read_csv('SSGI_2024_dataset.csv')
7 for col in df.columns:
8     if col != 'Provinsi' and df[col].dtype == 'object':
9         df[col] = df[col].str.replace(',', '.').regex=False)
10        df[col] = pd.to_numeric(df[col], errors='coerce')
11
12 # 2. Visualisasi Distribusi Target per Provinsi (Bar Chart)
13 df_clean = df.dropna(subset=['prevalensi_stunting_persen']) \
14     .sort_values(by='prevalensi_stunting_persen')
15
16 plt.figure(figsize=(10, 12))
17 plt.barh(df_clean['Provinsi'],
18         df_clean['prevalensi_stunting_persen'])
19 plt.title('Distribusi Prevalensi Stunting per Provinsi')
20 plt.xlabel('Persentase Stunting')
21 plt.ylabel('Provinsi')
22 plt.tight_layout()
23 plt.show()
24
25 # 3. Plot Distribusi Stunting (Histogram & KDE)
26 plt.figure(figsize=(10, 6))
27 sns.histplot(df_clean['prevalensi_stunting_persen'], kde=True,
28             bins=10)
29 plt.title('Distribusi Persentase Stunting per Provinsi')
30 plt.xlabel('Persentase Stunting (%)')
31 plt.ylabel('Jumlah Provinsi')
32 plt.xticks(rotation=45)
33 plt.tight_layout()
34 plt.show()
35
36 # 4. Analisis Korelasi dan Visualisasi Heatmap
37 correlation =
38     df.corr(numeric_only=True)['prevalensi_stunting_persen'] \
39     .sort_values(ascending=False)
40 top_15_vars = correlation.head(15).index
41
42 plt.figure(figsize=(10, 8))
43 sns.heatmap(df[top_15_vars].corr(numeric_only=True),
44            annot=True, cmap='coolwarm', fmt='.2f')
45 plt.title('Heatmap Korelasi 15 Variabel Teratas dengan Stunting')

```

```

43 plt.tight_layout()
44 plt.show()


```



Gambar 4.1 Distribusi Prevalensi *Stunting* per Provinsi


Visualisasi diagram batang pada Gambar 4.1 merepresentasikan tingkat prevalensi *stunting* di seluruh provinsi secara terurut. Berdasarkan grafik tersebut, Provinsi Nusa Tenggara Timur mencatatkan rekor angka tertinggi dengan persentase mencapai 37,0%. Sebaliknya, Provinsi Bali menempati posisi

terendah dengan tingkat prevalensi yang dapat ditekan hingga 8,6%. Sementara itu, nilai rata-rata prevalensi secara agregat nasional berada pada angka 19,8%. Pemetaan grafis ini memperlihatkan adanya ketimpangan status kesehatan balita yang cukup signifikan antarwilayah observasi di Indonesia.



Gambar 4.2 Histogram Distribusi Data Target

Analisis sebaran frekuensi data target selanjutnya dijabarkan melalui bentuk histogram yang ditunjukkan pada Gambar 4.2. Kurva kepadatan pada grafik ini memperlihatkan pemusatan data (*central tendency*) yang mendekati distribusi normal. Mayoritas provinsi di Indonesia memiliki tingkat prevalensi yang terkonsentrasi secara padat pada kelas interval 15% hingga 25%. Hanya terdapat sebagian kecil provinsi yang berada pada titik rentang ekstrem bawah maupun ekstrem atas. Pola distribusi ini mengonfirmasi bahwa masalah *stunting* pada sebagian besar wilayah observasi cenderung seragam di sekitar nilai rata-rata.



Gambar 4.3 Heatmap Korelasi 15 Variabel Teratas

Identifikasi hubungan linear antarvariabel diekstraksi menggunakan matriks korelasi *Pearson* berbentuk *heatmap* seperti yang tertera pada Gambar 4.3. Baris pertama pada matriks tersebut secara spesifik memetakan nilai korelasi 15 kandidat fitur teratas terhadap variabel target prevalensi *stunting*. Hasil perhitungan matematis menunjukkan hubungan positif yang sangat kuat dengan indikator malnutrisi lain, yakni *underweight* (0,93) dan *wasting* (0,78). Pada kategori fasilitas kesehatan dan lingkungan, fitur ketidaklengkapan pemeriksaan ANC K6 (0,61) serta risiko akses sanitasi (0,58) memegang peranan korelatif tertinggi. Temuan pola hubungan kuantitatif ini memberikan landasan objektif yang kuat untuk tahapan seleksi fitur sebelum masuk ke proses pemodelan.

4.1.3.2 Penanganan Missing Value

Tahap penanganan *missing value* dilakukan untuk memastikan integritas data sebelum memasuki fase pemodelan. Berdasarkan hasil temuan pada data mentah SSGI 2024, ditemukan kekosongan data yang masif pada Provinsi Papua Tengah dan Papua Pegunungan sebagai wilayah pemekaran baru. Karena ketiadaan data tersebut bersifat struktural pada level observasi, metode *listwise deletion* diterapkan dengan menghapus kedua provinsi tersebut dari *dataset*. Selain itu, baris agregat "Indonesia" juga dieliminasi karena bukan merupakan entitas provinsi independen. Langkah ini memastikan bahwa *dataset* yang tersisa merupakan data lengkap tanpa memerlukan imputasi buatan. Implementasi kode dan ringkasan perubahan jumlah observasi ditunjukkan pada Kode 4.2 dan Tabel 4.6.

Kode 4.2 Penghapusan Observasi dan Validasi Missing Value

```
1 # 1. Menghapus baris provinsi dengan data kosong dan agregat nasional
2 provinces_to_drop = ['Papua Tengah', 'Papua Pegunungan', 'Indonesia']
3
4 plot_data_clean = plot_data_clean[~plot_data_clean['Provinsi'] \
5                                   .isin(provinces_to_drop)]
6
7 # 2. Validasi ketiadaan missing value
8 missing_values = plot_data_clean.isnull().sum()
9 missing_values = missing_values[missing_values > 0]
10
11 if len(missing_values) == 0:
12     print("No missing values found in the dataset")
```

Tabel 4.6 Perbandingan Jumlah Observasi Sebelum dan Sesudah Pembersihan

No	Kondisi Dataset	Jumlah Baris
1	Sebelum Penanganan Missing Value	39
2	Sesudah Penanganan Missing Value	36

4.1.3.3 Eliminasi Variabel Non-Determinan

Setelah pembersihan baris, dilakukan eliminasi fitur pada tingkat kolom untuk menghindari bias pemodelan. Fitur `prevalensi_underweight_persen` dan `prevalensi_wasting_persen` dihapus secara sengaja karena merupakan

indikator malnutrisi yang sangat berkorelasi dengan target *stunting*. Mempertahankan kedua variabel ini akan memicu *data leakage*, di mana model seolah-olah memiliki performa tinggi namun secara logika tidak valid dalam memetakan faktor penyebab (determinan) luar. Proses eliminasi ini dijabarkan pada Kode 4.3 dan perubahan dimensi kolomnya diringkaskan pada Tabel 4.7.

Kode 4.3 Eliminasi Fitur untuk Mencegah *Data Leakage*

```
1 # Menghapus kolom underweight dan wasting
2 columns_to_drop = ['prevalensi_underweight_persen',
3                   'prevalensi_wasting_persen']
4 plot_data_clean = plot_data_clean.drop(columns=columns_to_drop)
5 print(f"Jumlah kolom setelah penghapusan:
6       {len(plot_data_clean.columns)}")
```

Tabel 4.7 Perbandingan Jumlah Atribut Sebelum dan Sesudah Eliminasi

No	Kondisi Dataset	Jumlah Kolom
1	Sebelum Eliminasi Variabel	58
2	Sesudah Eliminasi Variabel	56

4.1.3.4 Penetapan Variabel Penelitian

Tahap akhir pra-pemrosesan adalah penetapan matriks variabel penelitian yang siap masuk ke tahap pemodelan. *Dataset* final terdiri dari 36 provinsi dengan 54 fitur determinan numerik murni sebagai variabel independen (*X*) dan satu kolom target persentase prevalensi *stunting* (*y*). Kolom nama provinsi dipisahkan karena tidak berperan dalam perhitungan matematis algoritma *Random Forest*. Rincian pemisahan matriks ditunjukkan pada Kode 4.4, sedangkan struktur data akhirnya direpresentasikan pada Tabel 4.8.

Kode 4.4 Pemisahan Variabel Independen (*X*) dan Dependen (*y*)

```
1 # Menentukan target dan fitur prediktor
2 y = plot_data_clean['prevalensi_stunting_persen']
3 X = plot_data_clean.drop(['Provinsi', 'prevalensi_stunting_persen'],
4                           axis=1)
5 print("Dimensi X:", X.shape) # (36, 54)
6 print("Dimensi y:", y.shape) # (36,)
```


Tabel 4.8 Ilustrasi *Dataset* Final Pemodelan *Stunting*

Provinsi(<i>Index</i>)	y: prevalensi_ stunting	X1: jarak_ hamil_ risiko	X2: usia_ ibu_ risiko	... (X54)
Bali	8,6	9,5	12,5	...
Jawa Timur	14,7	10,4	13,1	...
Kep. Riau	15,0	10,6	10,3	...
...	...	...	...	...

4.1.4 Pemodelan *Random Forest*

Setelah melalui serangkaian tahapan pra-pemrosesan data, langkah selanjutnya adalah pengembangan algoritma untuk memprediksi angka prevalensi *stunting*. Mengacu pada alur penelitian, rangkaian proses pengembangan model dibagi menjadi tiga tahapan utama, mulai dari pencarian parameter optimal (*hyperparameter tuning*), pelatihan model secara utuh (*fitting*), hingga diakhiri dengan evaluasi performa model. Adapun proses-proses tersebut dijabarkan sebagai berikut.

4.1.4.1 *Hyperparameter Tuning* Berbasis *Cross Validation*

Tahapan *hyperparameter tuning* dilaksanakan dengan tujuan mengidentifikasi konfigurasi optimal pada model *Random Forest Regressor* agar mampu menghasilkan performa prediksi yang stabil dan akurat. Mengingat dimensi *dataset* penelitian yang tergolong kecil (36 observasi), pembagian data latih (*training*) dan data uji (*testing*) konvensional berisiko menghasilkan variansi bias yang tinggi. Oleh karena itu, pendekatan *Leave-One-Out Cross-Validation* (LOOCV) diterapkan. Pada skema ini, model dilatih sebanyak 36 kali, di mana pada setiap iterasinya, 35 data digunakan untuk pelatihan dan 1

data ditinggalkan untuk pengujian. Bersamaan dengan proses ini, dilakukan pencarian parameter terbaik menggunakan *Grid Search* terhadap 108 kombinasi parameter. Evaluasi kinerja difokuskan untuk menekan nilai *Mean Absolute Error* (MAE).

Secara konseptual, tahapan pencarian parameter melalui skema LOOCV ini merupakan fase di mana proses pelatihan (*training*), validasi (*validation*), dan pengujian (*testing*) dieksekusi secara serentak di dalam satu siklus iterasi terintegrasi. Melalui pendekatan ini, evaluasi performa model dapat dilakukan secara menyeluruh terhadap data yang disembunyikan (*unseen data*) pada setiap iterasinya tanpa memerlukan pemisahan proporsi data di awal, sehingga representasi informasi penting dari keseluruhan populasi sampel tetap terjaga. Rincian proses komputasi iteratif beserta ekstraksi matriks evaluasi pada tahapan ini dijabarkan pada Kode 4.5.

Kode 4.5 Pelaksanaan LOOCV, *Grid Search*, dan Ekstraksi Evaluasi

```

1 from sklearn.model_selection import GridSearchCV, LeaveOneOut
2 from sklearn.ensemble import RandomForestRegressor
3
4 # Definisi kandidat parameter
5 param_grid = {
6     'n_estimators': [50, 100, 150],
7     'max_depth': [3, 5, 7, None],
8     'min_samples_leaf': [1, 2, 3],
9     'max_features': ['sqrt', 'log2', None]
10 }
11
12 model = RandomForestRegressor(random_state=42)
13 loocv = LeaveOneOut()
14 scorers = {'mae': 'neg_mean_absolute_error',
15           'rmse': 'neg_root_mean_squared_error'}
16
17 # Eksekusi Grid Search dengan LOOCV
18 grid_search = GridSearchCV(
19     estimator=model, param_grid=param_grid, cv=loocv,
20     scoring=scorers, refit='mae', return_train_score=True,
21     n_jobs=-1, verbose=2)
22 grid_search.fit(X, y)
23
24 # Ekstraksi dan peninjauan skor terbaik berdasarkan MAE
25 best_index = grid_search.best_index_
26 best_mae = -grid_search.cv_results_['mean_test_mae'][best_index]
27 best_rmse = -grid_search.cv_results_['mean_test_rmse'][best_index]
28
29 print(f"Kombinasi Parameter Optimal: {grid_search.best_params_}")
30 print(f"Skor MAE Terbaik: {best_mae:.2f}")
31 print(f"Skor RMSE Terbaik: {best_rmse:.2f}")


```

Hasil komputasi dari pencarian parameter optimal secara komprehensif

direpresentasikan pada Tabel 4.9. Berdasarkan matriks evaluasi, konfigurasi terbaik untuk algoritma *Random Forest Regressor* diperoleh pada kombinasi penggunaan 100 estimasi pohon (`n_estimators`), kedalaman maksimal 5 tingkat (`max_depth`), batas minimal 1 observasi pada simpul daun (`min_samples_leaf`), dan fungsi logaritma basis 2 untuk penyeleksian fitur maksimal (`max_features`). Penerapan pengaturan parameter tersebut secara komputasional menghasilkan tingkat penyimpangan prediksi terendah dengan skor *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE) yang masing-masing bernilai 3,44. Konsistensi perolehan angka minimal pada kedua metrik evaluasi tersebut mengonfirmasi tingkat stabilitas model dalam mengenali pola data. Selanjutnya, untuk memvalidasi performa model secara visual, dinamika proses pelatihan (*learning curve*) ditunjukkan pada Gambar 4.4.

Tabel 4.9 Hasil *Hyperparameter Tuning* Model *Random Forest*

No	Nama Parameter	Nilai Optimal
1	<code>n_estimators</code>	100
2	<code>max_depth</code>	5
3	<code>min_samples_leaf</code>	1
4	<code>max_features</code>	log2



Gambar 4.4 Kurva Pelatihan dan Validasi pada Proses *Hyperparameter Tuning*

4.1.4.2 Pelatihan Model Final

Setelah konfigurasi parameter terbaik berhasil diidentifikasi pada tahapan sebelumnya, proses dilanjutkan dengan pembentukan model final. Parameter optimal yang diperoleh dari proses *tuning* tersebut kemudian dikonfigurasi ke dalam algoritma *Random Forest Regressor* yang baru. Model final ini dilatih kembali (*retrain*) menggunakan keseluruhan 36 baris *dataset* populasi untuk mendapatkan pola pemetaan variabel fitur secara maksimal tanpa adanya reduksi sampel. Setelah model berhasil dilatih secara utuh, dilakukan prediksi terhadap nilai prevalensi *stunting* guna membandingkan kedekatan antara nilai target aktual dengan nilai tebakan dari sistem. Rincian implementasi deklarasi model dan eksekusi prediksi dapat dilihat pada Kode 4.6. Selanjutnya, sintaksis komputasi untuk memvisualisasikan sebaran kedekatan tersebut ditunjukkan pada Kode 4.7, dengan hasil komparasi aktual-prediksi direpresentasikan pada Tabel 4.10 dan Gambar 4.5.

Kode 4.6 Pelatihan Model dan Eksekusi Prediksi

```

1 import pandas as pd
2 import matplotlib.pyplot as plt
3
4 # Deklarasi model final dengan parameter terbaik
5 best_params = grid_search.best_params_
6 model_final = RandomForestRegressor(**best_params, random_state=42)
7
8 # Melatih model dengan seluruh observasi
9 model_final.fit(X, y)


```

```
10
11 # Melakukan prediksi pada data
12 y_pred = model_final.predict(X)
13
14 # Menyusun DataFrame komparasi
15 comparison_df = pd.DataFrame({
16     'Provinsi': plot_data_clean['Provinsi'],
17     'Actual': y, 'Predicted': y_pred,
18     'Difference': y - y_pred
19 }).sort_values('Actual')
20
21 pd.set_option('display.float_format', lambda x: '%.2f' % x)
```

Tabel 4.10 Cuplikan Perbandingan Nilai Aktual dan Prediksi

No	Provinsi	Aktual	Prediksi	Selisih
1	Bali	8,60	12,56	-3,96
2	Jawa Timur	14,70	16,77	-2,07
3	Kep. Riau	15,00	16,96	-1,96
...				
35	Sulawesi Barat	35,40	31,28	4,12
36	NTT	37,00	33,82	3,18

Rincian komparasi numerik pada Tabel 4.10 tersebut memberikan gambaran awal mengenai tingkat simpangan yang dihasilkan oleh model final. Agar mempermudah observasi terhadap pola sebaran selisih data secara komprehensif, hasil perbandingan antara nilai prevalensi *stunting* aktual dan tebakan prediksi divisualisasikan secara utuh pada Gambar 4.5. Representasi grafis ini memetakan kedekatan kedua nilai tersebut pada masing-masing dari 36 provinsi agar performa akurasi sistem dapat diinterpretasikan dengan lebih intuitif.



Gambar 4.5 Sebaran Nilai Aktual dan Prediksi *Stunting* per Provinsi

4.2 Evaluasi Performa Model

Tahapan evaluasi dilakukan untuk mengukur besaran tingkat penyimpangan (*error*) dan kesesuaian pola yang dihasilkan oleh model final terhadap keseluruhan populasi data. Sesuai dengan skema fase kedua, model final ini telah dilatih menggunakan 100% observasi tanpa adanya data yang disembunyikan. Oleh karena itu, evaluasi pada tahap ini tidak bertujuan untuk menguji generalisasi pada data baru (*testing*), melainkan untuk meninjau seberapa baik algoritma berhasil memetakan variabel fitur terhadap target aktualnya

sebelum memasuki tahapan ekstraksi interpretasi SHAP. Pendekatan evaluasi dilakukan melalui perhitungan matematis antara nilai tebakan model (*y_pred*) dan data realita (*y*). Metrik utama yang digunakan mencakup *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), *R-squared* (R^2), dan *Mean Absolute Percentage Error* (MAPE). Rincian sintaksis komputasi untuk kalkulasi metrik tersebut dieksekusi pada Kode 4.8, di mana hasil rangkumannya dicatat pada Tabel 4.11.

Kode 4.8 Perhitungan Metrik Evaluasi Regresi

```
1 from sklearn.metrics import mean_absolute_error, mean_squared_error,
   r2_score
2 import numpy as np
3
4 # Mengkalkulasi nilai metrik evaluasi
5 mae = mean_absolute_error(y, y_pred)
6 mse = mean_squared_error(y, y_pred)
7 rmse = np.sqrt(mse)
8 r2 = r2_score(y, y_pred)
9 mape = np.mean(np.abs((y - y_pred) / y)) * 100
10
11 print(f"MAE: {mae:.2f} | RMSE: {rmse:.2f}")
12 print(f"R-squared: {r2:.4f} | MAPE: {mape:.2f}%")
```

Berdasarkan hasil evaluasi pada Tabel 4.11, model *Random Forest* mampu merekam pola *dataset* dengan nilai determinasi (R^2) sebesar 0,9090. Hal ini mengindikasikan bahwa model dapat menjelaskan 90,9% variabilitas penyebab *stunting* secara representatif. Di sisi lain, persentase deviasi prediksi yang ditunjukkan oleh nilai MAPE mencatatkan angka 7,22%, yang mengklasifikasikan performa model ke dalam kategori akurat.

Tabel 4.11 Hasil Evaluasi Performa Model Regresi Final

No	Metrik Evaluasi	Skor
1	<i>Mean Absolute Error</i> (MAE)	1,40
2	<i>Root Mean Squared Error</i> (RMSE)	1,77
3	<i>R-Squared</i> (R^2)	0,9090
4	<i>Mean Absolute Percentage Error</i> (MAPE)	7,22%

4.3 Analisis Hasil Pemodelan *Random Forest*

Setelah semua tahapan pembuatan model dan pengujian selesai dilakukan, bagian ini akan membahas hasil yang diperoleh. Analisis ini bertujuan untuk meninjau kecocokan pengaturan parameter, pola prediksi model, dan nilai evaluasinya. Pembahasan ini penting sebagai pengantar yang logis sebelum masuk ke tahap interpretasi fitur menggunakan SHAP. Rincian analisis tersebut dijelaskan pada poin-poin berikut.

4.3.1 Analisis Konfigurasi Parameter

Tahap konfigurasi parameter membahas kecocokan hasil *tuning* optimal yang sebelumnya telah dirangkum pada Tabel 4.9. Pemilihan nilai *max_depth* sebesar 5 menunjukkan bahwa pembatasan kedalaman pohon efektif untuk *dataset* dengan jumlah observasi yang sedikit. Langkah ini dilakukan untuk mencegah algoritma menghafal data latih secara berlebihan. Selain itu, penggunaan parameter *max_features* berupa *log2* memastikan setiap variabel memiliki kesempatan yang sama untuk dievaluasi pada tiap cabang pohon. Pengaturan ini membantu model agar belajar lebih baik dan terhindar dari masalah *overfitting*.

4.3.2 Analisis Pola Prediksi *Stunting* per Provinsi

Pola tebakan model dapat diamati melalui komparasi pada Tabel 4.10 dan visualisasi *scatter plot* pada Gambar 4.5. Secara umum, garis prediksi menunjukkan tren yang sejalan dengan nilai aslinya di sebagian besar wilayah. Namun, masih terdapat sedikit perbedaan estimasi pada provinsi dengan tingkat prevalensi terendah seperti Bali, dan tertinggi seperti Nusa Tenggara Timur. Hal ini terjadi karena algoritma *Random Forest* bekerja dengan cara mengambil nilai rata-rata (*averaging*) dari banyak pohon keputusan. Cara kerja ini membuat prediksi model menjadi lebih stabil dan tidak mudah terpengaruh oleh data ekstrem (*outlier*), sehingga hasilnya tetap berada pada batas yang masuk akal

secara statistik.

4.3.3 Analisis Metrik Evaluasi

Setelah meninjau sebaran kedekatan nilai prediksi secara visual pada tahapan sebelumnya, performa dari model referensi final perlu dikuantifikasi secara matematis menggunakan tolok ukur yang objektif. Kualitas model dalam mengenali pola data dikonfirmasi oleh perolehan matriks evaluasi pada Tabel 4.11. Skor *Mean Absolute Error* (MAE) sebesar 1,40 mengindikasikan bahwa rata-rata selisih absolut antara tebakan sistem dengan realita prevalensi *stunting* hanya terpaut sebesar 1,40%. Nilai *Root Mean Squared Error* (RMSE) sebesar 1,77, yang secara proporsional tidak terpaut jauh dari MAE, menunjukkan bahwa model cukup stabil dan terhindar dari penyimpangan residual yang ekstrem. Lebih lanjut, koefisien determinasi (R^2) sebesar 0,9090 membuktikan bahwa variabel prediktor yang digunakan secara kolektif mampu menjelaskan 90,9% variansi prevalensi *stunting*. Diperkuat dengan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 7,22% yang berada di ambang batas sangat baik (di bawah 10%), dapat disimpulkan bahwa model telah berhasil memetakan pola hubungan antar variabel secara komprehensif pada observasi populasi SSGI 2024.

Meskipun algoritma telah menunjukkan tingkat kesesuaian (*fitting*) yang tinggi, metrik tersebut merepresentasikan evaluasi pada data pelatihan secara utuh, sehingga model final ini difokuskan sebagai model referensi interpretasi, bukan dideklarasikan untuk ekstrapolasi atau estimasi pada data baru. Kendala utama dari algoritma berbasis *ensemble* seperti *Random Forest* adalah sifatnya yang *black-box*, sehingga mekanisme internal pembobotan keputusannya tidak dapat diobservasi secara langsung. Di sisi lain, rumusan rekomendasi penanganan *stunting* yang presisi membutuhkan transparansi mengenai determinan mana yang paling berpengaruh. Oleh karena itu, tahapan analisis selanjutnya dikhususkan untuk menguraikan model final

tersebut menggunakan pendekatan *SHapley Additive exPlanations* (SHAP) guna mengekstraksi besaran dan arah kontribusi dari masing-masing fitur secara saintifik dan transparan.

4.4 Interpretasi Model Menggunakan SHAP

Mengacu pada batasan algoritma *Random Forest* yang bersifat kotak hitam, tahapan ini difokuskan pada interpretasi hasil prediksi menggunakan SHAP. Pendekatan ini digunakan untuk mengetahui besaran pengaruh dari masing-masing variabel independen terhadap angka prevalensi *stunting*. Analisis SHAP dalam penelitian ini dibagi menjadi dua ruang lingkup, yaitu analisis skala global dan analisis skala lokal. Pembagian ini bertujuan untuk melihat gambaran besar faktor penentu di tingkat nasional, sekaligus mengamati alasan spesifik di balik hasil prediksi pada masing-masing provinsi.

Proses interpretasi diawali dengan menginisialisasi objek pembaca model (*explainer*) ke dalam sistem. Karena *Random Forest* merupakan algoritma yang dibangun dari sekumpulan pohon keputusan, pustaka SHAP menyediakan fungsi khusus berupa *TreeExplainer* untuk membaca struktur model tersebut secara efisien. Setelah model berhasil dibaca, sistem akan menghitung matriks nilai SHAP untuk mengukur seberapa besar dorongan atau tarikan setiap variabel terhadap hasil tebakan akhir. Rincian deklarasi algoritma SHAP beserta pengecekan dimensi *output*-nya ditunjukkan pada Kode 4.9.

Kode 4.9 Inisialisasi *TreeExplainer* dan Ekstraksi Nilai SHAP

```

1 import shap
2 import numpy as np
3
4 # Inisialisasi SHAP explainer untuk model berbasis pohon
5 explainer = shap.TreeExplainer(model_final)
6 shap_values = explainer.shap_values(X)
7
8 # Pengecekan dimensi matriks SHAP values
9 print("Dimensi SHAP values:", np.shape(shap_values))
10 # Output: (36, 54)

```

4.4.1 Interpretasi Global (*Global Explanation*)

Interpretasi skala global bertujuan untuk melihat pola pengambilan keputusan model terhadap seluruh data observasi tingkat nasional. Pendekatan ini berfokus pada evaluasi dampak masing-masing variabel secara umum sebelum meninjau kasus pada wilayah yang lebih spesifik. Proses interpretasi model pada tahapan ini dibagi ke dalam tiga bentuk visualisasi utama. Visualisasi tersebut mencakup identifikasi urutan variabel penentu, pengamatan arah pengaruh fitur, dan peninjauan batas angka kritis dari indikator utama. Rincian penjelasan untuk masing-masing tahapan analisis ini diuraikan pada sub-subbab berikut.

4.4.1.1 Tingkat Kepentingan Fitur (*Feature Importance Plot*)


Tahap awal interpretasi dilakukan dengan melihat tingkat kepentingan fitur melalui perhitungan rata-rata nilai absolut SHAP. Proses ini bertujuan untuk mengetahui variabel mana yang memiliki kontribusi paling besar terhadap prediksi model secara umum. Kode 4.10 menunjukkan implementasi fungsi `summary_plot` untuk menghasilkan diagram batang yang mengurutkan fitur-fitur tersebut. Hasil visualisasi dari kode tersebut kemudian ditampilkan pada Gambar 4.6. Melalui grafik ini, urutan indikator kesehatan yang menjadi penentu angka *stunting* di Indonesia dapat diidentifikasi secaraurut.

Kode 4.10 Visualisasi Tingkat Kepentingan Fitur Global

```

1  import matplotlib.pyplot as plt
2
3  # Visualisasi Bar Plot untuk 20 fitur paling berpengaruh
4  shap.summary_plot(shap_values, X, plot_type="bar",
5                    max_display=20, show=False)
6
7  fig = plt.gcf()
8  fig.set_size_inches(10, 8)
9  plt.title("Rata-rata Dampak Absolut Fitur terhadap Stunting",
10           fontsize=14)
11 plt.tight_layout()
    plt.show()

```



Gambar 4.6 Rata-Rata Dampak Absolut Fitur terhadap *Stunting* (*SHAP Bar Plot*)

Tabel 4.12 Keterangan Istilah Variabel pada *SHAP Bar Plot*

No	Nama Variabel di Grafik	Keterangan / Makna Istilah
1	persen.tidak.memenuhi.mmff	<i>Minimum Milk Feeding Frequency</i> (Persentase balita non-ASI yang kurang asupan susu minimal 2 kali sehari).
2	persen.tidak.memenuhi.mdd	<i>Minimum Dietary Diversity</i> (Persentase balita yang kurang keberagaman jenis kelompok makanan harian).
3	persen.cakupan.pmt	Pemberian Makanan Tambahan (Bantuan pangan gizi untuk balita atau ibu hamil berisiko).
4	persen.tidak.memenuhi.mad	<i>Minimum Acceptable Diet</i> (Gabungan indikator frekuensi makan dan keberagaman jenis makanan minimal).
5	persen.cakupan.ttd	Tablet Tambah Darah (Suplemen zat besi untuk mencegah anemia pada ibu hamil atau remaja putri).
6	persen.kunjungan.anc	<i>Antenatal Care</i> (Pelayanan pemeriksaan kesehatan ibu selama masa kehamilan oleh tenaga medis).
7	persen.pendampingan.tpk	Tim Pendamping Keluarga (Tim yang mendampingi keluarga berisiko <i>stunting</i> di tingkat desa/kelurahan).
8	persen.kepemilikan.kia	Kesehatan Ibu dan Anak (Merujuk pada kepemilikan dan penggunaan Buku KIA untuk pemantauan kesehatan).
9	persen.usia.ibu.berisiko	Persentase ibu melahirkan pada usia berisiko (di bawah 20 tahun atau di atas 35 tahun).

Visualisasi *Global Feature Importance* pada Gambar 4.6 menunjukkan besaran rata-rata kontribusi absolut dari setiap variabel prediktor. Berdasarkan hasil ekstraksi SHAP, variabel `persen_tidak_memenuhi_mmff` atau persentase balita non-ASI yang tidak mendapatkan asupan susu minimal dua kali sehari (*Minimum Milk Feeding Frequency*) menempati peringkat pertama sebagai determinan paling dominan. Secara keilmuan gizi, susu merupakan sumber utama protein hewani, kalsium, dan faktor pertumbuhan esensial yang sangat krusial bagi pembentukan linear tulang anak pada masa 1000 Hari Pertama Kehidupan (HPK) [SITASI 1]. Defisiensi asupan ini secara langsung memicu malnutrisi kronis yang bermanifestasi menjadi *stunting*.

Faktor paling berpengaruh kedua dalam model adalah persentase kehamilan pada wanita dengan usia berisiko. Kehamilan pada usia yang belum matang secara biologis memicu terjadinya kompetisi pemenuhan nutrisi antara janin dengan tubuh ibu yang masih dalam tahap pertumbuhan. Kondisi ini secara signifikan meningkatkan probabilitas bayi lahir dengan Berat Badan Lahir Rendah (BBLR) serta panjang badan di bawah standar, yang merupakan prediktor kuat terjadinya *stunting* di kemudian hari [SITASI 2].

Selanjutnya, variabel `persen_tidak_memenuhi_mdd` atau kurangnya *Minimum Dietary Diversity* (MDD) menempati posisi ketiga. Hal ini menegaskan bahwa kuantitas frekuensi makan tidak akan optimal jika tidak diimbangi dengan keberagaman jenis pangan. Kegagalan memenuhi variasi kelompok makanan harian dapat menyebabkan anak mengalami *hidden hunger* (kelaparan tersembunyi), yaitu defisiensi mikronutrien spesifik seperti zink, zat besi, dan vitamin A yang sangat vital bagi metabolisme dan pertumbuhan seluler [SITASI 3].

Temuan dari algoritma ini memberikan wawasan (*insight*) bahwa determinan proksimal yang berkaitan langsung dengan kualitas asupan gizi rumah tangga dan kesiapan biologis ibu memiliki bobot dampak yang lebih kuat terhadap prevalensi *stunting* dibandingkan faktor infrastruktur atau fasilitas

kesehatan. Akses terhadap fasilitas kesehatan cenderung bersifat sebagai faktor distal (tidak langsung), di mana keberadaannya tidak akan menurunkan angka *stunting* secara optimal apabila akar permasalahan nutrisi harian tingkat individu tidak teratasi [SITASI 4]. Identifikasi peringkat ini menjadi landasan komprehensif untuk melakukan analisis yang lebih mendalam pada tahapan distribusi arah pengaruh variabel selanjutnya.

4.4.1.2 Arah dan Distribusi Dampak Fitur (*Summary Plot*)


Tahapan analisis selanjutnya difokuskan pada pengamatan arah pengaruh dari masing-masing variabel terhadap hasil keluaran model. Pemetaan arah distribusi ini dilakukan dengan mengeksekusi Kode 4.11 untuk menghasilkan visualisasi *SHAP Summary Plot*. Hasil komputasi dari kode tersebut ditampilkan dalam bentuk grafik sebaran pada Gambar 4.7. Karena visualisasi ini menggunakan urutan fitur yang identik dengan tahapan sebelumnya, pembaca dapat merujuk kembali pada Tabel 4.1 untuk melihat keterangan label. Grafik ini menggunakan parameter gradasi warna untuk merepresentasikan angka asli pada data, di mana merah berarti tinggi dan biru berarti rendah.

Kode 4.11 Visualisasi Arah dan Distribusi Dampak Fitur

```

1  import matplotlib.pyplot as plt
2
3  # Visualisasi sebaran arah pengaruh fitur (Summary Plot/Beeswarm)
4  shap.summary_plot(shap_values, X, show=False)
5
6  fig = plt.gcf()
7  fig.set_size_inches(10, 8)
8  plt.title("Arah dan Distribusi Dampak Fitur (Summary Plot)",
9           fontsize=14)
10 plt.tight_layout()
    plt.show()

```



Gambar 4.7 Arah dan Distribusi Dampak Fitur terhadap *Stunting* (SHAP Summary Plot)

Berdasarkan Gambar 4.7, terlihat bagaimana tiga variabel utama memberikan dorongan kenaikan terhadap tebakan prevalensi model. Pada variabel `persen_tidak_memenuhi_mmff`, sebaran titik berwarna merah mendominasi area di sebelah kanan garis tegak (nol). Pola serupa juga ditemukan secara konsisten pada variabel persentase usia ibu berisiko dan kurangnya pemenuhan MDD. Sebaran ini membuktikan bahwa semakin tinggi persentase masalah kelengkapan gizi dan risiko usia ibu, maka prediksi kasus *stunting* di suatu wilayah akan bertambah. Hasil distribusi warna yang sejalan dengan teori kesehatan ini menandakan bahwa algoritma telah berhasil memetakan pola

sebab-akibat dengan akurat.

4.4.1.3 Analisis Ketergantungan Fitur (*Dependence Plot*)


Langkah terakhir dalam analisis skala global adalah menginterpretasikan distribusi nilai dari lima variabel dengan peringkat tertinggi. Pendekatan ini dilakukan menggunakan visualisasi *SHAP Dependence Plot* untuk mencari titik batas perubahan pengaruh pada masing-masing indikator. Eksekusi sintaksis perulangan untuk menghasilkan kelima grafik tersebut secara berurutan ditunjukkan pada Kode 4.12. Visualisasi yang dihasilkan kemudian dianalisis untuk melihat pada rentang angka berapa suatu variabel mulai merubah arah keputusan model. Penjelasan rincian dari setiap grafik dijabarkan pada paragraf-paragraf di bawah ini.

Kode 4.12 Visualisasi Ketergantungan Lima Fitur Teratas

```

1  import matplotlib.pyplot as plt
2
3  # Daftar 5 fitur teratas berdasarkan SHAP
4  top5_features = [
5      "persen_tidak_memenuhi_mmff",
6      "persen_usia_ibu_berisiko",
7      "persen_tidak_memenuhi_mdd",
8      "persen_tidak_dapat_pmt",
9      "persen_akses_sanitasi_berisiko"
10 ]
11
12 # Visualisasi dependence plot per fitur
13 for feature in top5_features:
14     plt.figure(figsize=(7, 5))
15     shap.dependence_plot(
16         feature, shap_values, X,
17         interaction_index=None,
18         show=False
19     )
20     plt.title(f"SHAP Dependence Plot - {feature.replace('_', ' ')}")
21     plt.xlabel("Nilai Fitur", fontsize=11)
22     plt.ylabel("SHAP Value (Pengaruh terhadap Risiko Stunting)",
23               fontsize=11)
24     plt.tight_layout()
25     plt.show()

```





Gambar 4.8 *Dependence Plot* Variabel Persen Tidak Memenuhi MMFF

Gambar 4.8 menampilkan grafik ketergantungan untuk fitur persentase tidak memenuhi MMFF. Berdasarkan sebaran titik pada visualisasi tersebut, nilai SHAP berada secara stabil di area negatif saat angka observasi berada di bawah 22%. Namun, terdapat lonjakan drastis yang menyeberangi sumbu nol menuju area positif ketika persentase fitur melampaui ambang batas 22% hingga 25%. Semakin nilai persentase menjauhi batas tersebut ke arah kanan, dorongan terhadap risiko prediksi *stunting* menjadi semakin tinggi secara signifikan. Pola ini membuktikan bahwa kurangnya asupan susu pada balita non-ASI memiliki batas toleransi maksimal di kisaran 22% sebelum memicu lonjakan kasus.

Pola lonjakan risiko yang teridentifikasi setelah melewati ambang batas 22% tersebut mengonfirmasi tingginya kerentanan biologis balita non-ASI terhadap defisiensi protein hewani secara komunal. Secara keilmuan gizi dan pediatri, susu merupakan substitusi krusial yang menyumbangkan asam amino esensial, kalsium, dan mineral fosfor bagi anak yang tidak lagi menerima Air Susu Ibu (ASI). Ketiadaan asupan profil asam amino yang adekuat secara persisten terbukti secara klinis menekan sekresi *Insulin-like Growth Factor 1* (IGF-1), yakni hormon peptida spesifik yang paling bertanggung jawab dalam

menstimulasi proliferasi kondrosit dan pemanjangan tulang linear pada masa balita [SITASI 25]. Lebih lanjut, transisi drastis nilai SHAP menuju area pendorong risiko positif ketika persentase wilayah melampaui batas toleransi tersebut merepresentasikan titik kegagalan kompensasi gizi populasi. Apabila tingkat deprivasi asupan susu bergeser menjadi fenomena yang masif, mekanisme pertahanan tubuh balita tidak lagi mampu menutupi defisit gizi absolut melalui sumber pangan alternatif harian, sehingga bermanifestasi menjadi hambatan pertumbuhan massal [SITASI 26]. Visualisasi presisi dari algoritma ini secara saintifik memvalidasi urgensi pemenuhan asupan susu minimal sebagai jaring pengaman nutrisi wajib untuk mencegah malnutrisi kronis pada kelompok anak pasca-penyapihan.




Gambar 4.9 *Dependence Plot* Variabel Persen Usia Ibu Berisiko

Visualisasi ketergantungan untuk persentase usia ibu berisiko ditunjukkan pada Gambar 4.9. Grafik ini memperlihatkan pola lonjakan nilai SHAP yang tegas ketika angka asli fitur melewati ambang batas 14%. Pada rentang persentase di bawah 14%, dampak yang diberikan cenderung bernilai negatif atau menekan angka prediksi. Sebaliknya, ketika persentase wilayah menyentuh angka 15% ke atas, hasil tebakan langsung mendapat dorongan positif yang memicu kenaikan

prediksi. Karakteristik ini mengindikasikan bahwa intervensi pencegahan kehamilan pada usia berisiko sebaiknya diupayakan agar tidak melampaui batas 14%.

Lonjakan risiko yang teramati ketika prevalensi usia ibu berisiko melampaui batas kritis tersebut sejalan dengan kajian biologi reproduksi dan obstetri. Kehamilan pada usia reproduksi ekstrem, khususnya pada fase remaja (di bawah 20 tahun), memicu terjadinya kompetisi biologis dalam penyerapan nutrisi esensial antara tubuh ibu yang masih dalam masa pertumbuhan linear dengan janin yang sedang dikandung (*maternal-fetal competition*). Kompetisi ini secara langsung membatasi aliran oksigen dan transfer mikronutrien melalui plasenta, yang berdampak pada tingginya probabilitas *Intrauterine Growth Restriction* (IUGR) dan kelahiran bayi dengan Berat Badan Lahir Rendah (BBLR) [SITASI 23]. Di sisi lain, kehamilan pada kelompok usia lanjut (di atas 35 tahun) turut membawa risiko penurunan fungsi organ reproduksi dan insufisiensi plasenta yang secara sistemik menghambat laju pertumbuhan janin secara intrauterin [SITASI 24]. Transisi nilai perhitungan matematis menuju area pendorong risiko positif secara masif setelah melewati ambang batas 14% membuktikan bahwa beban akumulasi kelahiran bayi dengan kerentanan fisik sejak lahir dapat menciptakan efek bola salju (*snowball effect*) yang memperburuk angka prevalensi secara komunal. Temuan ini secara saintifik memvalidasi urgensi optimalisasi program edukasi kesehatan reproduksi dan perencanaan keluarga untuk menjaga persentase wilayah di bawah ambang batas toleransi algoritma tersebut.




Gambar 4.10 *Dependence Plot* Variabel Persen Tidak Memenuhi MDD

Analisis ketergantungan untuk persentase balita tidak memenuhi MDD dapat diamati melalui sebaran titik pada Gambar 4.10. Indikator keberagaman makanan ini menunjukkan pola hubungan naik yang sejalan dengan peningkatan nilai aslinya. Titik kritis dari variabel ini terlihat secara jelas berada di sekitar angka 55% ketika melewati sumbu nol. Semakin nilai persentase bergerak menjauhi ambang batas tersebut menuju angka 80%, risiko prevalensi yang ditebak oleh model menjadi semakin tinggi. Pola distribusi ini menegaskan bahwa peningkatan masalah keberagaman asupan gizi secara proporsional akan menambah tinggi prediksi kasus di suatu wilayah.

Pola peningkatan risiko yang berbanding lurus dengan tingginya ketiadaan keberagaman pangan ini sejalan dengan patofisiologi malnutrisi kronis pada anak. Secara keilmuan gizi, ketergantungan pada pola makan monoton yang umumnya hanya didominasi oleh sumber karbohidrat tunggal akan memicu terjadinya defisiensi mikronutrien esensial multisistemik atau *hidden hunger*. Ketidakmampuan dalam memenuhi spektrum nutrisi dari berbagai kelompok pangan mengakibatkan tubuh kekurangan kofaktor vital seperti zink, zat besi, dan vitamin A yang bertugas meregulasi sintesis hormon pertumbuhan, pembelahan


sel osteoblas, serta diferensiasi jaringan fungsional pembentuk tulang [SITASI 21]. Lebih lanjut, transisi arah tarikan nilai SHAP menjadi positif secara masif ketika melewati ambang batas 55% mengindikasikan bahwa suatu wilayah akan kehilangan efek daya lenting gizi (*nutritional resilience*) apabila lebih dari separuh populasi balitanya terjebak dalam krisis variasi asupan harian [SITASI 22]. Pemetaan matematis dari algoritma ini secara saintifik memvalidasi urgensi penganekaragaman konsumsi pangan berbasis sumber daya lokal sebagai strategi krusial dalam pencegahan *stunting* primer.



Gambar 4.11 *Dependence Plot* Variabel Persen Tidak Dapat PMT

Gambar 4.11 menjelaskan sebaran dampak dari variabel persentase sasaran yang tidak mendapatkan Pemberian Makanan Tambahan (PMT). Persebaran data pada visualisasi ini menunjukkan tarikan nilai SHAP yang tinggi saat angka asli fitur berada di bawah 85%. Ketika persentase fitur mendekati rentang 90% hingga 95%, dampak variabel mulai melemah dan berpindah ke area nol hingga negatif. Karakteristik bentuk ini memperlihatkan dinamika kontribusi ketiadaan PMT yang tidak selalu lurus berbanding dengan prediksi hasil. Hasil pemetaan batas persentase ini memberikan informasi pendukung untuk mengevaluasi pemerataan bantuan PMT di wilayah observasi.

Terdapat situasi non-linear yang ditangkap oleh model ini merepresentasikan karakteristik program Pemberian Makanan Tambahan (PMT) yang sejatinya berfungsi sebagai intervensi gizi spesifik yang bersifat kuratif dan komplementer, bukan sebagai substitusi asupan gizi harian. Secara keilmuan gizi kesehatan masyarakat, tingginya lonjakan risiko pada rentang ketiadaan PMT di bawah 85% mengindikasikan bahwa pada tingkat tersebut, kelompok rentan sangat bergantung pada suplementasi eksternal untuk menutup defisit makronutrien (*energy-protein gap*) yang tidak mampu terpenuhi secara mandiri oleh rumah tangga [SITASI 19]. Namun, ketika persentase ketiadaan bantuan menyentuh skala ekstrem (90% hingga 95%), daya ungkit variabel ini cenderung melemah dan terdistraksi. Hal ini secara epidemiologis dapat dijelaskan oleh pergeseran dominasi faktor determinan. Wilayah dengan tingkat kegagalan intervensi setinggi itu umumnya berhadapan dengan kerusakan sistemik pada infrastruktur kesehatan dan ketahanan pangan dasar. Dalam kondisi krisis multisektoral tersebut, keparahan prevalensi *stunting* lebih didikte secara langsung oleh ketiadaan asupan pokok absolut harian (seperti MDD dan MMFF) maupun keparahan infeksi lingkungan, sehingga ketiadaan PMT tidak lagi menjadi variabel penentu utama yang membedakan peningkatan risiko di dalam algoritma [SITASI 20]. Dinamika matematis ini memvalidasi hipotesis bahwa efektivitas PMT sangat bergantung pada ketepatan sasaran distribusi (*targeting accuracy*) di tengah kondisi ketahanan pangan yang bervariasi.



Gambar 4.12 *Dependence Plot* Variabel Persen Akses Sanitasi Berisiko

Grafik ketergantungan kelima yang menjelaskan persentase akses sanitasi berisiko ditampilkan pada Gambar 4.12. Distribusi titik data pada sumbu vertikal memperlihatkan kecenderungan pergerakan naik secara berkelanjutan. Variabel sanitasi mulai memberikan sumbangsih positif terhadap peningkatan prediksi *stunting* ketika angkanya melewati batas kritis 10%. Pada persentase di bawah angka batas tersebut, nilai perhitungan SHAP berada di area negatif yang mendeskripsikan penurunan angka tebakan. Pemetaan dari model ini membuktikan bahwa wilayah observasi perlu menekan persentase ketiadaan akses sanitasi layak di bawah batas 10%.

Korelasi linear antara ketiadaan fasilitas sanitasi yang layak dengan peningkatan risiko *stunting* secara langsung berkaitan dengan tingginya paparan patogen lingkungan. Secara kajian kesehatan masyarakat, tingginya proporsi akses sanitasi berisiko memfasilitasi transmisi patogen fekal-oral yang memicu penyakit infeksi enterik berulang serta *Environmental Enteric Dysfunction* (EED). Peradangan kronis pada saluran pencernaan akibat EED mengakibatkan atrofi vili usus, sehingga memicu malabsorpsi nutrisi esensial yang sejatinya sangat dibutuhkan untuk proses osteogenesis atau pembentukan tulang [SITASI 17].

Lebih lanjut, terbentuknya ambang batas kritis pada angka 10% mengindikasikan berlakunya konsep perlindungan kelompok (*herd protection*) dalam ekologi kesehatan lingkungan. Apabila persentase rumah tangga tanpa sanitasi layak melampaui batas toleransi tersebut, tingkat akumulasi kontaminasi patogen pada sumber air dan tanah akan mencapai beban paparan yang terlalu masif untuk dinetralisasi oleh sistem imun balita [SITASI 18]. Pemetaan ambang batas dari algoritma ini secara saintifik memvalidasi urgensi pemerataan infrastruktur sanitasi dasar sebagai prasyarat wajib agar intervensi gizi yang diberikan dapat diserap secara optimal oleh tubuh anak.

4.4.2 Interpretasi Lokal (*Local Explanation*)

Analisis skala lokal bertujuan untuk menjelaskan proses pengambilan keputusan algoritma pada satu observasi data yang spesifik. Berbeda dengan pendekatan global yang memetakan tren secara keseluruhan, tahapan ini berfokus pada faktor-faktor pendorong hasil tebakan pada kasus tunggal. Pendekatan ini berguna untuk memahami alasan di balik tingginya atau rendahnya prediksi prevalensi *stunting* pada sampel wilayah tertentu. Visualisasi pada tahap ini akan menampilkan bagaimana masing-masing variabel berkontribusi secara rinci dalam menambah atau menekan nilai dasar model. Hasil interpretasi dari observasi tunggal ini kemudian dapat diuraikan sebagai rujukan evaluasi khusus bagi wilayah yang bersangkutan.

4.4.2.1 Kriteria Pemilihan Sampel Wilayah

Sebelum melakukan ekstraksi visualisasi *Local Explanation*, tahap penentuan sampel observasi perlu dilakukan agar analisis lebih terarah. Pemilihan sampel provinsi pada penelitian ini menggunakan teknik *purposive sampling* yang didasarkan pada enam kriteria kondisi demografis dan tingkat prevalensi. Keenam sampel tersebut dirancang untuk merepresentasikan berbagai variasi keadaan yang memengaruhi hasil tebakan algoritma secara

spesifik. Melalui variasi observasi ini, model diharapkan mampu menunjukkan perbedaan pola pengambilan keputusan pada setiap kasus secara transparan.

Kriteria pertama difokuskan pada kedekatan geografis dan keterwakilan regional Pulau Sumatera sebagai lokasi institusi tempat penelitian ini dilakukan. Provinsi Lampung dipilih sebagai representasi wilayah utama karena merupakan domisili pelaksanaan penelitian di Institut Teknologi Sumatera. Selain Lampung, Provinsi Aceh dan Sumatera Utara turut dipilih untuk mewakili karakteristik regional Sumatera masing-masing, yakni sebagai wilayah dengan angka prevalensi *stunting* tertinggi dan wilayah dengan populasi terpadat di pulau tersebut yang mencapai lebih dari 15,4 juta jiwa [SITASI 1]. Peninjauan khusus pada ketiga provinsi ini bertujuan untuk memberikan kontribusi akademis yang relevan terhadap identifikasi dan penanganan masalah kesehatan di wilayah Sumatera.

Kriteria selanjutnya mencakup pemilihan provinsi yang memegang rekor ekstrem pada skala nasional untuk melihat respons model terhadap kondisi data yang kontras. Analisis pada wilayah dengan prevalensi tertinggi secara nasional, yakni Provinsi Nusa Tenggara Timur (NTT) dengan angka *stunting* mencapai 37,0% [SITASI 2], bertujuan untuk menemukan pemicu utama krisis gizi. Sementara itu, Provinsi Bali yang berhasil menekan prevalensi hingga menyentuh angka terendah secara nasional sebesar 8,7% [SITASI 3] berfungsi sebagai pembanding keberhasilan intervensi. Provinsi Jawa Barat sebagai wilayah dengan populasi penduduk terpadat di tingkat nasional yang menembus lebih dari 50,4 juta jiwa [SITASI 4] juga disertakan untuk meninjau dampak persaingan akses sumber daya terhadap hasil prediksi. Penggabungan sampel regional dan nasional ini ditujukan agar visualisasi skala lokal dapat memberikan gambaran yang menyeluruh mengenai kinerja model *machine learning*.

4.4.2.2 Analisis Skala Lokal (*Waterfall Plot*)

Tahapan interpretasi skala lokal dilakukan dengan mengeksekusi visualisasi *SHAP Waterfall Plot* untuk menginterpretasikan data observasi secara spesifik. Proses komputasi ini bertujuan untuk menguraikan kontribusi masing-masing variabel dalam mendorong atau menekan nilai rata-rata dasar prediksi model (*base value*) yang berada pada angka 22,375. Implementasi ekstraksi grafik untuk seluruh provinsi secara otomatis beserta proses penyimpanannya ditunjukkan pada Kode 4.13. Berdasarkan hasil pemrosesan tersebut, analisis mendalam difokuskan pada enam provinsi yang telah ditetapkan melalui kriteria *purposive sampling* sebelumnya. Rincian penjabaran kontribusi fitur penentu *stunting* untuk keenam sampel wilayah tersebut diuraikan sebagai berikut.


Kode 4.13 Visualisasi dan Ekstraksi *Waterfall Plot* Seluruh Provinsi

```

1  # SHAP waterfall plot value for a specific province
2  explainer = shap.TreeExplainer(model_final)
3  shap_values = explainer(X)
4
5  nama_folder = "hasil_waterfall_stunting"
6
7  if not os.path.exists(nama_folder):
8      os.makedirs(nama_folder)
9      print(f"Folder '{nama_folder}' berhasil dibuat!")
10
11  daftar_provinsi = plot_data_clean['Provinsi'].tolist()
12
13  for i in range(len(shap_values)):
14      prov_name = daftar_provinsi[i]
15      file_name = f"waterfall_{prov_name.replace(' ', '_')}.png"
16      path_simpan = os.path.join(nama_folder, file_name)
17
18      plt.figure(figsize=(10, 7))
19      shap.plots.waterfall(shap_values[i], show=False)
20      plt.suptitle(f"Kontribusi Fitur terhadap Prediksi Stunting -
21                  Provinsi {prov_name}",
22                  fontsize=14, y=1.05, fontweight='bold')
23
24      plt.figtext(
25          0.5, -0.02,
26          "Merah = menaikkan risiko stunting | Biru = menurunkan
27          risiko stunting",
28          ha='center', fontsize=11, color='gray', style='italic'
29      )
30
31      plt.tight_layout()
32      plt.savefig(path_simpan, dpi=300, bbox_inches='tight')
33      plt.show()
34      plt.close()
35
36  print(f"\nSelesai! Semua gambar sudah tersimpan di folder:
37        {nama_folder}")

```

1. Provinsi Lampung (Representasi Domisili Institusi)




Gambar 4.13 *Waterfall Plot* Prediksi *Stunting* Provinsi Lampung

Visualisasi pada Gambar 4.13 menampilkan distribusi pengaruh fitur untuk Provinsi Lampung dengan hasil tebakan akhir sebesar 18,63. Penurunan dari nilai dasar ini didominasi secara penuh oleh kontribusi negatif (warna biru) dari mayoritas indikator kesehatan. Faktor sasaran balita tidak dapat PMT, risiko akses sanitasi, dan persentase usia ibu berisiko menjadi variabel teratas yang menekan angka prevalensi. Tarikan searah tanpa adanya perlawanan balok merah ini mengindikasikan bahwa fasilitas kesehatan dasar di wilayah Lampung secara umum sudah cukup menekan potensi lonjakan kasus *stunting*.

2. Provinsi Aceh (Prevalensi Tertinggi Regional Sumatera)


Kontribusi Fitur terhadap Prediksi Stunting - Provinsi Aceh



Gambar 4.14 Waterfall Plot Prediksi Stunting Provinsi Aceh

Observasi skala lokal untuk Provinsi Aceh memproyeksikan tebakan model yang melonjak tinggi menuju angka 26,301. Berdasarkan Gambar 4.14, peningkatan ini didorong kuat oleh sekumpulan balok merah yang mempresentasikan nilai positif terhadap prediksi risiko. Variabel kurangnya pemenuhan MMFF dan jarangny pemantauan pertumbuhan balita menjadi pemicu utama dengan kontribusi dorongan terbesar. Tingginya tumpukan fitur pembawa risiko ini merepresentasikan akar permasalahan gizi yang memerlukan intervensi segera di wilayah tersebut.

3. Provinsi Sumatera Utara (Populasi Terpadat Regional Sumatera)




Gambar 4.15 Waterfall Plot Prediksi Stunting Provinsi Sumatera Utara

Dinamika kontribusi yang saling mengimbangi terlihat pada grafik distribusi Provinsi Sumatera Utara di Gambar 4.15. Prediksi model untuk wilayah ini berakhir pada angka 22,501, yang sangat mendekati nilai rata-rata dasar prediksi nasional. Penekanan risiko oleh variabel pemenuhan MAD dan usia ibu berisiko mendapat perlawanan dari dorongan risiko akibat indikator tidak KB pasca salin dan imunisasi PCV yang tidak lengkap. Keseimbangan antara balok penekan dan pendorong ini menggambarkan kompleksitas tantangan fasilitas kesehatan di wilayah dengan padat penduduk.

4. Provinsi Nusa Tenggara Timur (Prevalensi Tertinggi Nasional)


Kontribusi Fitur terhadap Prediksi Stunting - Provinsi Nusa Tenggara Timur



Gambar 4.16 Waterfall Plot Prediksi Stunting Provinsi Nusa Tenggara Timur

Gambar 4.16 menjelaskan secara ekstrem pemicu di balik rekor prevalensi tertinggi secara nasional di Provinsi Nusa Tenggara Timur. Model menghasilkan tebakan akhir yang sangat tinggi di angka 33,815 dengan grafik yang didominasi oleh pergerakan balok merah secara masif. Kurangnya asupan susu (MMFF) dan minimnya pemantauan pertumbuhan memberikan sumbangsih penambahan risiko terbesar, masing-masing sebesar +1,0. Identifikasi tumpukan pendorong arah positif ini menegaskan keparahan krisis kelengkapan gizi dasar dan fasilitas pemantauan anak di wilayah tersebut.

5. Provinsi Bali (Prevalensi Terendah Nasional)




Gambar 4.17 *Waterfall Plot* Prediksi *Stunting* Provinsi Bali

Sebagai representasi wilayah dengan angka kasus terendah, *Waterfall Plot* Provinsi Bali pada Gambar 4.17 memperlihatkan pola sapuan biru yang sempurna. Prediksi akhir wilayah ini ditekan secara drastis hingga mencapai angka 12,565 tanpa adanya satu pun fitur utama yang memberi dorongan risiko. Keberagaman asupan makanan (MDD) dan efektivitas PMT menjadi indikator terkuat yang mengurangkan nilai prediksi dasar. Ketidadaan balok merah pada grafik ini mengonfirmasi kualitas standar keunggulan kesehatan ibu dan anak yang sangat baik di wilayah Bali.

6. Provinsi Jawa Barat (Populasi Terpadat Nasional)

Kontribusi Fitur terhadap Prediksi Stunting - Provinsi Jawa Barat



Gambar 4.18 Waterfall Plot Prediksi Stunting Provinsi Jawa Barat

Analisis visualisasi untuk provinsi dengan populasi terpadat, yaitu Jawa Barat, dapat diamati melalui Gambar 4.18. Meskipun memiliki tekanan persaingan akses yang tinggi, model secara mengejutkan memprediksi penurunan angka prevalensi menuju nilai 17,755. Penurunan ini didorong secara konsisten oleh efektivitas program PMT dan kecukupan keberagaman pangan (MDD). Terdapat satu variabel yang memberikan dorongan risiko kecil, yakni masalah akses sanitasi berisiko, yang merupakan dampak logis dari kepadatan permukiman penduduk di wilayah tersebut.

DAFTAR PUSTAKA

- [1] J. C. Waterlow, "Classification and definition of protein-calorie malnutrition," *British Medical Journal*, vol. 3, no. 5826, pp. 566–569, 1972.
- [2] D. H. Said and A. Rahmah, "Pencegahan stunting melalui edukasi gaya hidup sehat dan penguatan ekonomi," *Jurnal Pembelajaran Pemberdayaan Masyarakat (JP2M)*, vol. 5, no. 2, pp. 349–358, 2024, 2721-5148.
- [3] R. Rahagia, N. Sriyanah, I. A. Tyarini, A. Lontaan, and M. Yunus, "Upaya Pencegahan Stunting Berbasis Edukasi dan Sosialisasi," *Abdimas Polsaka: Jurnal Pengabdian Kepada Masyarakat*, vol. 2, no. 1, 2023, 2829-162X.
- [4] Kementerian Kesehatan RI, "Survei Status Gizi Indonesia (SSGI) 2024 Dalam Angka," Kementerian Kesehatan RI, tech. rep., 2025.
- [5] Badan Kebijakan Pembangunan Kesehatan, "Survei Kesehatan Indonesia (SKI) 2023 Dalam Angka," Kementerian Kesehatan RI, tech. rep., 2023.
- [6] Kementerian Sekretariat Negara RI, "Strategi Nasional Percepatan Pencegahan dan Penurunan Stunting 2025-2029," Kementerian Sekretariat Negara RI, tech. rep., 2024.
- [7] H. Supriyanto, "Implementasi Kebijakan Penurunan Stunting di Kecamatan Salem Kabupaten Brebes," *Jurnal Multidisiplin Indonesia*, vol. 2, no. 2, 2023, 2964-9048.
- [8] A. S. Saleh, T. Hasan, and U. K. S. Saleh, "Edukasi Penerapan Gizi Seimbang Masa Kehamilan Berbasis Pangan Lokal Sebagai Pencegahan Stunting," *AHMAR METAKARYA: JURNAL*

- PENGABDIAN MASYARAKAT*, vol. 2, no. 2, pp. 49–53, 2023, 2807-3576.
- [9] A. B. Zemariam et al., “Prediction of stunting and its socioeconomic determinants among adolescent girls in Ethiopia using machine learning algorithms,” *PLOS ONE*, vol. 20, no. 1, e0316452, 2025.
 - [10] T. Tamanna, S. Mahmud, N. Salma, M. M. Hossain, and M. R. Karim, “Identifying determinants of malnutrition in under-five children in Bangladesh: insights from the BDHS-2022 cross-sectional study,” *Scientific Reports*, vol. 15, no. 14336, 2025.
 - [11] M. A. E. Pratama, S. Hendra, H. R. Ngemba, R. Nur, R. Azhar, and R. Laila, “Comparison of Machine Learning Algorithms for Predicting Stunting Prevalence in Indonesia,” *SISFOKOM Journal (Information and Computer Systems)*, vol. 13, no. 2, pp. 200–209, 2024.
 - [12] S. Pande, R. Singh, and A. Kumar, “Analyzing determinants from both compositional and contextual level impeding desired linear growth of children in Indian context,” *BMC Nutrition*, vol. 9, p. 89, 2023.
 - [13] H. W. Jemil, S. W. Semayneh, A. B. Kassaw, and K. D. Gashu, “Predicting severe stunting and its determinants among under-five in Eastern African Countries: A machine learning algorithms,” *PLoS ONE*, vol. 21, no. 1, e0340221, 2026.
 - [14] BKKBN, *Peraturan Badan Kependudukan dan Keluarga Berencana Nasional Nomor 12 Tahun 2021 tentang Rencana Aksi Nasional Percepatan Penurunan Angka Stunting Indonesia Tahun 2021-2024*, Berita Negara Republik Indonesia Tahun 2021 Nomor 1188, Jakarta, 2021.
 - [15] Kementerian Kesehatan RI, *Peraturan Menteri Kesehatan Republik Indonesia Nomor 2 Tahun 2020 tentang Standar Antropometri Anak*, Berita Negara Republik Indonesia Tahun 2020 Nomor 2, Jakarta, 2020.

- [16] World Health Organization, *WHO Child Growth Standards: Methods and Development*. Geneva: World Health Organization, 2006.
- [17] World Health Organization, “Childhood Stunting: Context, Causes and Consequences Framework,” World Health Organization, tech. rep., 2013, Akses daring pada 2 Februari 2026.
- [18] I. D. Id, *Machine Learning: Teori, Studi Kasus dan Implementasi Menggunakan Python*, 1st ed. Pekanbaru: UR PRESS, 2021, ISBN: 978-632-255-092-6.
- [19] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*, 2nd ed. New York: Springer, 2021.
- [20] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [21] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009, p. 588.
- [22] Q. Zhou, Q. Zhao, P. Zhu, and Z. Huang, “Pest Bird Density Forecast of Transmission Lines by Random Forest Regression Model and Line Transect Method,” *Proceedings of [Nama Konferensi/Jurnal jika diketahui, misal: IEEE International Conference on...]*, Jiangmen Power Supply Bureau of Guangdong Power Grid, 2020.
- [23] H. Shen, H. Zhao, and Y. Jiang, “Machine Learning Algorithms for Predicting Stunting among Under-Five Children in Papua New Guinea,” *Children*, vol. 10, no. 10, p. 1638, 2023.
- [24] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd. Melbourne: OTexts, 2021.
- [25] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in Python*. Springer Nature, 2023.

- [26] J.-O. Irisson, A. D'Hervé, C. M. Guigand, L. Stemmann, and F. Lombard, "Iterative spatial leave-one-out cross-validation and gap-filling based data augmentation for supervised learning applications in marine remote sensing," *GIScience & Remote Sensing*, vol. 59, no. 1, pp. 1281–1300, 2022.
- [27] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Boston: Morgan Kaufmann, 2012, ISBN: 978-0-12-381479-1.
- [28] M. Kutlu, T. B. Donmez, and C. Freeman, "Machine learning interpretability in diabetes risk assessment: a SHAP analysis," *Computers and Electronics in Medicine*, 2024, Also available at University of Southampton ePrints.
- [29] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017, pp. 4765–4774.
- [30] U. Orji and E. Ukwandu, "Machine learning for an explainable cost prediction of medical insurance," *Machine Learning with Applications*, vol. 15, p. 100516, 2024.
- [31] G.-W. Cha, H.-J. Moon, and Y.-C. Kim, "Comparison of Random Forest and Gradient Boosting Machine Models for Predicting Demolition Waste Based on Small Datasets and Categorical Variables," *International Journal of Environmental Research and Public Health*, vol. 18, no. 16, p. 8530, 2021.
- [32] M. Fatmawati, B. A. Herlambang, and N. Q. Nada, "Random Forest Algorithm for Toddler Nutritional Status Classification," *Journal of Applied Informatics and Computing (JAIC)*, vol. 8, no. 2, pp. 428–433, 2024.

LAMPIRAN

A Dataset

Penelitian ini menggunakan data sekunder dari laporan Survei Status Gizi Indonesia (SSGI) tahun 2024. Sebagai bagian dari studi pendahuluan, data telah melalui tahap ekstraksi dan agregasi awal untuk memastikan ketersediaan variabel determinan. Berikut adalah rincian akses data:

1. **Sumber Data Mentah (Laporan Resmi):** Buku Laporan Survei Status Gizi Indonesia (SSGI) Tahun 2024 oleh Badan Kebijakan Pembangunan Kesehatan (BKPK) Kementerian Kesehatan:
<https://www.badankebijakan.kemkes.go.id/survei-status-gizi-indonesia-ssgi-2024/>
2. **Draf Dataset Pra-pemrosesan (Studi Pendahuluan):** Dataset tabular yang telah diekstraksi berbasis provinsi yang siap digunakan dalam eksperimen pemodelan:
https://bit.ly/Dataset_SSGI_2024